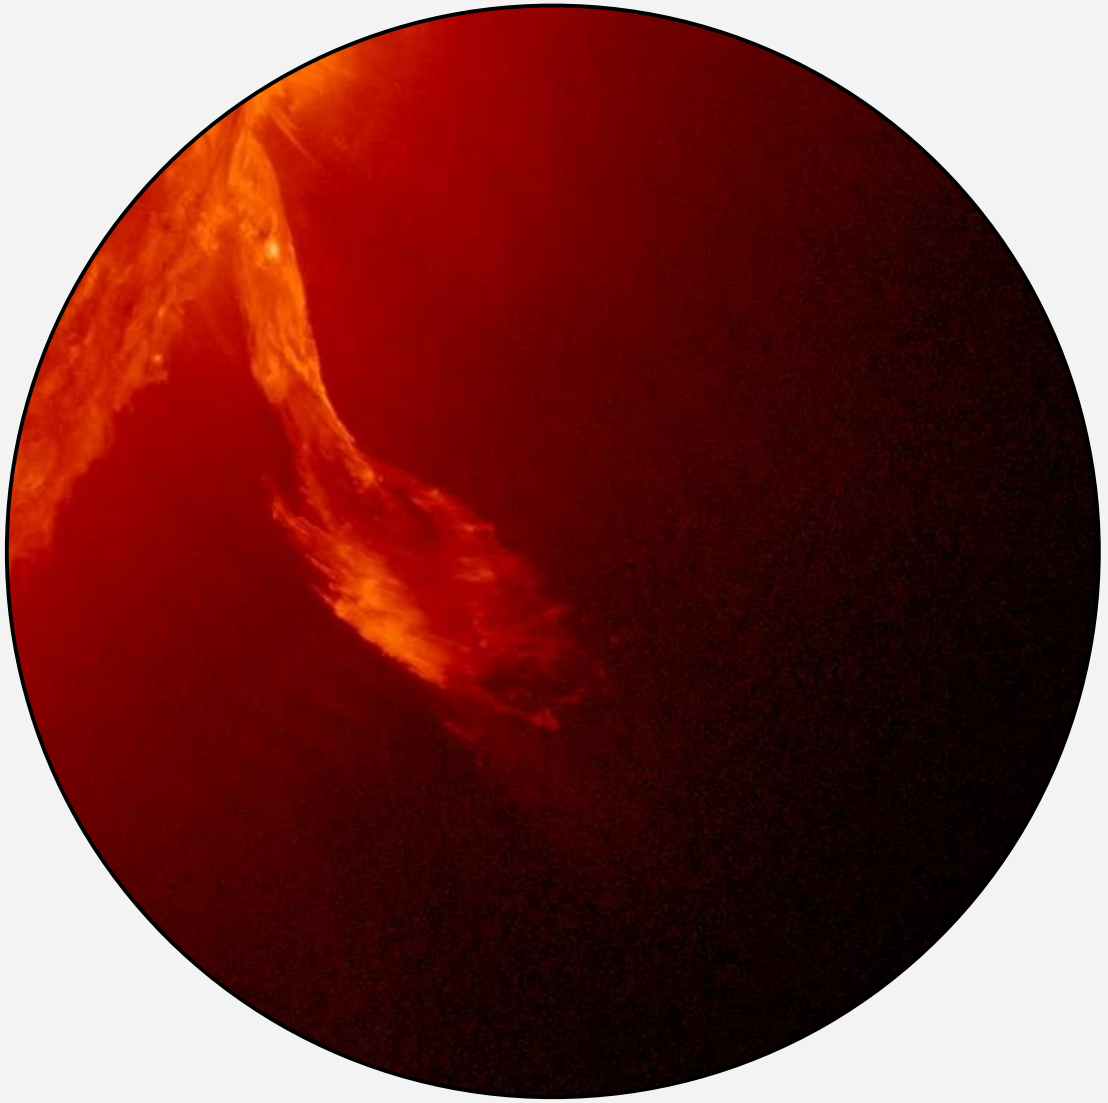
Copiloto de Física Solar

Del dato solar al lenguaje



Juan Esteban Agudelo

Observatorio Astronómico Nacional, Universidad Nacional de Colombia

ESCUELA ASTROFÍSICA SOLAR · 29 OCT 2026

OBSERVATORIO ASTRONÓMICO NACIONAL DE COLOMBIA

GOSA GROUP OF SOLAR ASTROPHYSICS UN - COLOMBIA

Ruta de la sesión

01

Surya y el dato solar

Qué es Surya, sus 13 canales y cómo se normalizan los datos. Práctica con el cuaderno, secciones 1 a 5. (≈ 40 min)

02

Pares imagen–texto

Cómo construir descripciones de observaciones solares a partir de la literatura y de catálogos de eventos. (≈ 20 min)

03

De los tokens al lenguaje

El proyector, la secuencia que lee el LLM y el entrenamiento. Práctica con el cuaderno, secciones 6 y 7. (≈ 35 min)

04

Resultados y más allá

Qué logró el prototipo frente a líneas base, sus límites, SUVI y los ejercicios. (≈ 25 min)

El copiloto, y por qué empezamos con un VLM

“Muéstrame la evolución de esta región activa en las últimas 48 horas y estima la probabilidad de una erupción de clase M en las próximas 24 horas. Explica qué características magnéticas son las más responsables de ese riesgo.”

Lo que un científico debería poder preguntar

Un LLM orquesta el acceso a los datos, ejecuta Surya y explica los resultados en lenguaje científico.

El eslabón que falta

Antes de que un LLM pueda razonar sobre lo que ve Surya, los embeddings de Surya deben **traducirse al espacio de lenguaje del LLM**. Ese flujo corresponde a la descripción básica de un modelo de visión y lenguaje (VLM).

1 — **VLM**
Describir una observación de SDO (ahora)

2 — **P&R**
Ajuste por instrucciones: responder preguntas sobre ella

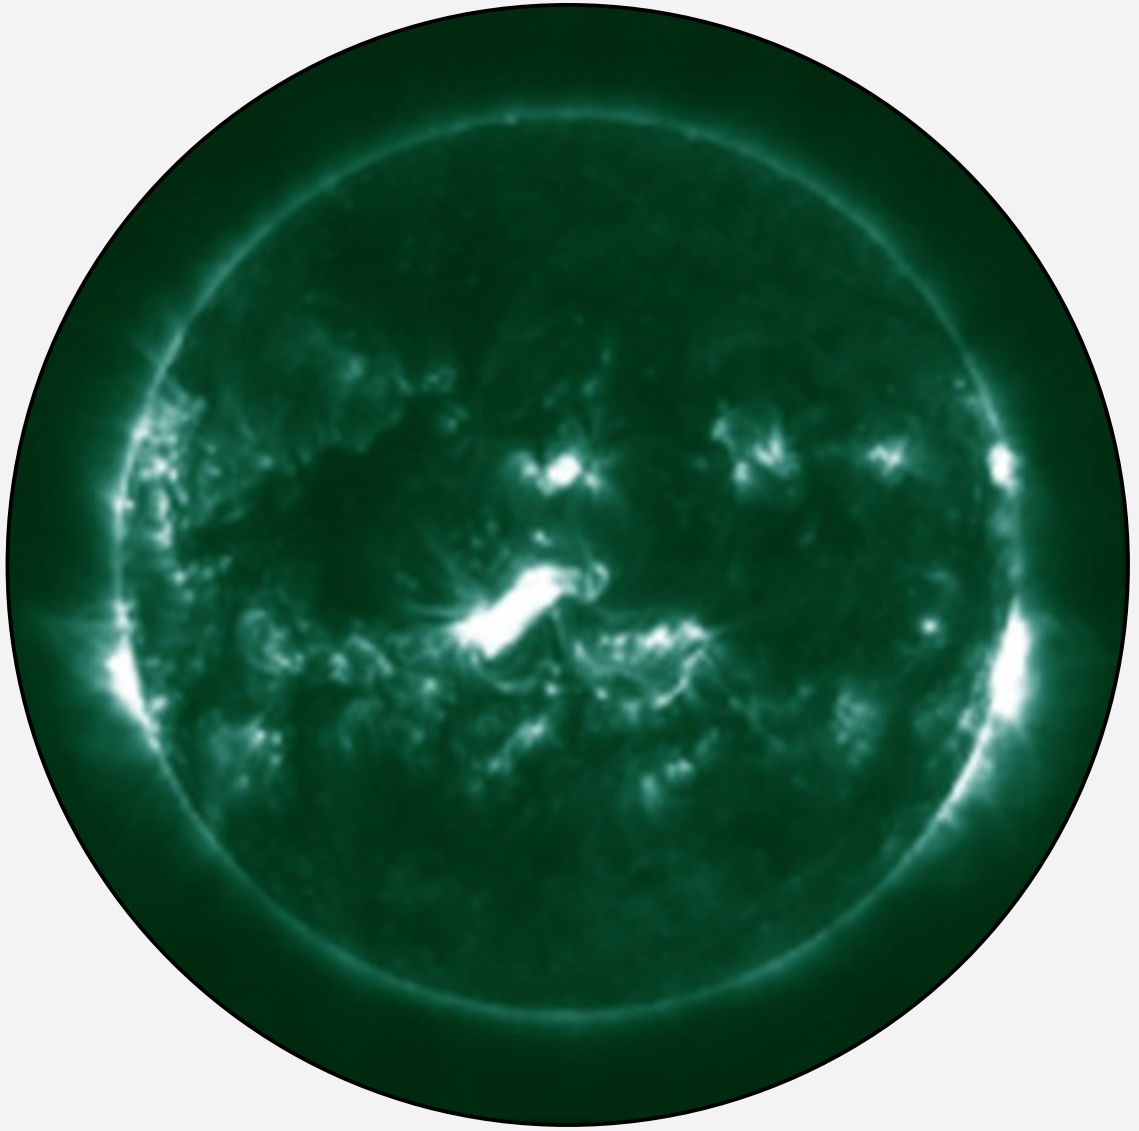
3 — **Herramientas**
Consultar archivos y catálogos, ejecutar Surya

4 — **Copiloto**
Agente que planifica, calcula y explica

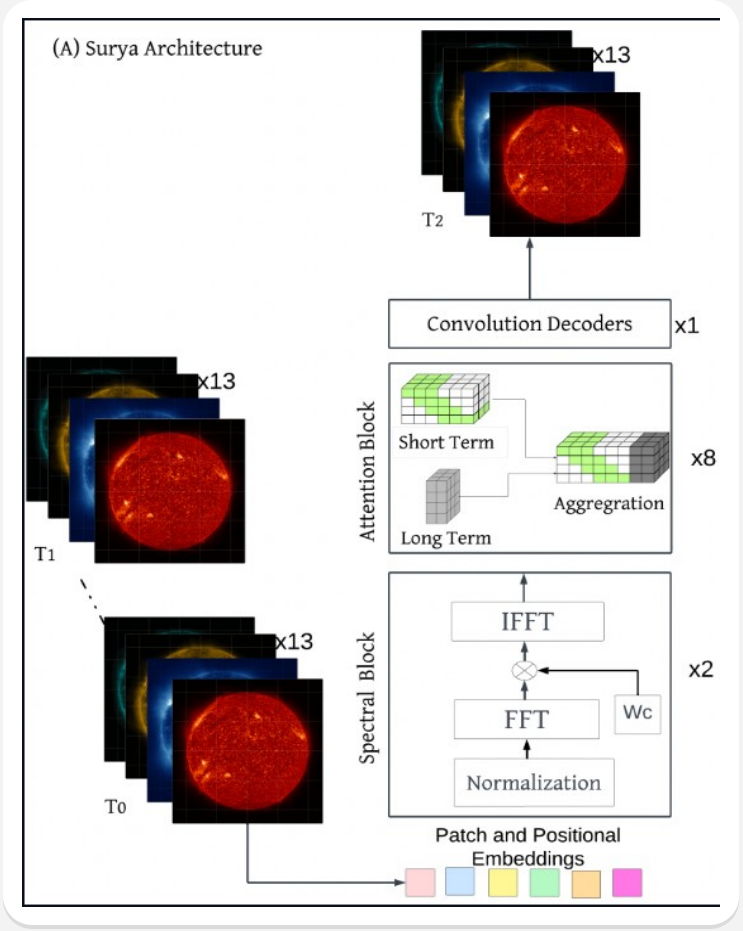
01

Surya y el dato solar

El modelo, sus canales y su normalización



Surya: un modelo fundacional para heliofísica



Transformer espaciotemporal con compuertas espectrales y atención de corto y largo alcance.

366M
parámetros

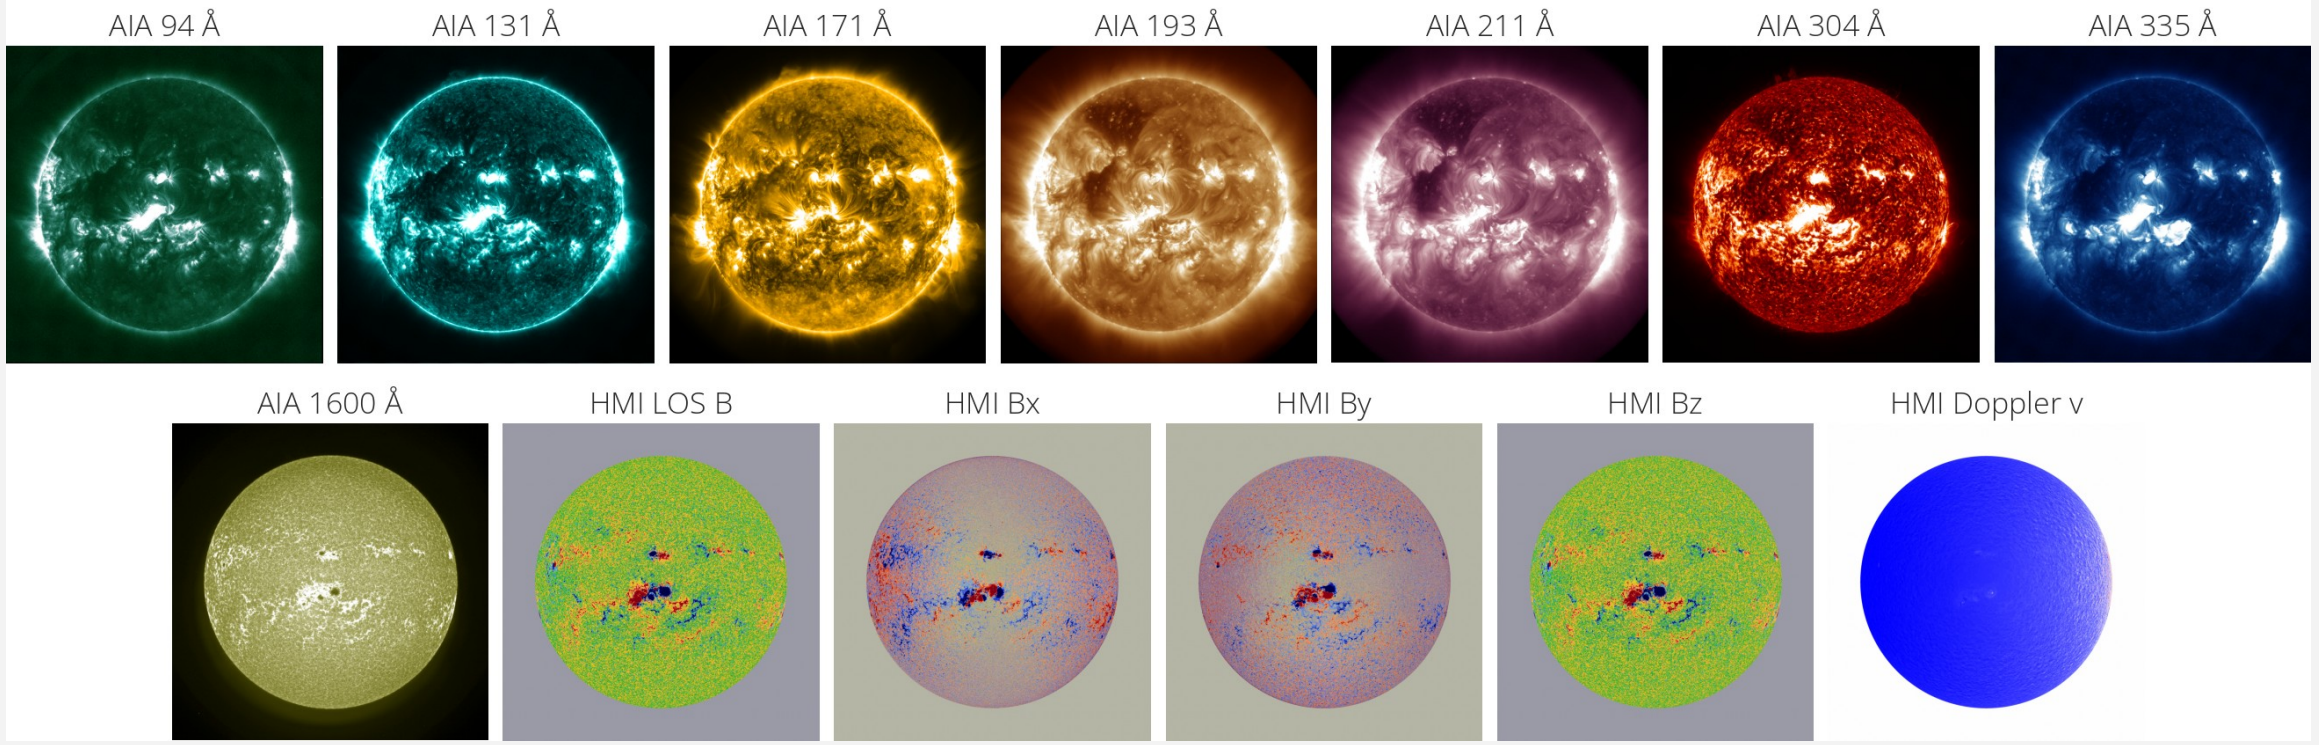
13
canales: 8 AIA + 5 HMI

4096^2
resolución nativa de SDO

- Preentrenado para **pronosticar el Sol una hora adelante** (cadencia de 12 min, dos cuadros de entrada separados 60 min).
- Afinado para tareas posteriores: pronóstico de erupciones, segmentación de regiones activas, velocidad del viento solar, espectros EUV.
- Como **nunca se entrenó para hablar,** sus embeddings no están alineados con el lenguaje.

Surya: Roy et al. (2025).

La entrada de Surya: 13 canales y dos instantes



Cada observación apila 8 canales de AIA (EUV y UV, 94–1600 Å) y 5 productos de HMI (magnetograma de línea de visión, campo vectorial Bx, By, Bz y velocidad Doppler), cada uno de 4096 × 4096 px, en dos instantes separados 60 min, y forma un tensor de entrada (1, 13, 2, 4096, 4096).

Muestra de validación de Surya, 2014-01-07 (primero de los dos instantes), estiramiento 2–98 % por canal.

Normalizar los datos antes de Surya

Lo que hace cada paso

- Multiplicar por un **factor de escala** (0.01 en los 13 canales).
- Logaritmo con signo, sign(x) · log1p(|x|): comprime valores enormes, como los de una erupción, y conserva la polaridad de HMI.
- Estandarizar, (x − media) / (desviación + ε), con constantes globales del conjunto de datos.

Qué esperar al mirar los números

- Las constantes son globales, no por imagen: la salida de una imagen no queda con media 0 y desviación 1.
- En AIA el valor crudo mínimo es 0 y termina en −media/desviación (en aia94, ≈ −0.54), no en 0.
- En una erupción X1.2 los píxeles quedan muy por encima de la media global: el máximo de aia94 llega a ≈ 220.

× 0.01
factor de escala (paso 1)

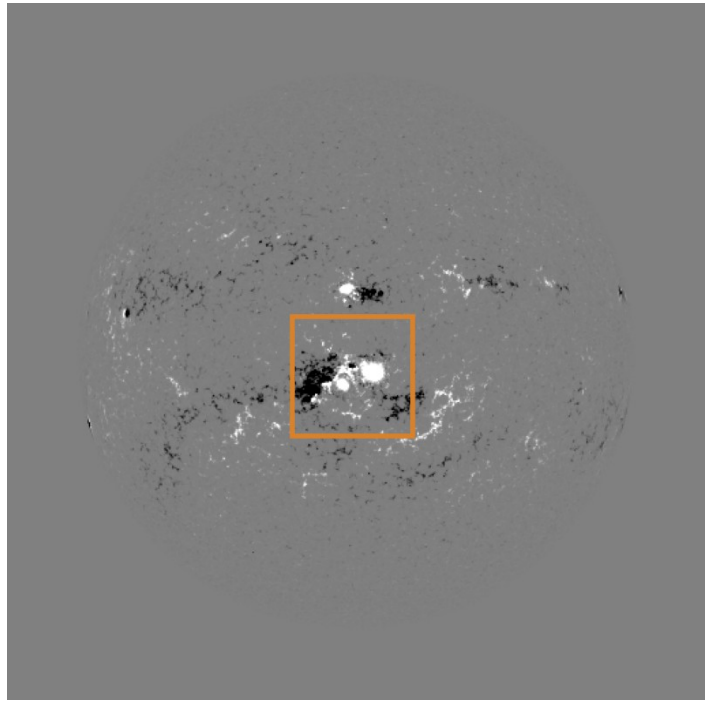
log
logaritmo con signo (paso 2)

(x−μ)/σ
estandarizar (paso 3)

Práctica: **cuaderno, sección 2**. Aplica los tres pasos a mano sobre un recorte real de la AR 11944 (7 de enero de 2014, 18:24 UT) y compáralos con la tabla de los 13 canales.

Constantes de Surya: scalers.yaml del punto de control oficial.

La región de interés



Una región activa del catálogo de NOAA, recortada sobre los tokens de Surya.

704 px
lado de la caja (AR 11944)

45 × 45
tokens de la región (de 256 × 256)

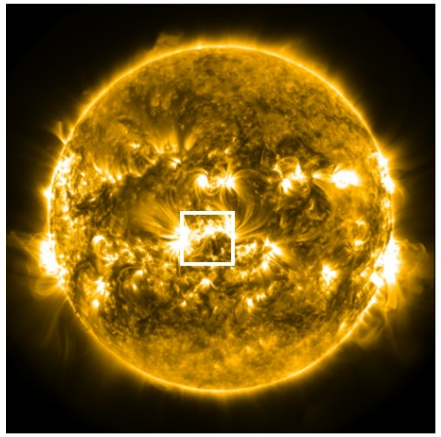
÷ 16
del píxel al token

- La caja viene del **catálogo de regiones activas de NOAA (HEK)**, en píxeles de la imagen de 4096 × 4096.
- Cada token es un parche de 16 × 16 px: el índice del token es el píxel dividido entre 16, redondeando hacia arriba el final de la caja.
- En los arreglos las filas **crecen hacia el norte**: las imágenes se muestran con origin="lower".

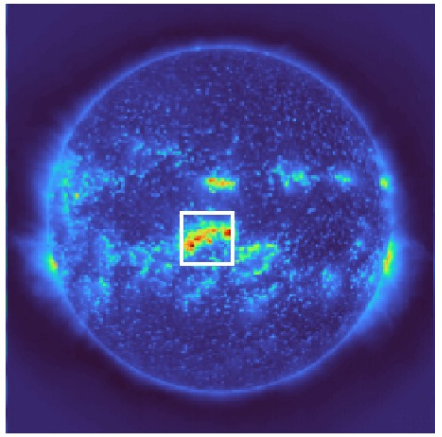
Magnetograma de HMI, 2014-01-07 18:24 UT, con la caja de la AR 11944.

Surya en ejecución (realizado en el clúster de la UNAL)

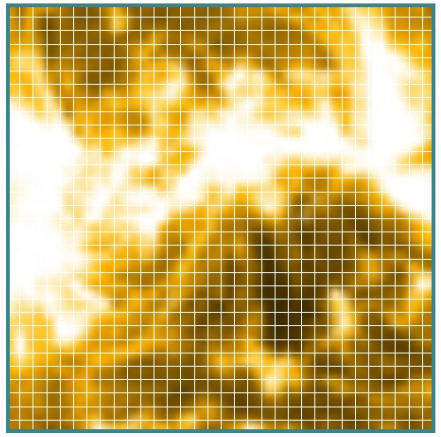
AIA 171 Å (input)



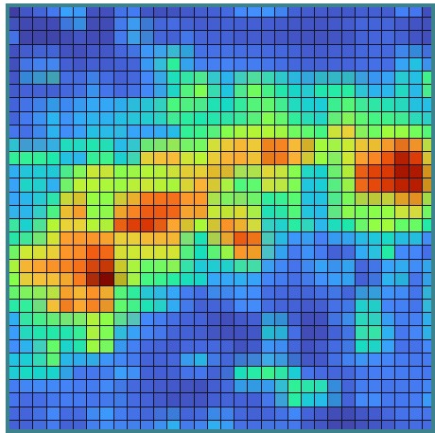
Token L2 norm (output)



Zoom: 512 × 512 px



Same zoom: 32 × 32 tokens



entrada

`(1, 13, 2, 4096, 4096)`

1.74 GB en fp32

salida del codificador

`(1, 65536, 1280)`

un token por parche de 16 × 16 px; el tiempo está plegado en los canales

366.2M
pesos cargados

8.9 GB
VRAM máxima, RTX A4500

Cada celda representa un token, donde cada token corresponde a un parche de 16 × 16 px, con la información de los 13 canales y de ambos instantes codificada en él. Así, el mapa es de 256 × 256 tokens en lugar de 4096 × 4096 píxeles, y en él destacan las regiones activas y el limbo.

Punto de control oficial nasa-ibm-ai4science/Surya-1.0, muestra de validación 2014-01-07. Ampliación reescalada del render del cuaderno.

Recortar tokens en lugar de píxeles

Lo que decidimos

- Ejecutar Surya sobre el **disco completo**, como fue entrenado.
- Conservar solo los tokens dentro de la caja del evento. Por ejemplo, una región de 512 × 512 px equivale a 1024 tokens.
- Aplicarles un pooling promedio para obtener unos 256 tokens, ya que el contexto del LLM es limitado.

¿Por qué no recortamos primero la imagen?

- Los embeddings de posición se infieren a partir del disco completo, tal como se diseñó el modelo desde el principio.
- La compuerta espectral funciona con FFT y se entrenó para capturar relaciones a lo largo de toda la escena.
- Recortar quitaría el contexto de posición y de escala que Surya aprendió.

65,536
tokens de Surya por observación

1024
tokens de la región

256
nuestra meta por región

La **caja de la parte 02** corresponde a la región que queremos conservar. Una gran ventaja de este flujo es que una observación con tres regiones activas puede dar tres muestras de entrenamiento.

LLaVA-1.5: Liu et al. (2023).

Manos a la obra (1/2)

1 **Datos**
Abrir el cuaderno y cargar el recorte de 13 canales

2 **Normalizar**
Los tres pasos a mano sobre aia94 y hmi_m

3 **Región**
De píxeles a tokens (÷ 16) y la caja sobre el disco

4 **Tokens**
Mapa de normas de los 45 × 45 tokens de Surya

5 **Pooling**
De 45 × 45 a 16 × 16 = 256 tokens, en NumPy

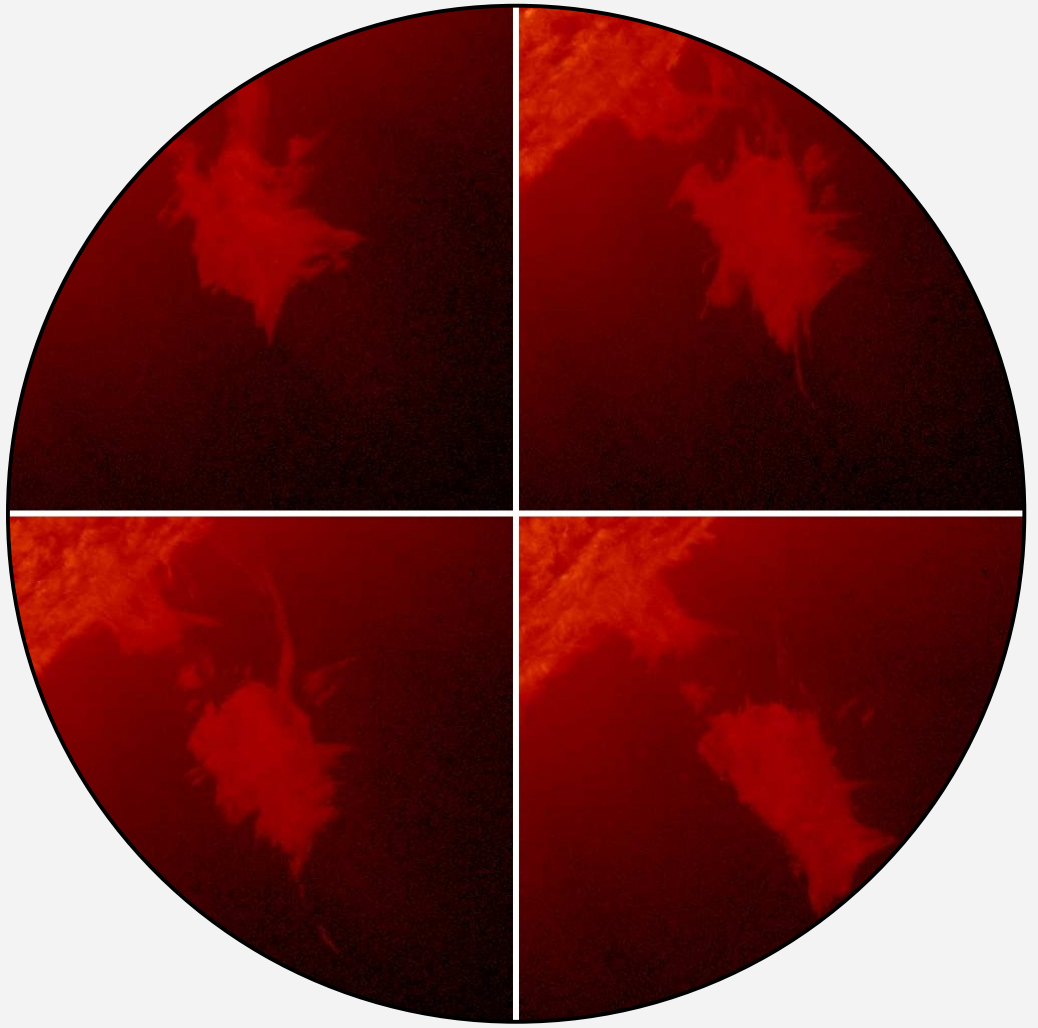
Cuaderno de la sesión

- Carpeta 02_Notebooks: 01_Del_dato_solar_al_caption.ipynb, secciones 1 a 5 (≈ 20 min). Los datos están en 03_Datos y no hace falta GPU.
- Entorno: escuela-solar, el de la guía de instalación. No necesita PyTorch.

02

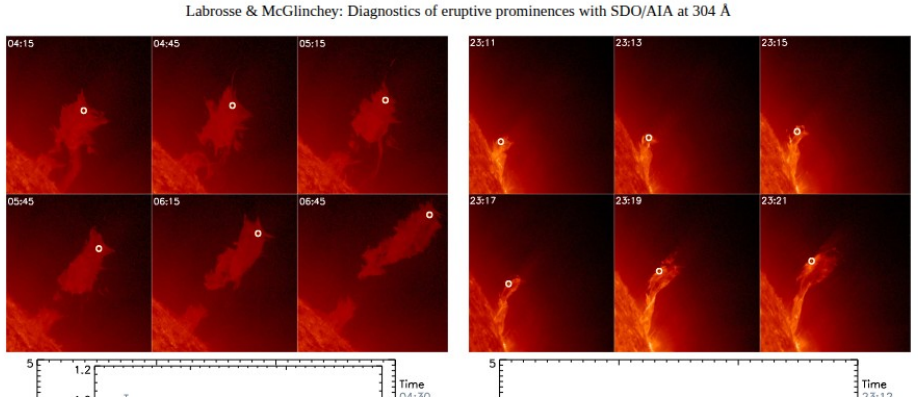
Datos: contexto y observaciones

Construir pares imagen–texto a partir de la literatura de SDO



¿Por qué no darle a Surya la figura del artículo?

FIGURA



- Un instante, uno o dos canales
- PNG recortado, reescalado y anotado

≠

LO QUE NECESITA

`(13, 2, 4096, 4096)`

canales × instantes × píxeles del disco completo ≈ 1.74 GB en fp32

- Los 8 canales de AIA y los 5 de HMI
- Dos cuadros separados 60 min
- El disco completo: importan las posiciones y la escala

Del artículo extraemos la **descripción** junto con la **fecha** y la **ubicación**. Luego las usamos para descargar la observación real del **archivo de SDO**.

Figura: Labrosse & McGlinchey (2012).

De un artículo a una observación

1
Buscar artículos
API de SciX / NASA ADS sobre una base local de artículos arbitrados de SDO

›

2
Extraer figuras
PyMuPDF y un clasificador de imágenes solares: conserva observaciones y descarta gráficas

›

3
Leer metadatos
Un LLM lee el pie de figura, los párrafos que la citan y las tablas: qué, cuándo, canal y dónde (aprox.)

›

4
Ubicar el evento
Consultar el Heliophysics Event Knowledgebase (HEK) por ese tipo de evento y esa fecha

›

5
Emparejar
Comparar la figura del artículo con el mapa de SDO y conservar la mejor región

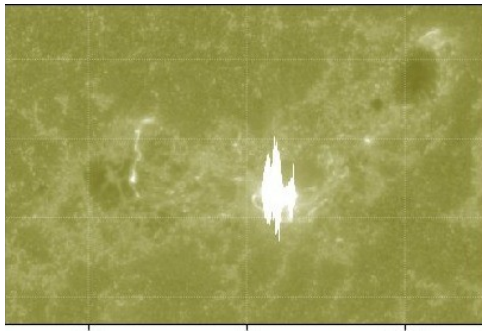
Salida por figura: un par de entrenamiento

qué
Erupción de luz blanca, AR 11515, 1600 Å

cuándo
2012-07-05 03:36 UT

dónde
una **caja sobre el disco** (arcsec)

La fecha y la caja seleccionan la observación y los tokens que usará Surya.



Pasos 4–5: ubicar el evento, emparejar y recortar

1 Consultar HEK

Se buscan eventos del fenómeno del artículo a la hora indicada (±15 s): erupciones, regiones activas, filamentos, CMEs… Las prominencias se buscan como erupciones, eyecciones y burbujas.

2 Restringir por región

Se conservan los eventos del sector que menciona el artículo (NE, SO, …) y se recorta una caja alrededor de cada candidato.

3 Comparación con plantilla

Se desliza la figura del artículo sobre cada candidato (OpenCV, correlación cruzada normalizada). Devuelve la mejor ubicación y un **puntaje de confianza**.

Heliophysics Event Knowledgebase

Reúne reportes de eventos, incluidos los de **NOAA SWPC** (erupciones de GOES, regiones activas numeradas) y módulos automáticos de detección de estructuras sobre SDO.

Los metadatos del artículo dan *qué* y *cuándo* → HEK da **posiciones candidatas** → la propia figura elige la correcta.

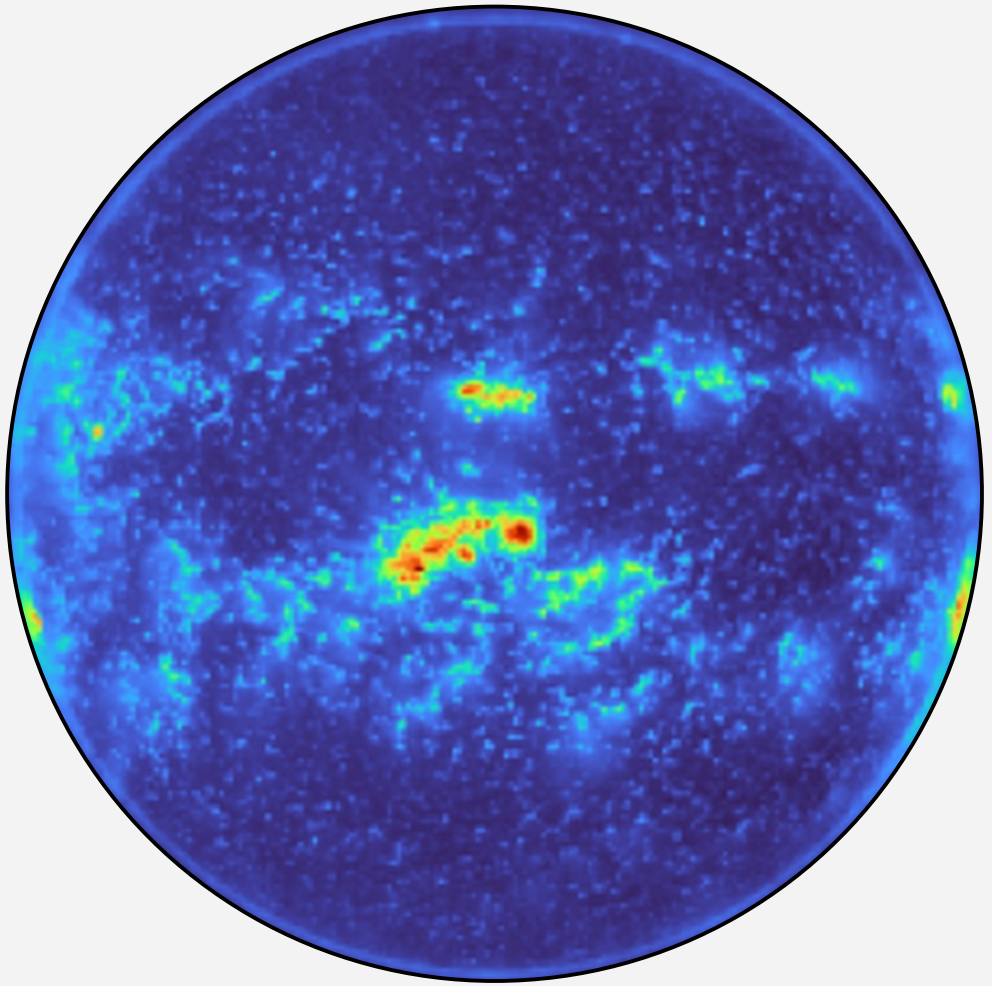
Diseño e implementación: Julio Flórez

HEK: Hurlburt et al. (2012).

03

De los tokens de Surya al lenguaje

Pase hacia adelante, presupuesto de tokens y proyector



La arquitectura

Un proyector no lineal

Como Surya aprendió a **pronosticar**, no sabe traducir a texto, que es un dominio completamente distinto y no relacionado linealmente con la tarea de preentrenamiento.

Usando Qwen3-8B

Tiene pesos abiertos, tamaño oculto 4096, cabe en nuestras GPU, y mantenemos **una sola familia de modelos** para decodificador, juez, metadatos y agente.

Es más barato de lo que parece

Como Surya está congelado, los embeddings se calculan una vez y se guardan: Surya y el LLM nunca comparten VRAM y lo único que se entrena es el proyector.

Disco SDO
13 canales × 2 cuadros
`4096²`

›

Surya
366M · congelado
`65536 × 1280`

›

Recorte + pool
tokens de la caja → 256
`256 × 1280`

›

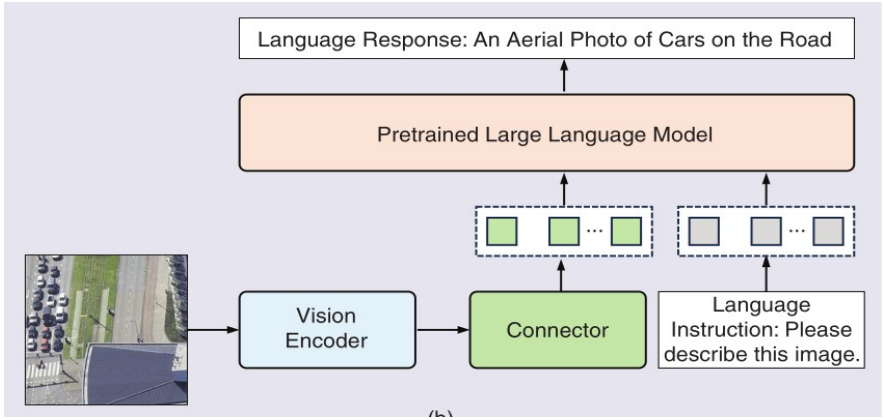
Proyector MLP
entrenable · $W_2 \cdot \mathrm{GELU}(W_1 v + b_1) + b_2$
`256 × 4096`

›

Qwen3-8B
+ instrucción de texto
`tamaño oculto 4096`

›

Caption
"A white-light flare in…"



Corresponde a la misma receta de los VLM de teledetección (**GeoChat, RS-LLaVA, EarthGPT**, …): un codificador visual de dominio, un conector y un LLM preentrenado. La observación de la Tierra ya demostró que esta receta funciona con imágenes satelitales multiespectrales, y es la referencia análoga más cercana a nuestro caso.

Revisión de VLM de teledetección: Weng et al. (2025). Qwen3: Yang et al. (2025).

La secuencia que lee el LLM

PASO 1

build_example

Decide cuántas posiciones hay y cuáles cuentan para la pérdida. Solo usa texto: reserva 256 posiciones para la imagen con <|image_pad|>.

PASO 2

collate

Junta varias muestras en un lote rectangular: rellena a la derecha y marca con attention_mask lo que es real.

PASO 3

inject_visual

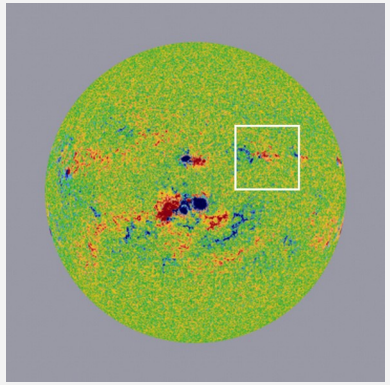
Pone los 256 vectores del proyector en las posiciones reservadas. Es el único paso donde entra la imagen.

Ejemplo real: *286 posiciones* para un caption de 10 tokens:

encabezado 0–3 **imagen 4–259** **pérdida 275–284**

Detalle: La pérdida se calcula solo sobre el caption y su marca de fin **(<|im_end|>)**, no sobre la pregunta ni sobre la imagen.

Un primer proyector de prueba, de punta a punta

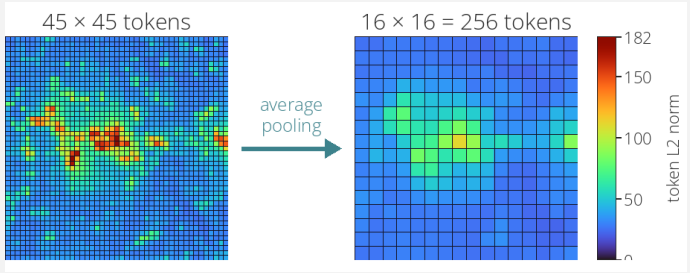


Entrada: magnetograma de HMI, 2014-01-07, norte arriba. Caja: la región de 704 × 704 px de la AR 11942.

Surya
congelado · 45 × 45 tokens agrupados
`256 × 1280`

Proyector
MLP · 22 M · 139 pares
`256 × 4096`

Qwen3-8B
+ instrucción de texto
`tamaño oculto 4096`



caption generado

An active region in the southern hemisphere on the west side of the disk (S11 W18) with 1 sunspot. It is a small single unipolar sunspot.

caption de referencia (McIntosh + plantilla)

An active region in the northern hemisphere on the west side of the disk (N10 W29) with 3 sunspots. It is a bipolar group where one spot has penumbra; its largest spot has a rudimentary penumbra and few spots lie between its leading and following ends.

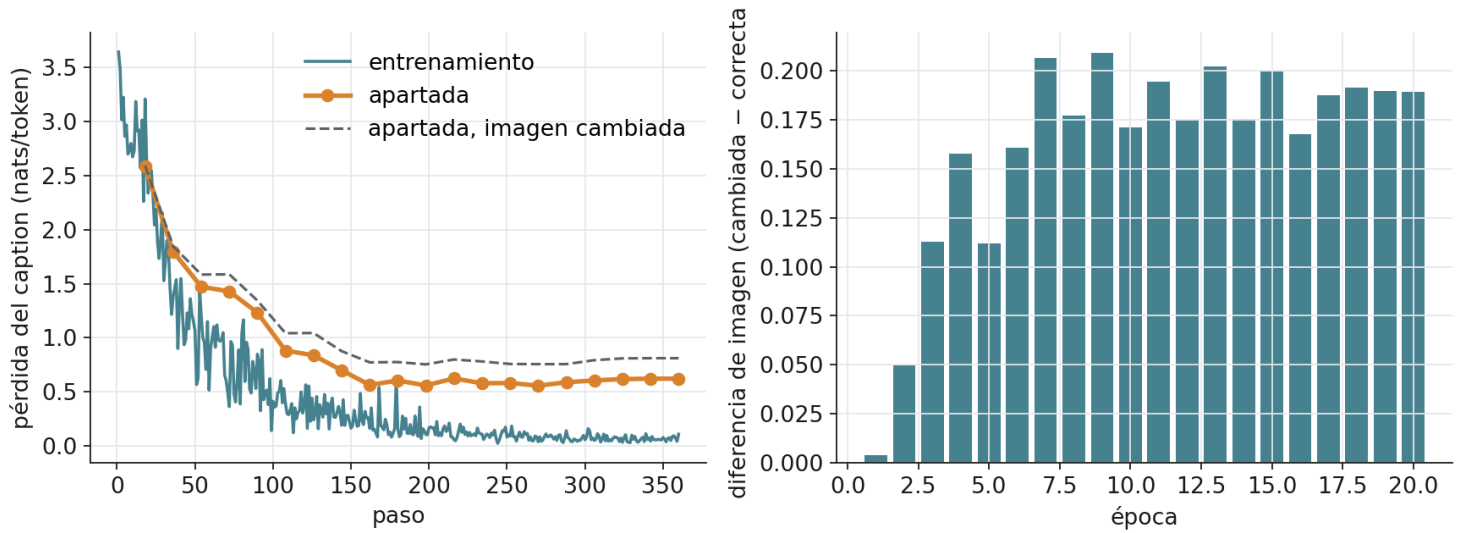
Datos (independientes del flujo de artículos)

- 139 recortes de entrenamiento de Surya, 55 apartados
- Clase de McIntosh de los reportes de regiones de NOAA
- Captions armados con una plantilla fija a partir de esa clase

Esto demuestra que el flujo del VLM (Surya → recorte → proyector → Qwen3) funciona, aunque la respuesta todavía no tenga la calidad correcta.

Clasificación de McIntosh: McIntosh (1990).

Resultados del prototipo



Pérdida de entrenamiento y apartada, y diferencia de imagen (corrida 2: 139 muestras de 18 días).

0.557
pérdida apartada (mejor época)

En días nuevos supera a las líneas base en **hemisferio (17 de 19 contra 7), posición y latitud**; con la imagen cambiada la pérdida sube +0.18. En las 2 regiones del 7 de enero pierde contra «siempre norte».

Límites

No aprendió a contar manchas (6 de 19) y el error de longitud es grande (31°). ***Prueba que el flujo entrena, no cuán bien describe el Sol.***

Corrida 2 del prototipo, 9 de octubre de 2026.

Cómo sabremos si funciona

NIVEL 1

Métricas léxicas

BLEU, METEOR, ROUGE-L, CIDEr contra captions de referencia. Baratas y automáticas, pero ciegas a la física.

NIVEL 2

LLM como juez

Puntúa la **coherencia física**: ¿es el fenómeno correcto? ¿el canal de AIA/HMI correcto? ¿la región correcta?

NIVEL 3

Revisión humana

Físicos solares califican una muestra. La última palabra, y una verificación del juez.

Nivel 2, p. ej. *"Una erupción en la AR 11515 vista en AIA 171 Å"* para una observación de 1600 Å: **fenómeno ✓** **región ✓** **canal ✗**

Aviso: La dinámica de las erupciones está fuera de alcance por diseño, ya que Surya ve **dos cuadros separados 60 min**, así que describimos estados antes/después, no la fase impulsiva.

Manos a la obra (2/2)

1 **Proyector**
MLP 1280 → 4096 → 4096 en NumPy: 22.03 M de parámetros

2 **Secuencia**
Posiciones de la imagen y de la pérdida, y tokens especiales

3 **Resultados**
Captions generados contra la referencia en 55 regiones apartadas

4 **Líneas base**
Hemisferio, posición y manchas: el modelo contra un modelo tonto

5 **Ejercicios**
Cuatro ejercicios con comprobaciones; el último busca un sesgo del modelo

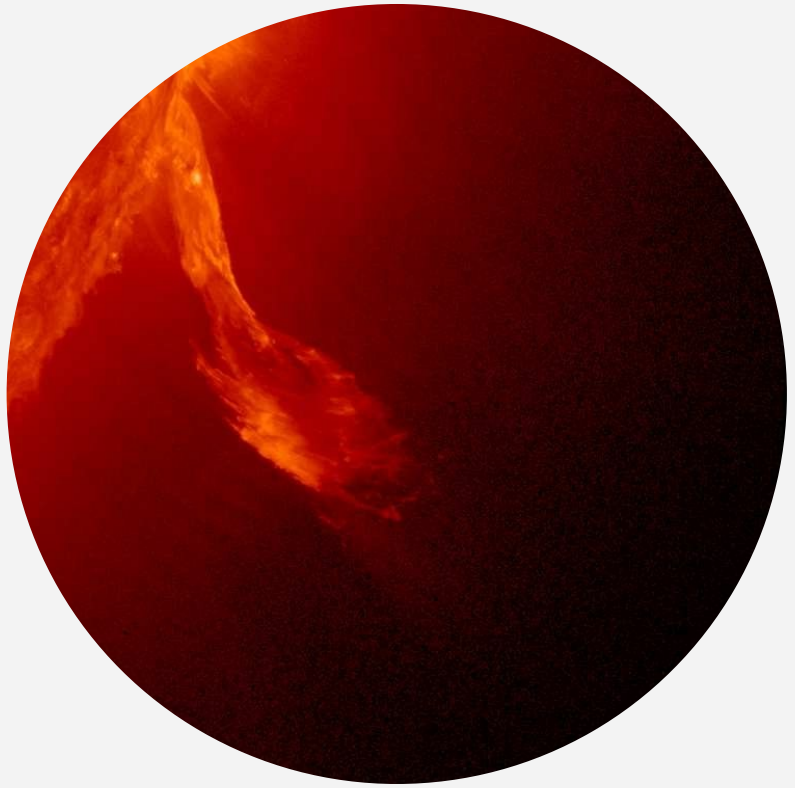
Cuaderno de la sesión

- Secciones 6 a 9 del cuaderno (≈ 15 min). Las soluciones están en 05_Recursos_adicionales.
- Intenten cada ejercicio antes de mirar las soluciones.

04

Resultados y más allá de SDO

Qué logró el prototipo, sus límites y SUVI



Más allá de SDO: ¿puede Surya ver a través de GOES-SUVI?

> *"SDO is an ongoing mission that runs concurrently with the GOES-SUVI operational satellites (which also makes EUV imaging observations) [...] This ensures that the Surya foundation model will remain applicable to future unseen data, thereby extending its utility beyond historical records."*
>
> Roy et al. (2025), §2.1

SUVI es un instrumento **operativo** de monitoreo del clima espacial en GOES-R. Si Surya transfiere, el copiloto podría trabajar con **datos en vivo** además de SDO.

Solo 6 de los 13 canales de Surya tienen un equivalente en SUVI

94 Å directo	**131 Å** directo	**171 Å** directo	**304 Å** directo
193 → 195 aprox.	**211 → 284** aprox.	**335 Å** ninguno	**1600 Å** ninguno (UV)
HMI × 5 ninguno: GOES no lleva magnetógrafo			

SUVI: 1280^2 px a 2.5″/px frente a AIA 4096^2 a 0.6″/px (~4× más grueso).

Estado actual

- Emparejamos descargas de SUVI y SDO para las mismas fechas.
- Se aplicó un filtro de ruido a los cuadros de SUVI, porque a veces vienen con mucho ruido.

SUVI: Darnel et al. (2022).

Mensajes para llevar

01 El objetivo

El Copiloto de Física Solar combina **Surya**, un modelo fundacional de 366M de parámetros entrenado con SDO, con un LLM de código abierto. Su primer bloque es un **modelo de visión y lenguaje** que debe describir observaciones de SDO y las estructuras en ellas.

02 Los datos

Los artículos científicos dan el **contexto** necesario para pedir los **datos observacionales** y crear los **pares imagen–texto.** El flujo se implementó con un LLM que lee qué muestra cada figura, junto con catálogos de eventos solares (HEK) y una comparación con plantilla para ubicar las estructuras en el disco solar real.

03 El proyector

Surya recibe como entrada el **disco completo** y devuelve los tokens correspondientes. Con ellos, recortamos los de la región que nos interesa y los agrupamos en 256 tokens para que quepan en la ventana de contexto del LLM, y luego los proyectamos con un **MLP al LLM Qwen3-8B.** Ya tenemos un primer proyector de prueba entrenado.

04 Siguientes pasos y más allá de SDO

Seguiremos con el flujo por lotes, el conjunto piloto y el entrenamiento del proyector con datos reales. Además, probamos si Surya transfiere a **GOES-SUVI** para ampliar su dominio de aplicación.

Referencias

[1] Roy, S., “Surya: Foundation Model for Heliophysics”, *arXiv e-prints*, Art. no. arXiv:2508.14112, 2025. doi:10.48550/arXiv.2508.14112.

[2] Labrosse, N. and McGlinchey, K., “Plasma diagnostic in eruptive prominences from SDO/AIA observations at 304 Å”, *Astronomy and Astrophysics*, vol. 537, Art. no. A100, EDP, 2012. doi:10.1051/0004-6361/201117801.

[3] Song, Y. L., Tian, H., Zhang, M., and Ding, M. D., “Observations of white-light flares in NOAA active region 11515: high occurrence rate and relationship with magnetic transients”, *Astronomy and Astrophysics*, vol. 613, Art. no. A69, EDP, 2018. doi:10.1051/0004-6361/201731817.

[4] Hurlburt, N., “Heliophysics Event Knowledgebase for the Solar Dynamics Observatory (SDO) and Beyond”, *Solar Physics*, vol. 275, no. 1–2, pp. 67–78, 2012. doi:10.1007/s11207-010-9624-2.

[5] Liu, H., Li, C., Li, Y., and Lee, Y. J., “Improved Baselines with Visual Instruction Tuning”, *arXiv e-prints*, Art. no. arXiv:2310.03744, 2023. doi:10.48550/arXiv.2310.03744.

[6] Weng, X., Pang, C., and Xia, G.-S., “Vision-Language Modeling Meets Remote Sensing: Models, datasets, and perspectives”, *IEEE Geoscience and Remote Sensing Magazine*, vol. 13, no. 3, IEEE, pp. 276–323, 2025. doi:10.1109/MGRS.2025.3572702.

[7] Yang, A., “Qwen3 Technical Report”, *arXiv e-prints*, Art. no. arXiv:2505.09388, 2025. doi:10.48550/arXiv.2505.09388.

[8] McIntosh, P. S., “The Classification of Sunspot Groups”, *Solar Physics*, vol. 125, no. 2, pp. 251–267, 1990. doi:10.1007/BF00158405.

[9] Darnel, J. M., “The GOES-R Solar UltraViolet Imager”, *Space Weather*, vol. 20, no. 4, Art. no. e2022SW003044, Wiley, 2022. doi:10.1029/2022SW00304410.1002/essoar.10510311.1.

Datos de Ciencia en YouTube

01

El canal

Datos de Ciencia es un **canal de YouTube** que hacemos con miembros del GoSA: habilidades de ciencia de datos listas para la industria, aprendidas con datos del universo.

02

Qué explicamos

Cómo programar en **Python desde cero** para **Ciencia de Datos**, **Machine Learning** e Inteligencia Artificial.

03

Quiénes lo hacemos

Miembros del **Grupo de Astrofísica Solar (GoSA)**, del Observatorio Astronómico Nacional de la **Universidad Nacional de Colombia**.

04

Dónde encontrarlo

En YouTube, como **@Datos.deCiencia**.

Videos del canal

01 Fundamentos de Python básico

Python desde cero: fundamentos para **empezar a programar**. Ya publicado.



02 NumPy vs Python básico

¿Es NumPy más lento? Compara un **bucle sobre un array** con uno sobre una lista. **Ya publicado.**



03 NumPy: tipos de datos y precisión

Tipos de datos, tiempos y **precisión**. ¿Más preciso o más rápido? Ya publicado.



04 NumPy: shape de los arrays

El **shape de los arrays** y qué representa cada dimensión. En producción.

Qué hacemos en el canal

NUMPY

NumPy (7 videos)

Arrays, formas y ejes, indexación, operaciones vectorizadas, broadcasting, datos faltantes y álgebra lineal básica.

PANDAS

Pandas (7 videos)

Series y DataFrame, selección, limpieza, agrupar, series temporales, combinar y rendimiento, con el **dataset OpenAQ** de calidad del aire.

FIGURAS

Visualización (6 videos)

Matplotlib y Seaborn: anatomía de una figura, gráficos básicos, imágenes y mapas de color, EDA, incertidumbre y figuras para comunicar.

Cada video pasa por *tres etapas*: **pseudoguion** **cuaderno** **grabación**

Plan: 20 videos de fundamentos. **NumPy 1 y 2 ya están publicados**; el siguiente, sobre el shape, está en producción.

Lo de hoy, y dónde aprenderlo en el canal

Lo que usamos hoy

- Arrays de NumPy: tensores de **(13, 704, 704)** y tokens de (45, 45, 1280).
- La normalización por canal, con constantes de forma (13, 1, 1).
- Imágenes con imshow, escalas y mapas de color.

Dónde aprenderlo en el canal

- Ya publicado: tipos de datos y precisión. En producción: el shape de los arrays.
- En el plan: broadcasting, con la normalización z por canal (C, H, W) como ejemplo trabajado.
- En el plan: imágenes y mapas de color, escalas lineal y log.

7
videos de NumPy

7
videos de Pandas

6
videos de Visualización

Pandas **(en el plan)** cubre leer tablas, seleccionar, limpiar y agrupar, lo que hace falta para trabajar con catálogos como HEK o los reportes de NOAA.

¡Suscríbete!

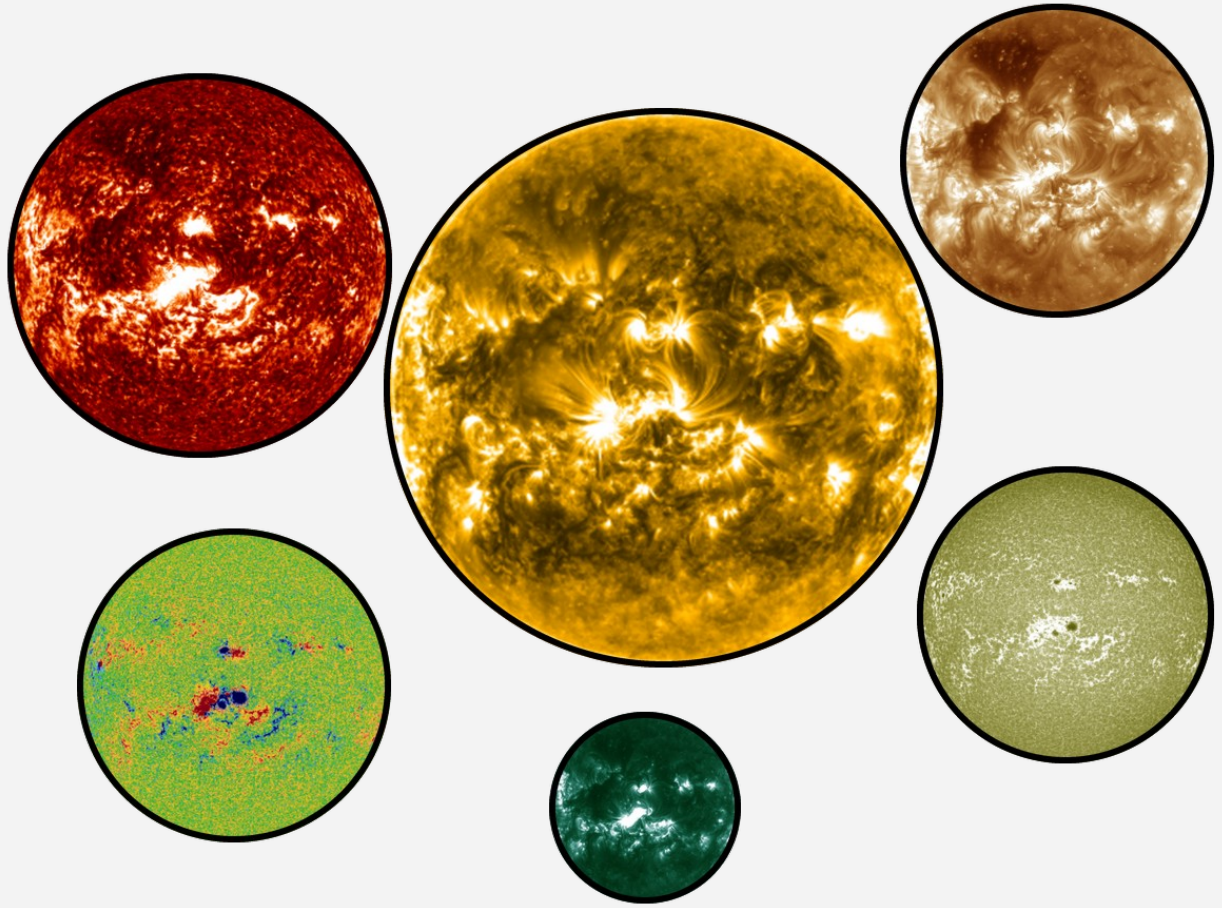


Escanea el código o busca
@Datos.deCiencia

*Python desde cero para **Ciencia de Datos, ML e IA***

¡Gracias!

¿Preguntas?



Material: repositorio de la escuela · Proyecto: ***github.com/juagudeloo***

OBSERVATORIO ASTRONÓMICO NACIONAL DE COLOMBIA

GOSA GROUP OF SOLAR ASTROPHYSICS UN - COLOMBIA