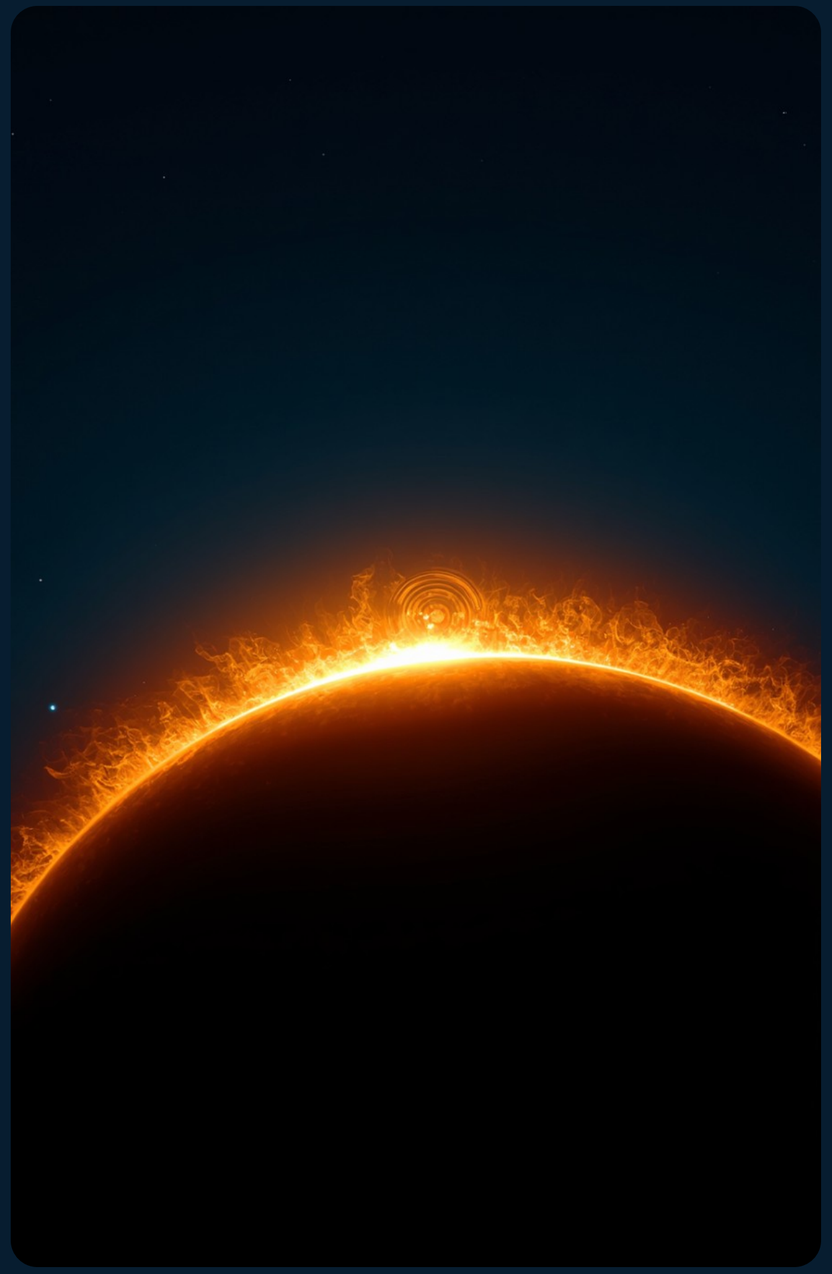
ESCUELA DE ASTROFÍSICA SOLAR · OCTUBRE 2026

HelioData Academy 2026

Machine Learning aplicado al estudio del Sol

Del dato solar al lenguaje: aplicaciones y un copiloto de física solar

Juan Esteban Agudelo Ortiz · OAN, Universidad Nacional de Colombia · 29 oct 2026



Group of Solar Astrophysics GoSA
Observatorio Astronómico Nacional · UNAL Bogotá

Agenda de la sesión

RUTA DE LA SESIÓN

01

Conceptos de ML

Supervisado y no supervisado, redes profundas y cómo se entrenan. (≈ 20 min)

02

Aplicaciones en física solar

Segmentar, enfocar, invertir y predecir; HelioML y MUISCA. (≈ 25 min)

03

Mi investigación: un copiloto

Surya, pares imagen–texto, proyector y resultados, con dos prácticas. (≈ 60 min + 15 de discusión)

SECCIÓN

01

Aprendizaje automático



¿Qué significa que un modelo aprenda de los datos?

Dos formas de aprender

Supervisado vs. no supervisado (Asensio Ramos et al. 2023, §1)

Supervisado

- Aprende de pares entrada–salida
- Regresión: flujo máximo de rayos X
- Clasificación: ¿erupción M o mayor?

No supervisado

- Solo ve observaciones, sin etiquetas
- Busca estructura: agrupar (clustering)
- Ej.: perfiles de Stokes parecidos

CONCLUSIÓN Con etiquetas confiables, supervisado; para explorar datos sin etiquetas, no supervisado.

CONCEPTO

Redes profundas

- **CNN**: leen imágenes con filtros locales
- **RNN y LSTM**: leen secuencias en el tiempo
- **Transformers**: atención entre todos los elementos
- Surya es un **transformer** espaciotemporal

IDEA CLAVE

La arquitectura se elige según la forma del dato: imagen, secuencia o conjunto de tokens.

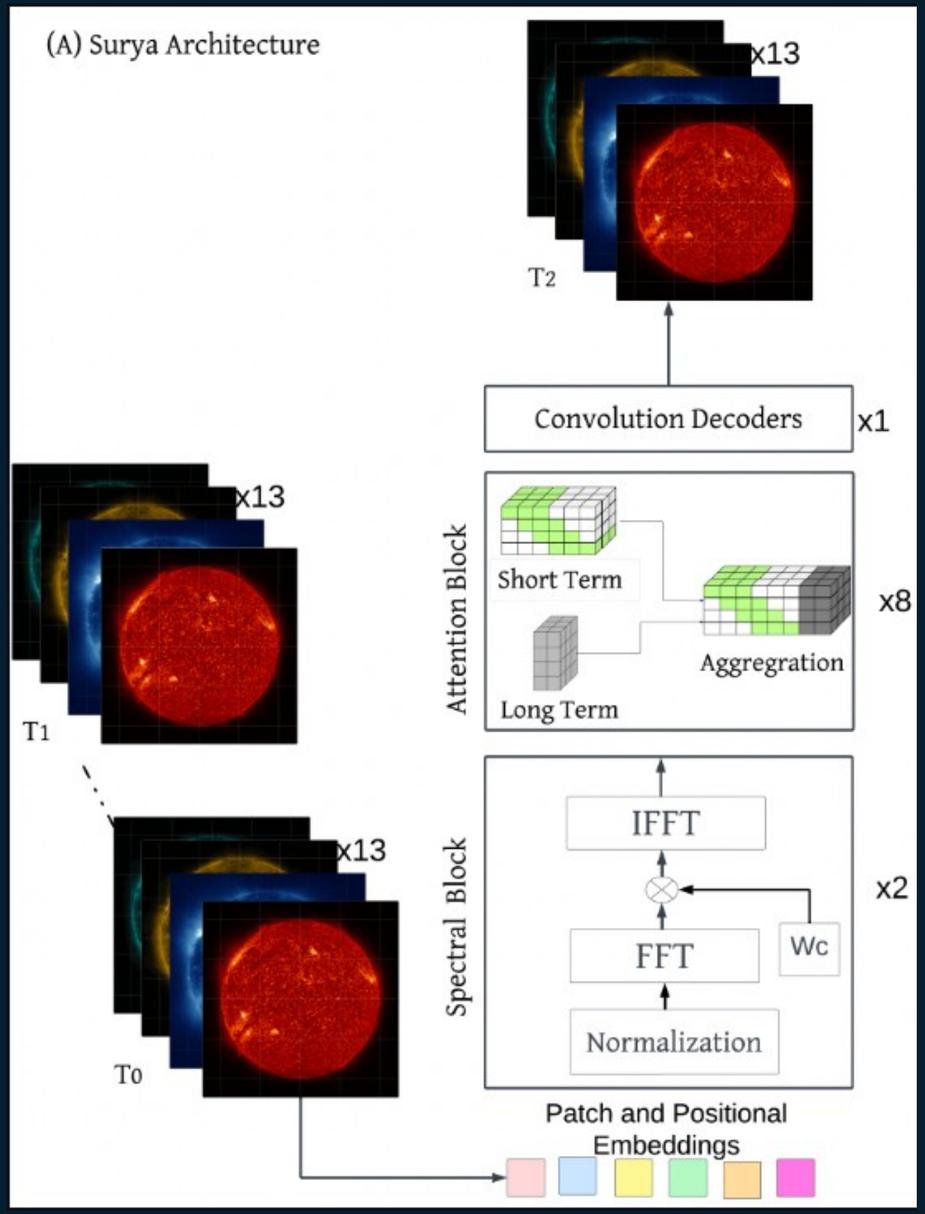


Imagen: arquitectura de Surya, Roy et al. (2025)

$$\mathcal{L} = -\sum_i [\, y_i \log \hat{y}_i + (1 - y_i) \log(1 - \hat{y}_i) \,]$$

Entropía cruzada binaria

y es la etiqueta de cada píxel (1 si es agujero coronal) y ŷ la probabilidad que predice la red. El descenso del gradiente, con retropropagación, ajusta los pesos para reducir L.

Referencia: Asensio Ramos et al. (2023), ec. 51

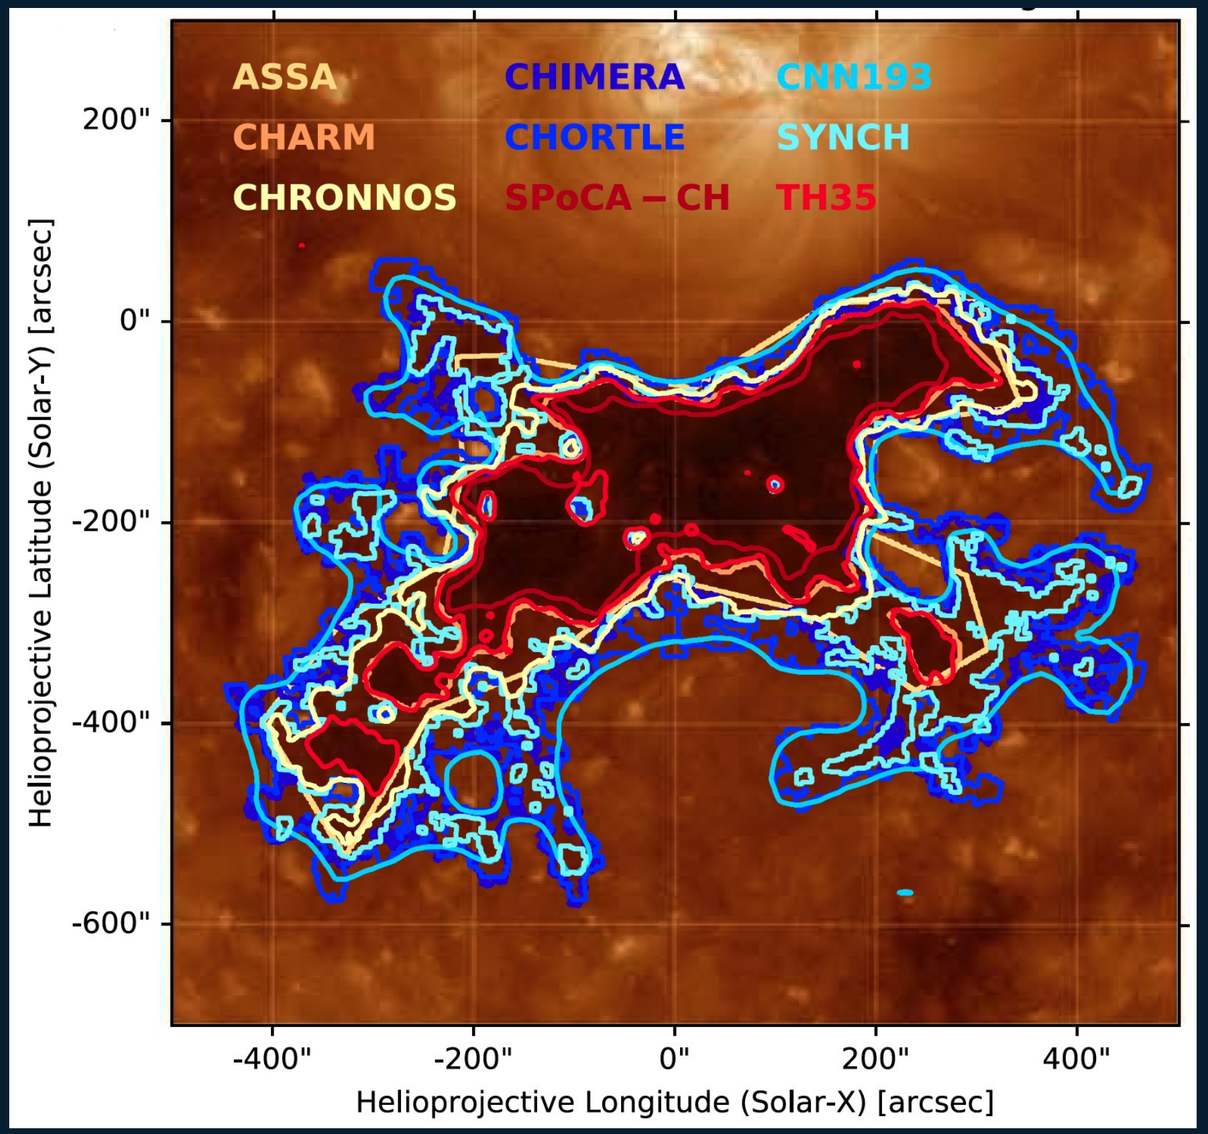


Imagen: un agujero coronal en AIA 193 Å segmentado por nueve métodos. Asensio Ramos et al. (2023), fig. 8, de Reiss et al. (2021), ApJ 913, 28

SECCIÓN

02

Aplicaciones en física solar



¿Qué se ha hecho ya con ML en datos solares?

Aplicaciones en cifras

ASENSIO RAMOS ET AL. (2023), SECCIÓN 7

01

2385 mapas

para entrenar una U-Net que marca agujeros coronales en AIA 193 Å

02

0,5″ → 0,25″

píxel de HMI tras Enhance, una CNN de superresolución

03

≈ 200 ms

SICON invierte un mapa de 512 × 512 de Hinode en una GPU

04

≈ 47 %

más regiones del lado lejano con FarNet, a iguales falsos positivos

APLICACIÓN

Predecir el clima espacial

- **Erupciones**: clasificación (¿M o mayor en horas o días?) o regresión del flujo
- **CNN** sobre magnetogramas de MDI y HMI (Huang et al., 2018)
- **LSTM** con 25 parámetros SHARP y la historia de erupciones (Liu et al., 2019)
- **CME**: SVM de Bobra e Ilonidis (2016), capítulo 1 de HelioML

IDEA CLAVE

Las erupciones grandes son raras: hay que comparar contra líneas base.

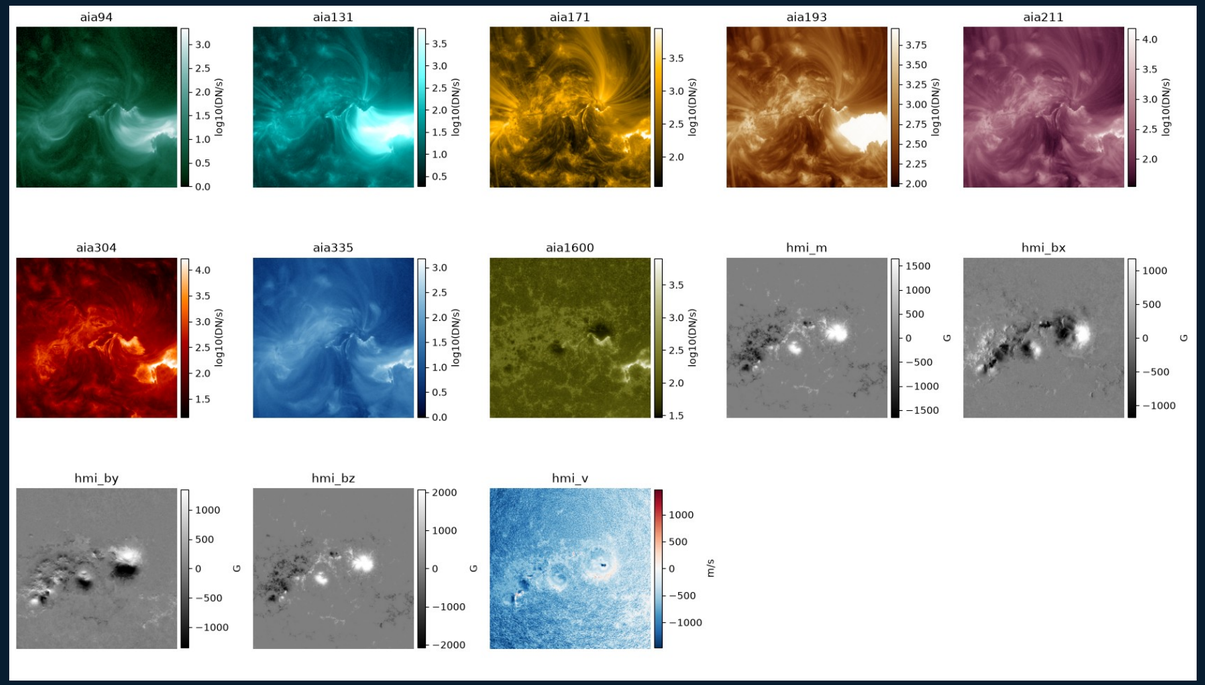


Imagen: AR 11944 durante la erupción X1.2 del 7 ene 2014 (SDO, formato Surya)

RECURSO

9 cuadernos

HelioML: un libro de cuadernos de Jupyter

Reproducen resultados publicados: CME con SVM, Enhance, DeepEM (≈ 10^7 soluciones DEM por segundo), FarNet, viento solar sin etiquetas (UMAP, HDBSCAN) y más.

Referencia: Bobra y Mason, HelioML v0.4.0, helioml.org

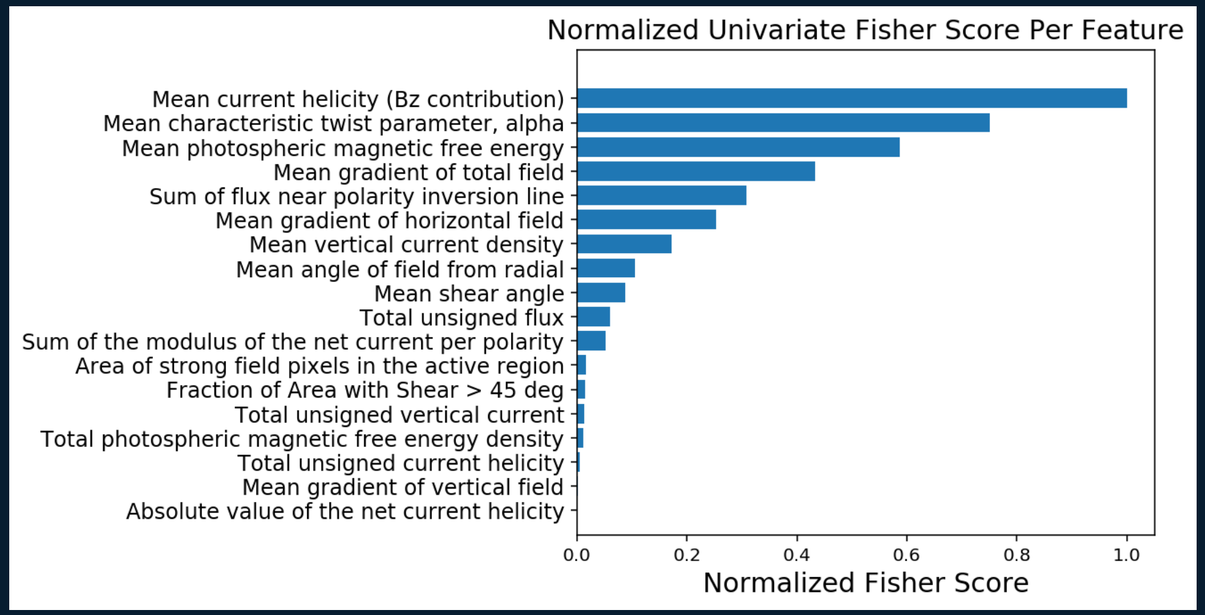


Imagen: puntaje de Fisher de cada parámetro SHARP para predecir CME. HelioML, cap. 1 (Bobra y Mason), según Bobra e Ilonidis (2016)

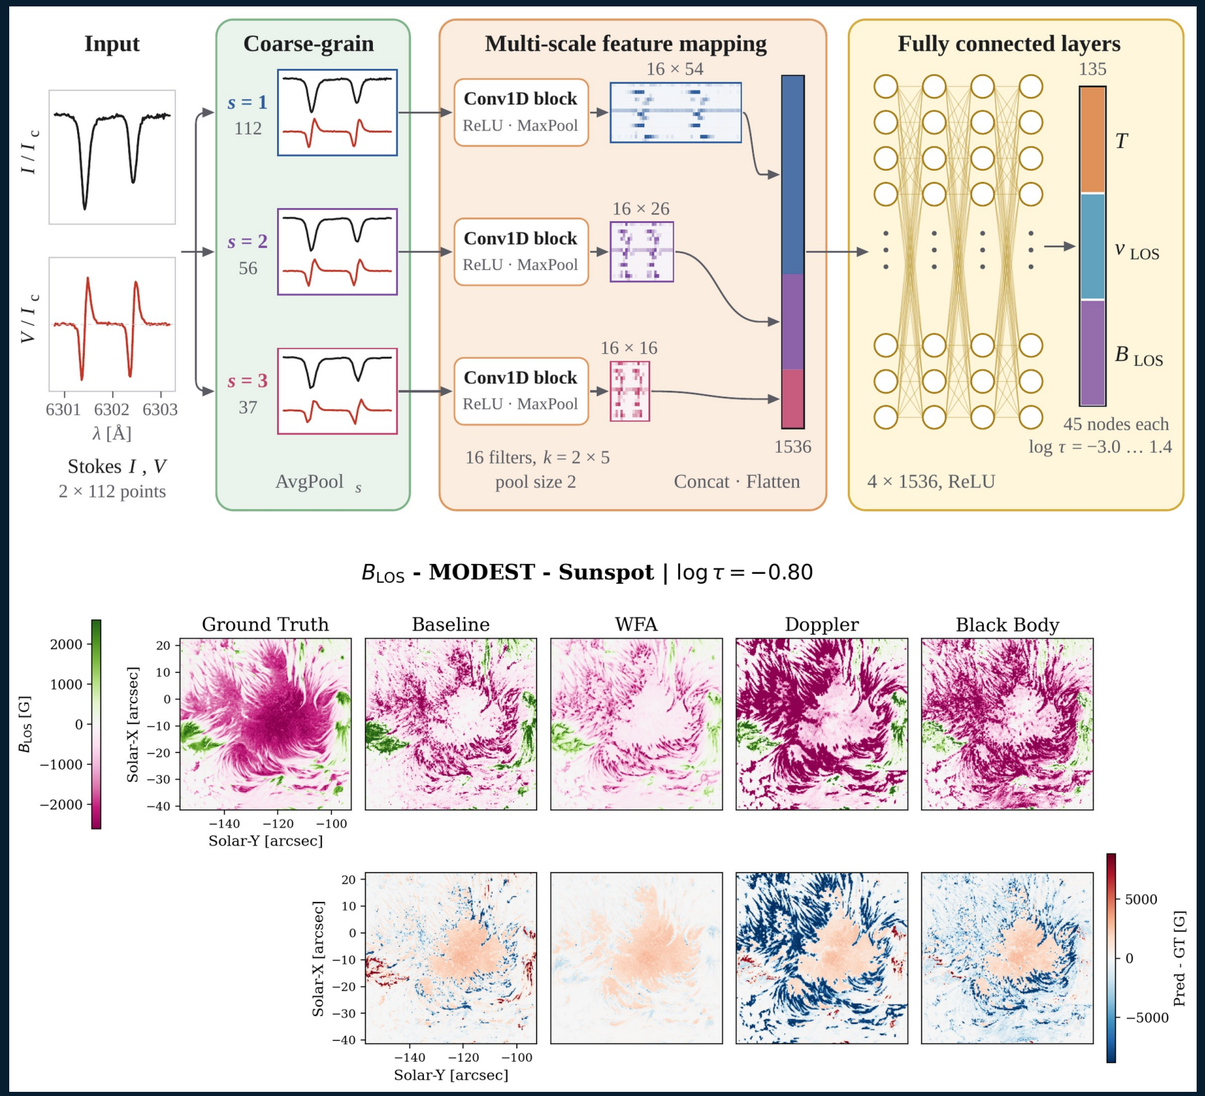
EN PREPARACIÓN

MUISCA: inversión de Stokes con física

- Invierte **Stokes I y V** en T, v_LOS y B_LOS en **45 nodos** de profundidad óptica
- CNN multiescala entrenada con perfiles de **NICOLE** sobre simulaciones **MURaM**
- Pérdida con términos físicos: **WFA**, Doppler y cuerpo negro
- 480 × 480 px en una GPU, 10^3–10^4 veces más rápido que sintetizar con NICOLE

IDEA CLAVE

En preparación: el término WFA generaliza mejor, pero aún no iguala a los códigos numéricos.



Arquitectura y B_LOS en una mancha (Hinode/MODEST, log τ = −0,8). Agudelo Ortiz, Morales, Vargas Domínguez, Castellanos Durán y Shelyag, en prep.

Por tarea vs. modelo base



Del modelo especializado al modelo fundacional

Un modelo por tarea

- Una red para una sola tarea
- Sus propias etiquetas e instrumento
- U-Net, Enhance, FarNet, MUISCA

Modelo base (Surya)

- Preentrenado con 13 canales de SDO
- Se adapta con poco ajuste (LoRA)
- Erupciones, viento solar, EUV…

CONCLUSIÓN Nuestra pregunta: ¿se pueden traducir los embeddings de Surya al lenguaje?

SECCIÓN

03

Mi investigación: un copiloto



¿Puede un modelo describir con palabras lo que ve Surya?

MOTIVACIÓN

El copiloto de física solar

- Meta: “muéstrame esta región activa y estima la probabilidad de una erupción M en 24 h”
- Un LLM orquesta los datos, ejecuta Surya y explica
- Ruta: **VLM** → preguntas → herramientas → agente
- Hoy, el primer paso: **describir** una observación de SDO

IDEA CLAVE

Antes de razonar sobre lo que ve Surya, sus embeddings deben traducirse al espacio del LLM.

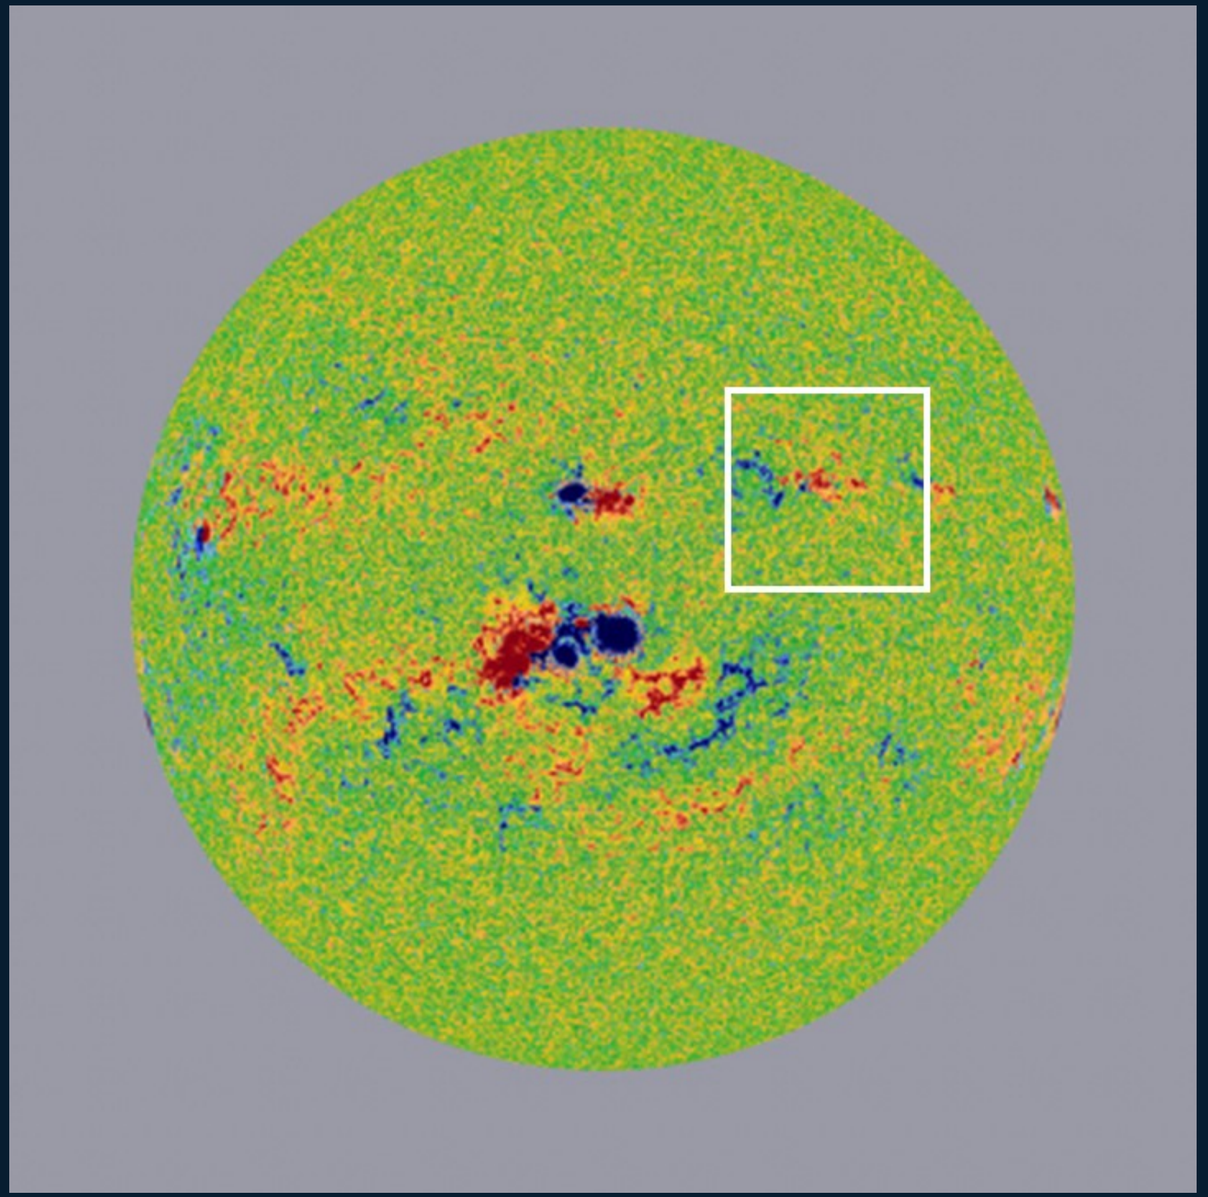


Imagen: magnetograma de HMI del 7 ene 2014 y la caja de una región activa

Surya en cifras

ROY ET AL. (2025)

01

366 M

parámetros: transformer espaciotemporal

02

13 canales

8 de AIA y 5 de HMI

03

4096²

píxeles: la resolución nativa de SDO

04

+60 min

preentrenado para pronosticar el Sol una hora adelante

ECUACIÓN / DATO DESTACADO

$$x' = \frac{s\left(0{,}01\,x\right) - \mu}{\sigma + \varepsilon}$$

$$s(x) = \operatorname{sign}(x)\log(1 + |x|)$$

Normalización de Surya

Escala, logaritmo con signo y estandarización con μ y σ globales de cada canal. Por eso una imagen no queda con media 0: aia94 va de −0,53 a 219,6.

Referencia: surya.datasets.helio.transform; cuaderno, sección 2

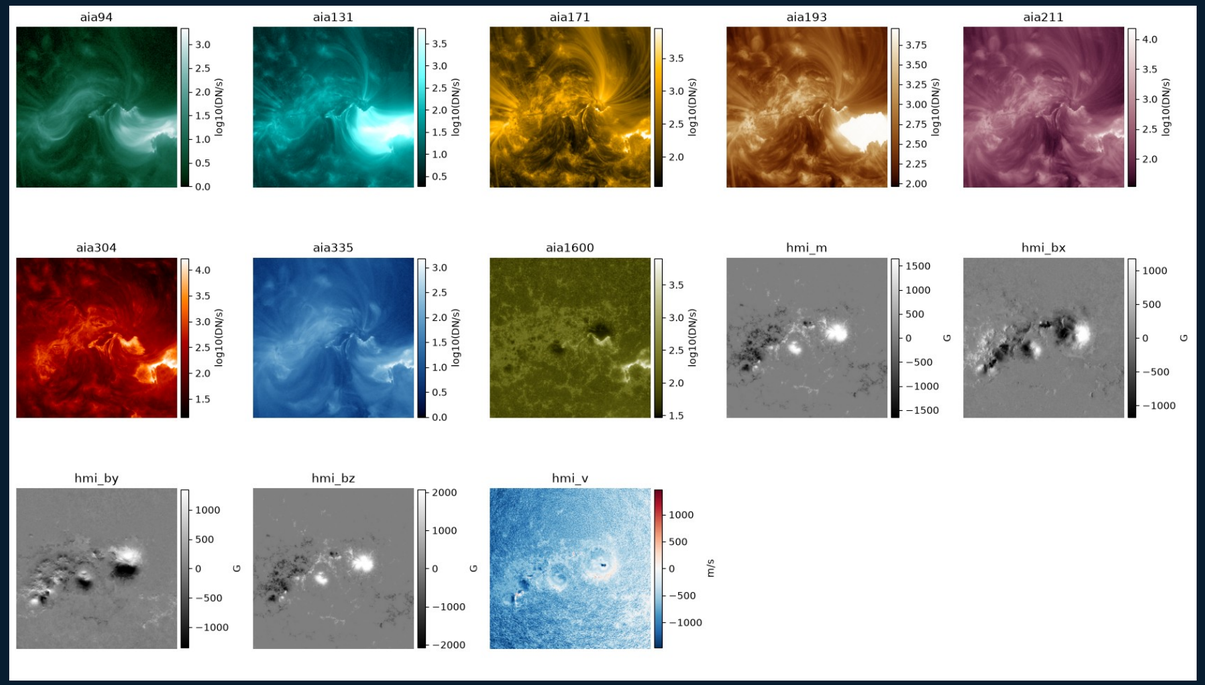


Imagen: los 13 canales del recorte de la AR 11944, con sus unidades (DN/s, G, m/s)

CÓDIGO · PRÁCTICA

Práctica 1: del dato a los tokens

1. Corre las secciones 1 a 5 del cuaderno
2. Cambia nombre a otro canal y compara los pasos
3. Mira por qué la media no queda en 0

OBJETIVO

Entender la normalización de Surya y sus constantes globales.

01_Del_dato_solar_al_caption.ipynb

```
1  nombre = "aia94"
2  k = constantes[nombre]
3  x = crudo[canales.index(nombre)].astype(np.float64)
4
5  paso1 = x * k["sl_scale_factor"]
6  paso2 = np.sign(paso1) * np.log1p(np.abs(paso1))
7  paso3 = (paso2 - k["mean"]) / (k["std"] + k["epsilon"])
8
9
10
11
```

SALIDA › paso 3: mín −0,526 · máx 219,601 · media 9,203

CONCEPTO

De la región a 256 tokens

- Recorte de **704 × 704 px** alrededor de la AR 11944
- Un token por parche de **16 × 16 px**: **45 × 45** tokens de 1280 dimensiones
- **Pooling adaptativo** a 16 × 16 = **256 tokens**
- Surya corre sobre el **disco completo**: se recortan tokens, no la imagen

IDEA CLAVE

Recortar la imagen quitaría el contexto de posición y escala que Surya aprendió.

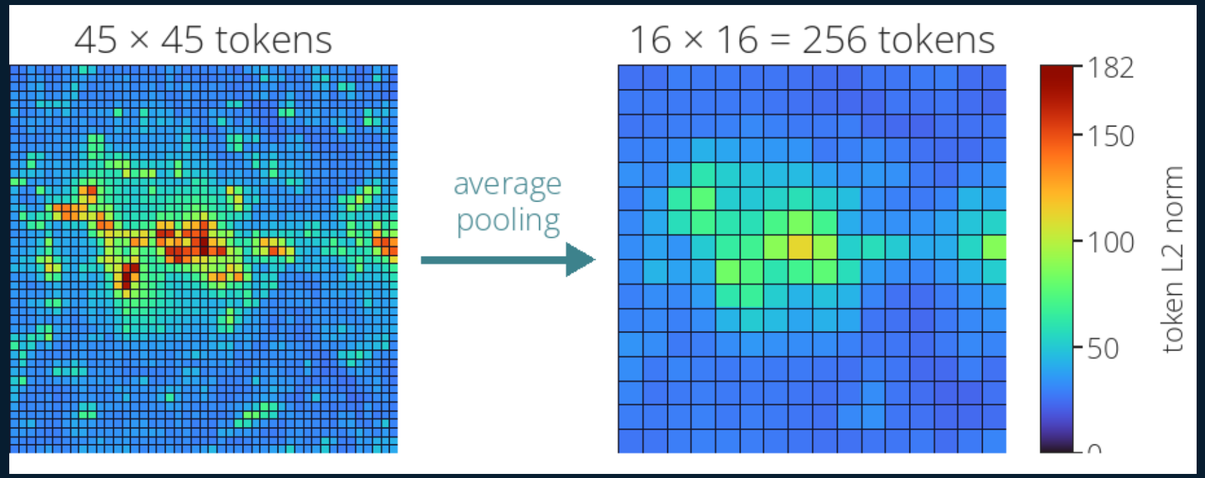


Imagen: norma L2 de los tokens antes y después del pooling

Dos fuentes de texto

Para entrenar hacen falta pares observación–descripción

Artículos

- Figuras y textos de la literatura
- Hay que re-consultar la observación
- Pocos pares y metadatos ruidosos

Catálogo (HEK, NOAA)

- Posición, manchas y clases
- Captions con plantilla fija, sin LLM
- Muchos pares, texto repetitivo

CONCLUSIÓN El prototipo usa el catálogo; los artículos llegan cuando el pipeline madure.

ARQUITECTURA

Surya + proyector + LLM

- **Surya** congelado: 256 tokens de 1280 dimensiones
- **Proyector MLP** 1280 → 4096 → GELU → 4096: **22 M** parámetros
- **Qwen3-8B** congelado lee los tokens visuales y escribe el caption
- La receta de LLaVA (Liu et al., 2023)

IDEA CLAVE

Solo se entrena el proyector: 22 M de parámetros frente a 366 M de Surya.

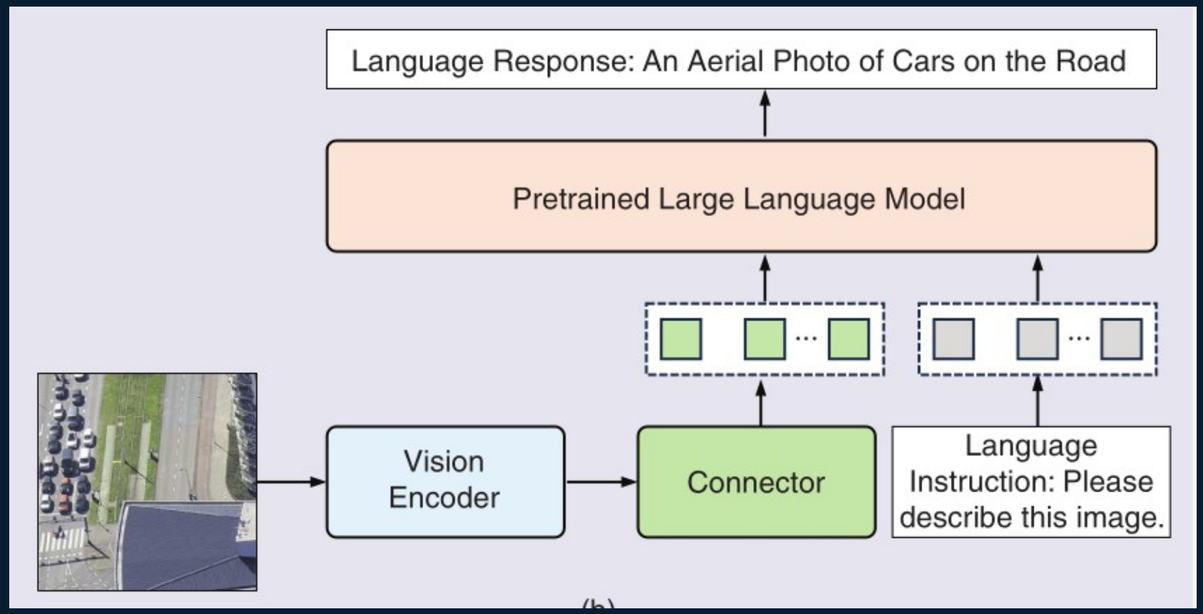


Imagen: esquema de un VLM de teledetección, Weng et al. (2025)

286 posiciones

La secuencia que lee el LLM

Instrucción, 256 tokens visuales (posiciones 4 a 259) y el caption. La pérdida solo cuenta el caption y su marca de fin (275 a 284), no la pregunta ni la imagen.

Referencia: cuaderno, sección 7

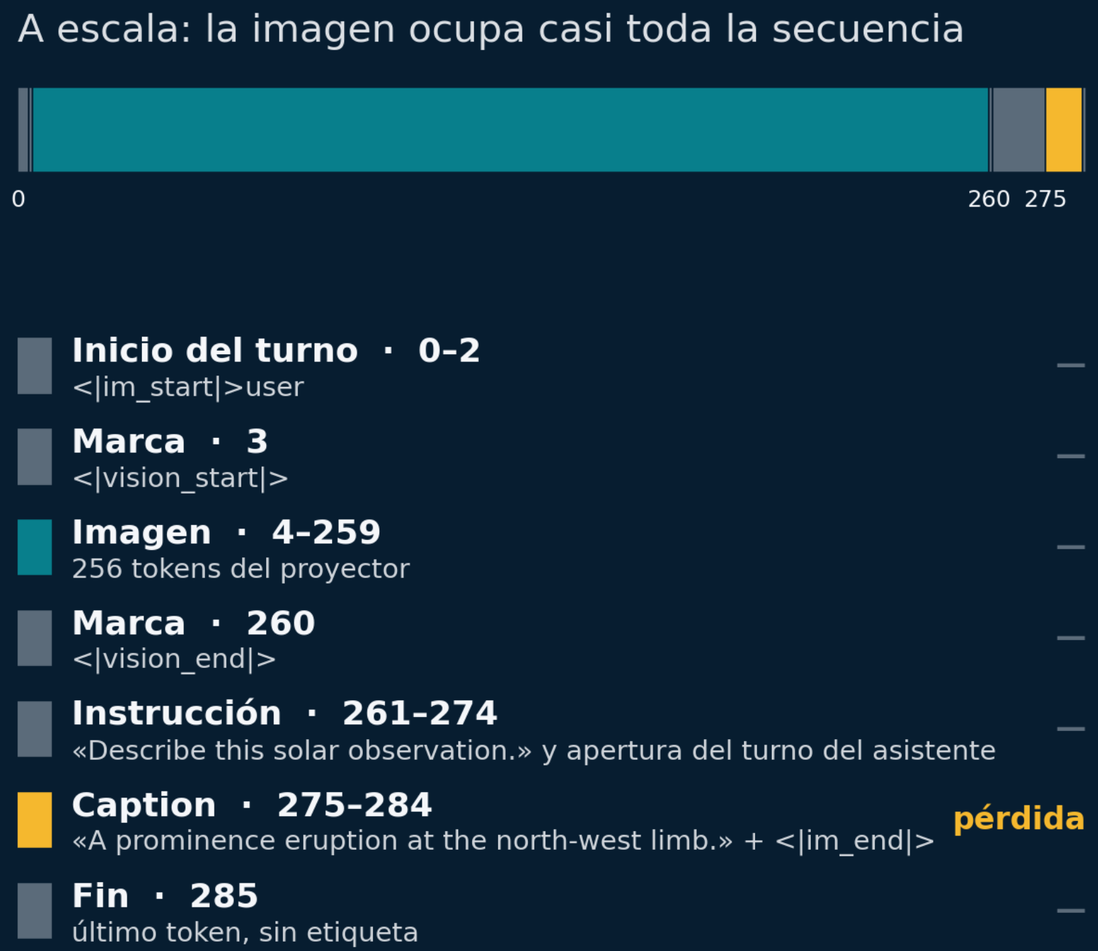


Imagen: elaboración propia a partir de 03_Datos/secuencia_ejemplo.json

CÓDIGO · PRÁCTICA

Práctica 2: el proyector

1. Corre las secciones 6 y 7 del cuaderno
2. Cuenta los parámetros del proyector
3. Mira qué posiciones entran en la pérdida

OBJETIVO

Ver cómo los 256 tokens de Surya se vuelven vectores que el LLM puede leer.

01_Del_dato_solar_al_caption.ipynb

```
1  def gelu(x):
2      return 0.5 * x * (1.0 + erf(x / np.sqrt(2.0)))
3
4  class Proyector:
5      def __call__(self, x):
6          return gelu(x @ self.w1 + self.b1) @ self.w2 + self.b2
7
8  proyector = Proyector()
9  visuales = proyector(agrupados.reshape(256, 1280))
10
11
```

SALIDA › (256, 4096) · 22.028.288 parámetros entrenables

Resultados del prototipo

PRUEBA DE QUE EL FLUJO ENTRENA, NO UN RESULTADO CIENTÍFICO

01

0,557

mejor pérdida en las regiones apartadas (época 15)

02

+0,18

cuánto sube la pérdida si se cambia la imagen

03

17 / 19

hemisferio correcto en días nuevos (línea base: 7)

04

29 / 55

captions que dicen «sur»; solo 12 regiones lo son

RESULTADOS

Lo que funciona y lo que no

- La pérdida baja y **la imagen importa**: la brecha es positiva
- En las 2 regiones del 7 ene, **«siempre norte»** gana (36/36 frente a 21/36)
- No aprendió a **contar manchas** (6 de 19 en días nuevos)
- Datos de pocos días y captions de plantilla: aún no hay generalización

IDEA CLAVE

Un porcentaje global engaña: hay que comparar contra líneas base y desglosar por clase.

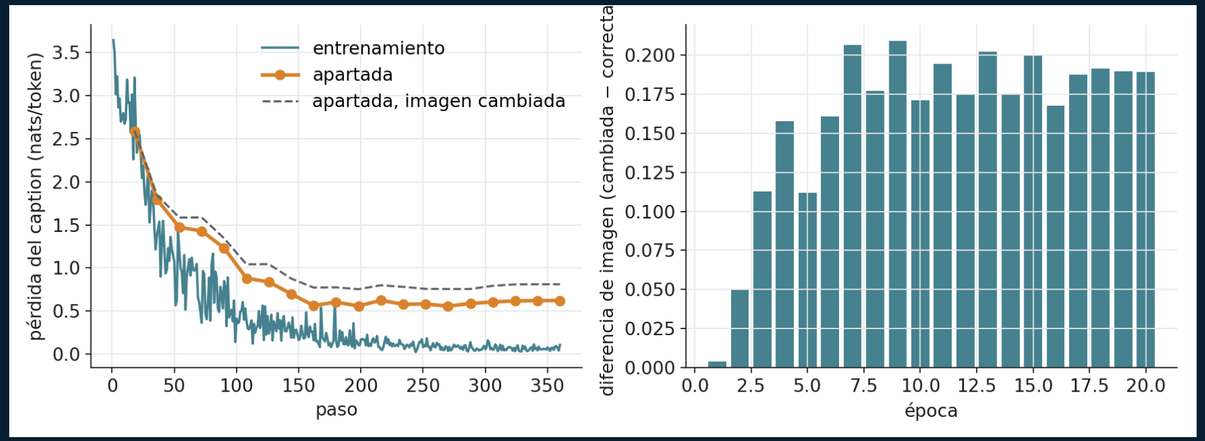


Imagen: curvas de pérdida del prototipo (corrida 2, 9 oct 2026)

MÁS ALLÁ DE SDO

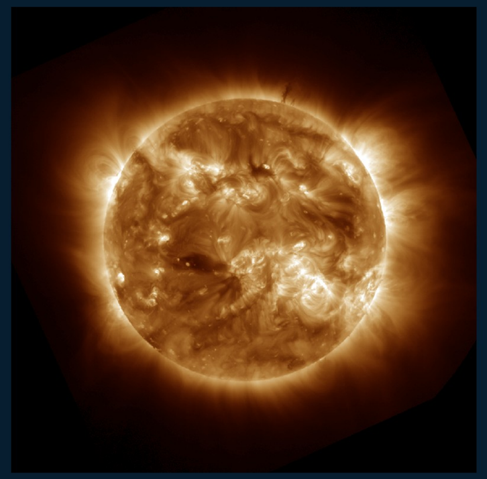
¿Ve Surya a través de GOES-SUVI?

- SUVI es un instrumento **operativo** de GOES-R: daría datos en vivo
- Solo **6 de los 13** canales de Surya tienen equivalente en SUVI
- SUVI: 1280² px a 2,5″/px; AIA: 4096² a 0,6″/px
- Hay cuadros de SUVI con ruido anómalo: falta un filtro de calidad

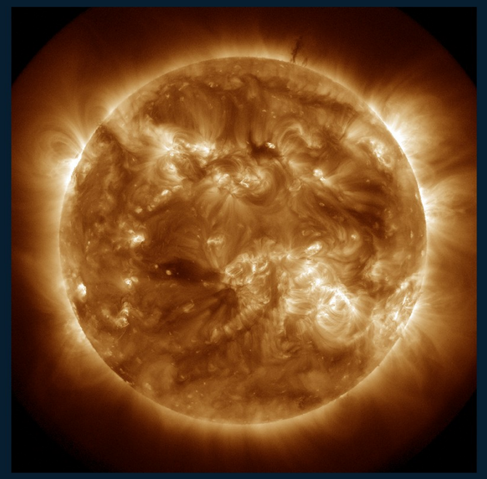
IDEA CLAVE

Si Surya transfiere, el copiloto podría trabajar con datos en vivo además de SDO.

15 mar 2023



GOES-18 SUVI 195 Å
1280² px · 2,50″/px · 09:56 UT



SDO AIA 193 Å
4096² px · 0,60″/px · 09:56 UT

Imagen: elaboración propia. SUVI 195 Å (GOES-18, NOAA) y AIA 193 Å (SDO, NASA), 15 mar 2023, 09:56 UT

Conclusiones

LO QUE NOS LLEVAMOS HOY

1. El ML ya resuelve tareas solares: segmentar, enfocar, invertir y predecir
2. Los modelos base como Surya pasan de una tarea a muchas
3. Un proyector pequeño conecta Surya con un LLM; faltan mejores datos



PARA SEGUIR › HelioML (helioml.org) y Asensio Ramos et al. (2023)

Referencias

LECTURAS

Asensio Ramos, Cheung, Chifu y Gafeira (2023). Machine learning in solar physics. Living Rev. Sol. Phys. 20, 1

Bobra y Mason. HelioML, v0.4.0 (helioml.org)

Roy et al. (2025). Surya: Foundation Model for Heliophysics. arXiv:2508.14112

Liu et al. (2023). Visual Instruction Tuning (LLaVA). arXiv:2304.08485

Díaz Baso y Asensio Ramos (2018). Enhance. A&A 614, A5

Bobra e Ilonidis (2016). Predicting CMEs. ApJ 821, 127



MÁS LECTURAS › 04_Lecturas en el repositorio de la escuela

DATOS DE CIENCIA

Datos de Ciencia en YouTube

- Python desde cero para **Ciencia de Datos, ML e IA**
- NumPy con datos reales de **TESS**: el tránsito de WASP-18 b
- **Juan Esteban Agudelo Ortiz** (líder y guion); Thomas Gonzales, Milena Barrios y Claudia Cuellar (presentación); Santiago Pinilla y Daniel Rodríguez (edición)
- En colaboración con miembros del GoSA del OAN

IDEA CLAVE

Lo de hoy (arrays, normalización, imshow) está en la serie de NumPy.



1 · Python desde cero



2 · NumPy vs Python básico



3 · Tipos de datos y precisión

En producción

4 · Shape de los arrays

Videos de @Datos.deCiencia: 1 a 3 publicados; 4 en producción

@Datos.deCiencia



¡Suscríbete!

Escanea el código o busca el canal en YouTube. Los cuadernos de la serie de NumPy están en github.com/Datos-De-Ciencia.

youtube.com/@Datos.deCiencia

Logo del canal y código QR al canal



¡Gracias!

¿Preguntas?

Juan Esteban Agudelo Ortiz
juagudeloo@unal.edu.co

Registro
tiny.cc/escuelasolar

Más información
astronomiaoan.co/gosa/escuela.html

Organiza: Group of Solar Astrophysics GoSA
Observatorio Astronómico Nacional · UNAL Bogotá