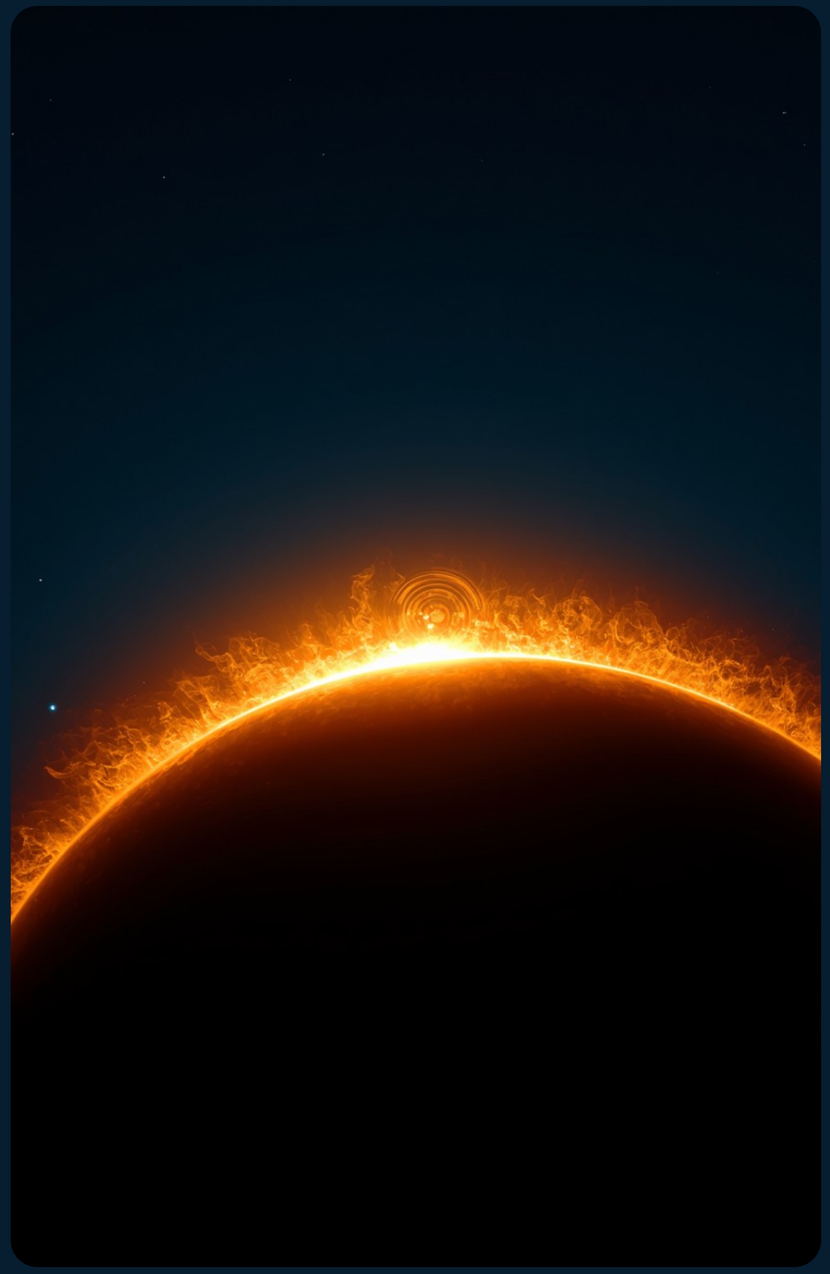
ESCUELA DE ASTROFÍSICA SOLAR · OCTUBRE 2026

# HelioData Academy 2026

## Machine Learning aplicado al estudio del Sol

Del dato solar al lenguaje: aplicaciones y un copiloto de física solar

Juan Esteban Agudelo Ortiz · OAN, Universidad Nacional de Colombia ·
29 oct 2026



Group of Solar Astrophysics GoSA
Observatorio Astronómico Nacional · UNAL Bogotá

# Agenda de la sesión

RUTA DE LA SESIÓN

## 01

### Conceptos de ML

Supervised y unsupervised, deep learning, y cómo se entrena y se evalúa un modelo. (≈ 20 min)

## 02

### Aplicaciones en física solar

Segmentation, super-resolution, inversión y forecasting; HelioML y MUISCA. (≈ 25 min)

## 03

### Mi investigación: un copiloto

Surya, pares imagen–texto, projector y resultados, con dos prácticas. (≈ 60 min + 15 de discusión)

SECCIÓN

# 01

# Machine Learning

¿Qué significa que un modelo aprenda de los datos?



# Dos formas de aprender

**Supervised vs. unsupervised learning**

## Supervised

- Aprende de pares input–output
- Regresión: flujo máximo de rayos X
- Clasificación: ¿flare M o mayor?

## Unsupervised

- Solo ve observaciones, sin labels
- Busca estructura: clustering
- Ej.: perfiles de Stokes parecidos

Referencias: Asensio Ramos, Cheung, Chifu y Gafeira (2023), Living Rev. Sol. Phys. 20, 4, sección 1.

CONCEPTO

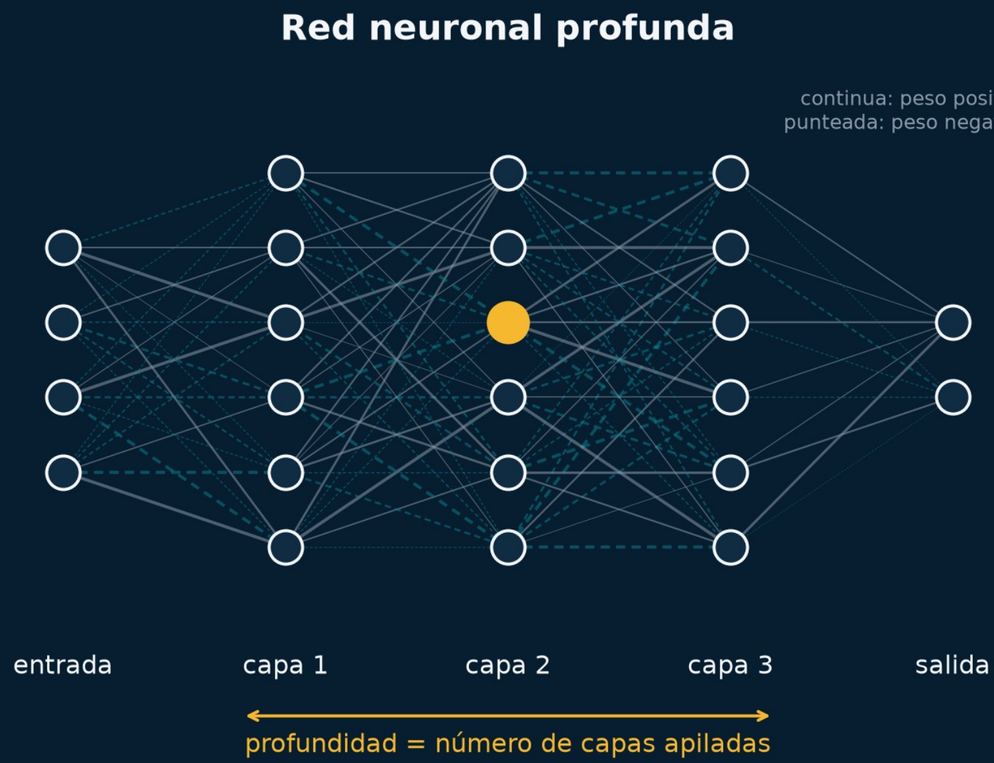
# Deep learning

- **CNN**: leen imágenes con filtros locales
- **RNN y LSTM**: leen secuencias en el tiempo
- **Transformers**: atención entre todos los elementos

**IDEA CLAVE**

La arquitectura se elige según la forma del dato: imagen, secuencia o conjunto de tokens.

Referencias: Asensio Ramos, Cheung, Chifu y Gafeira (2023), Living Rev. Sol. Phys. 20, 4, sección 5.1.




**Una neurona (en dorado):**

$$y = f\left(\sum_j w_j\, x_j + b\right)$$

$$y = f^{(L)}\left(\cdots f^{(2)}\left(f^{(1)}(x)\right)\right)$$

w, b: pesos que se aprenden · f: activación no lineal (ReLU, GELU…)

Imagen: elaboración propia. Definición según Asensio Ramos et al. (2023), sección 5

CONCEPTO

# Entrenar y evaluar

- La **loss** mide qué tan lejos está la predicción del label
- Entrenar es bajar la loss con **gradient descent**; backpropagation dice cómo mover cada peso
- Se evalúa en datos **held-out**, que el modelo nunca vio al entrenar
- Siempre contra un **baseline** tonto, p. ej. «nunca hay flare»

**IDEA CLAVE**

Un modelo es bueno solo si supera a un baseline en datos que no vio.

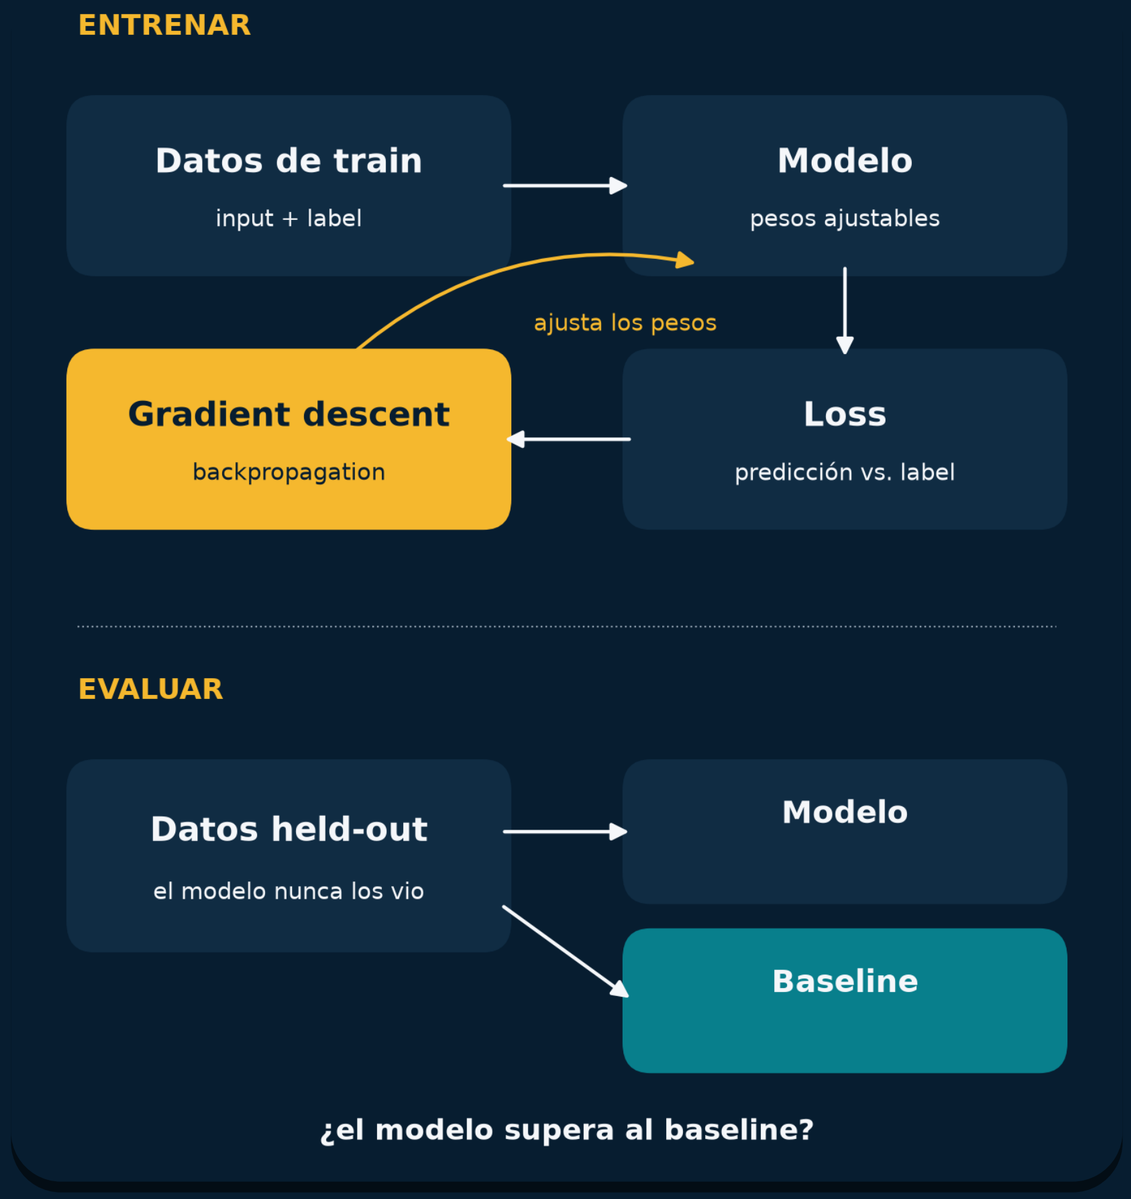



Imagen: elaboración propia (esquema)

SECCIÓN

# 02

# Aplicaciones en física solar



¿Qué se ha hecho ya con ML en datos solares?

# Aplicaciones del ML

## Lo que se ha hecho con ML en datos solares

### Entender el Sol

- Segmentation: agujeros coronales, manchas
- Classification de imágenes
- Inversión de Stokes, y su incertidumbre
- Reconstrucción 3D de la corona
- Deconvolution de imágenes
- Estimación de velocidades

### Predecir y mejorar datos

- Forecasting de flares y de CME
- Heliosfera y space weather
- Predicción del ciclo solar
- Super-resolution
- Denoising y desaturación
- Far-side imaging
- Generación de datos sintéticos

Referencias: Asensio Ramos, Cheung, Chifu y Gafeira (2023), Living Rev. Sol. Phys. 20, 4, sección 7.

APLICACIÓN

# Detectar agujeros coronales

- Zonas oscuras en EUV y fuente principal del **viento solar**
- **U-Net** sobre AIA 193 Å: dice si cada píxel es agujero o no; **2385 mapas** de entrenamiento (Illarionov y Tlatov, 2018)
- Se entrena con la **binary cross-entropy**, píxel a píxel
- **CHRONNOS**: 7 canales EUV de AIA + magnetograma de HMI (Jarolim et al., 2021)

**IDEA CLAVE**

Nueve métodos dibujan bordes distintos para el mismo agujero: falta estimar la incertidumbre.

Referencias: Illarionov y Tlatov (2018), MNRAS 481, 5014 · Jarolim et al. (2021), A&A 652, A13 · Reiss et al. (2021), ApJ 913, 28 · Asensio Ramos, Cheung, Chifu y Gafeira (2023), Living Rev. Sol. Phys. 20, 4, sección 7.1.



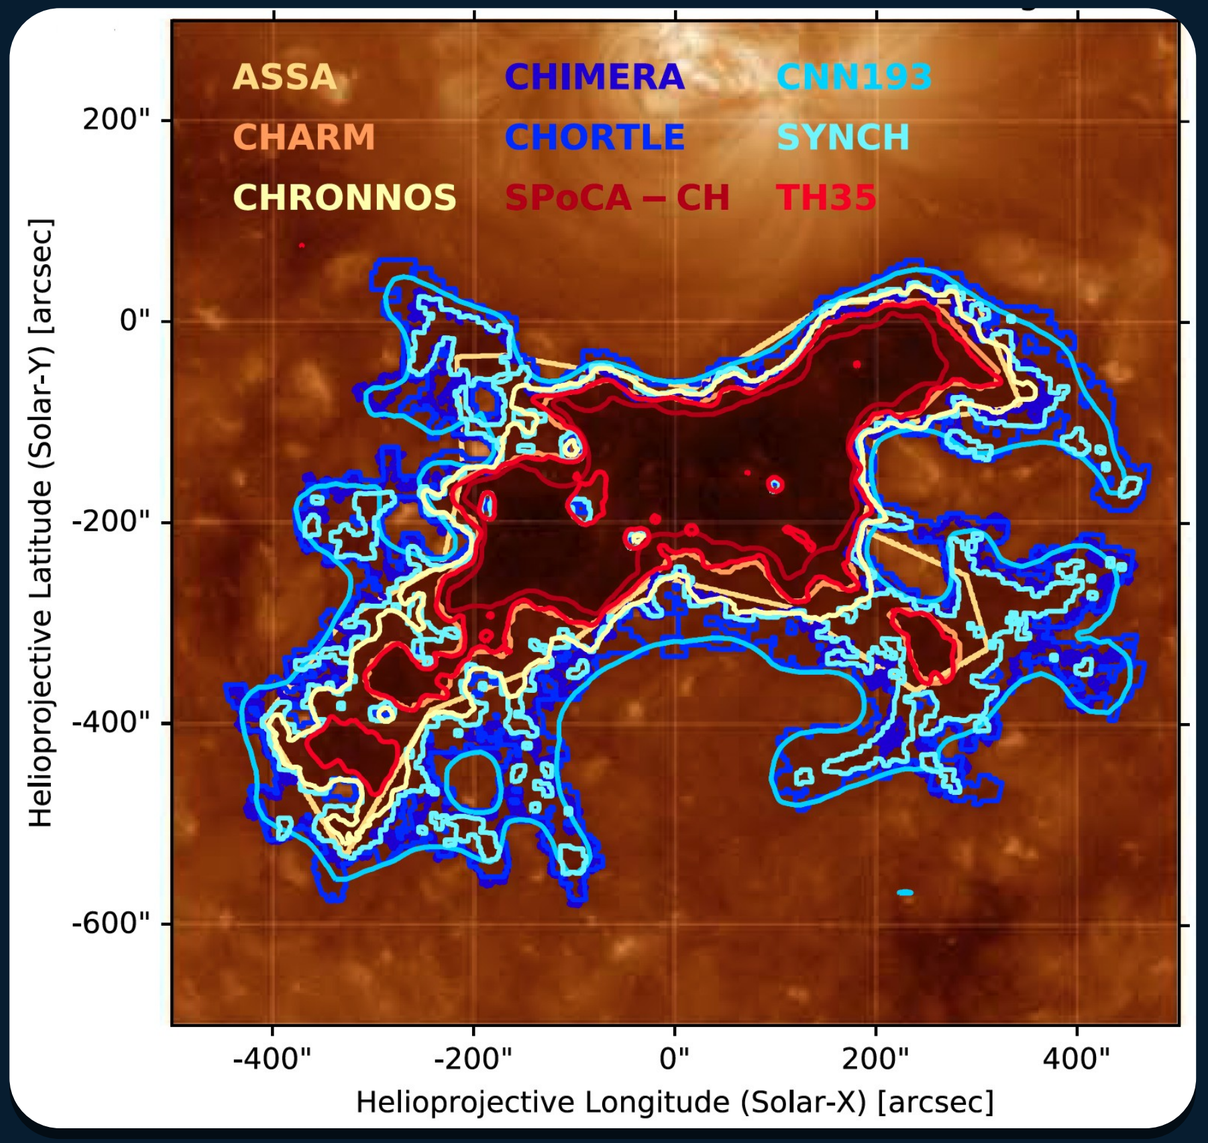



Imagen: un agujero coronal en AIA 193 Å segmentado por nueve métodos. Asensio Ramos et al. (2023), fig. 8, de Reiss et al. (2021), ApJ 913, 28

APLICACIÓN

# Predecir el clima espacial

- **Flares**: clasificación (¿M o mayor en horas o días?) o regresión del flujo
- **CNN** sobre magnetogramas de MDI y HMI (Huang et al., 2018)
- **LSTM** con 25 parámetros SHARP y la historia de flares (Liu et al., 2019)
- **CME**: SVM de Bobra e Ilonidis (2016), capítulo 1 de HelioML

**IDEA CLAVE**

Los flares grandes son raros: hay que comparar contra baselines.

Referencias: Huang et al. (2018), ApJ 856, 7 · Liu et al. (2019), ApJ 877, 121 · Bobra e Ilonidis (2016), ApJ 821, 127 · Asensio Ramos, Cheung, Chifu y Gafeira (2023), Living Rev. Sol. Phys. 20, 4, sección 7.3.



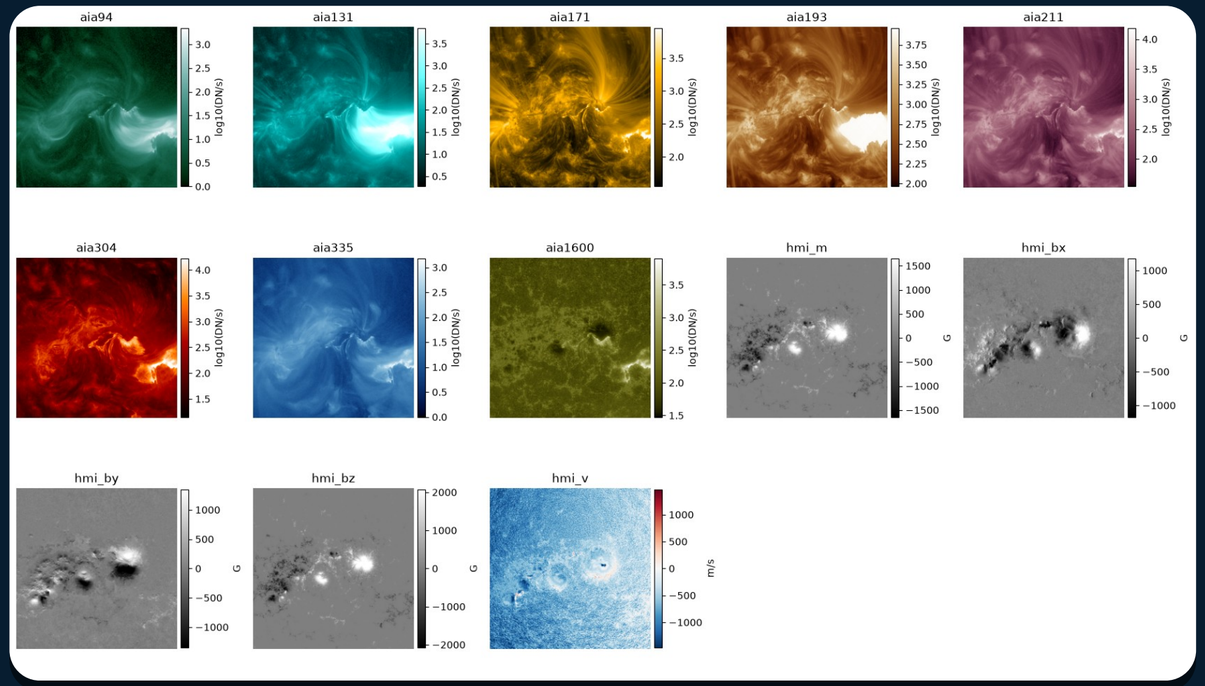



Imagen: AR 11944 durante el flare X1.2 del 7 ene 2014 (SDO, formato Surya)

RECURSO

# 9 notebooks

## HelioML: un libro de notebooks de Jupyter

Reproducen resultados publicados: CME con SVM, Enhance, DeepEM (≈ $10^7$ soluciones DEM por segundo), FarNet, viento solar sin labels (UMAP, HDBSCAN) y más.

**Explora HelioML**
helioml.org

Referencias: Bobra y Mason (2018), HelioML, doi:10.5281/zenodo.1412824 · Bobra e Ilonidis (2016), ApJ 821, 127 · Díaz Baso y Asensio Ramos (2018), A&A 614, A5 · Felipe y Asensio Ramos (2019), A&A 632, A82.



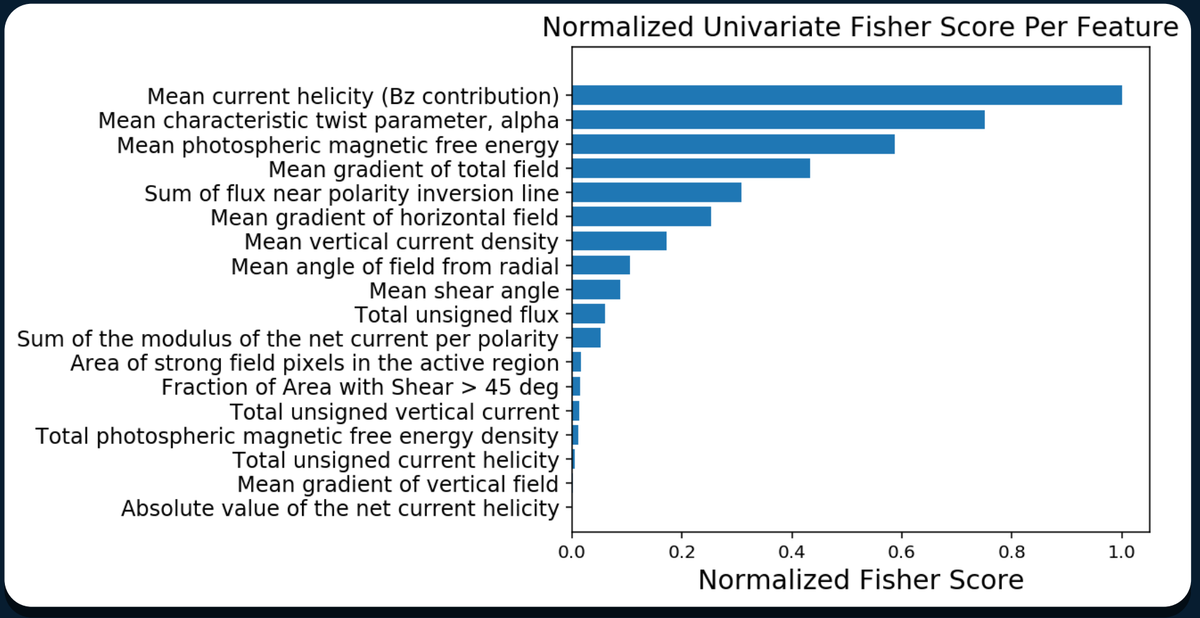



Imagen: Fisher score de cada parámetro SHARP para predecir CME. HelioML, cap. 1 (Bobra y Mason), según Bobra e Ilonidis (2016)

EN PREPARACIÓN

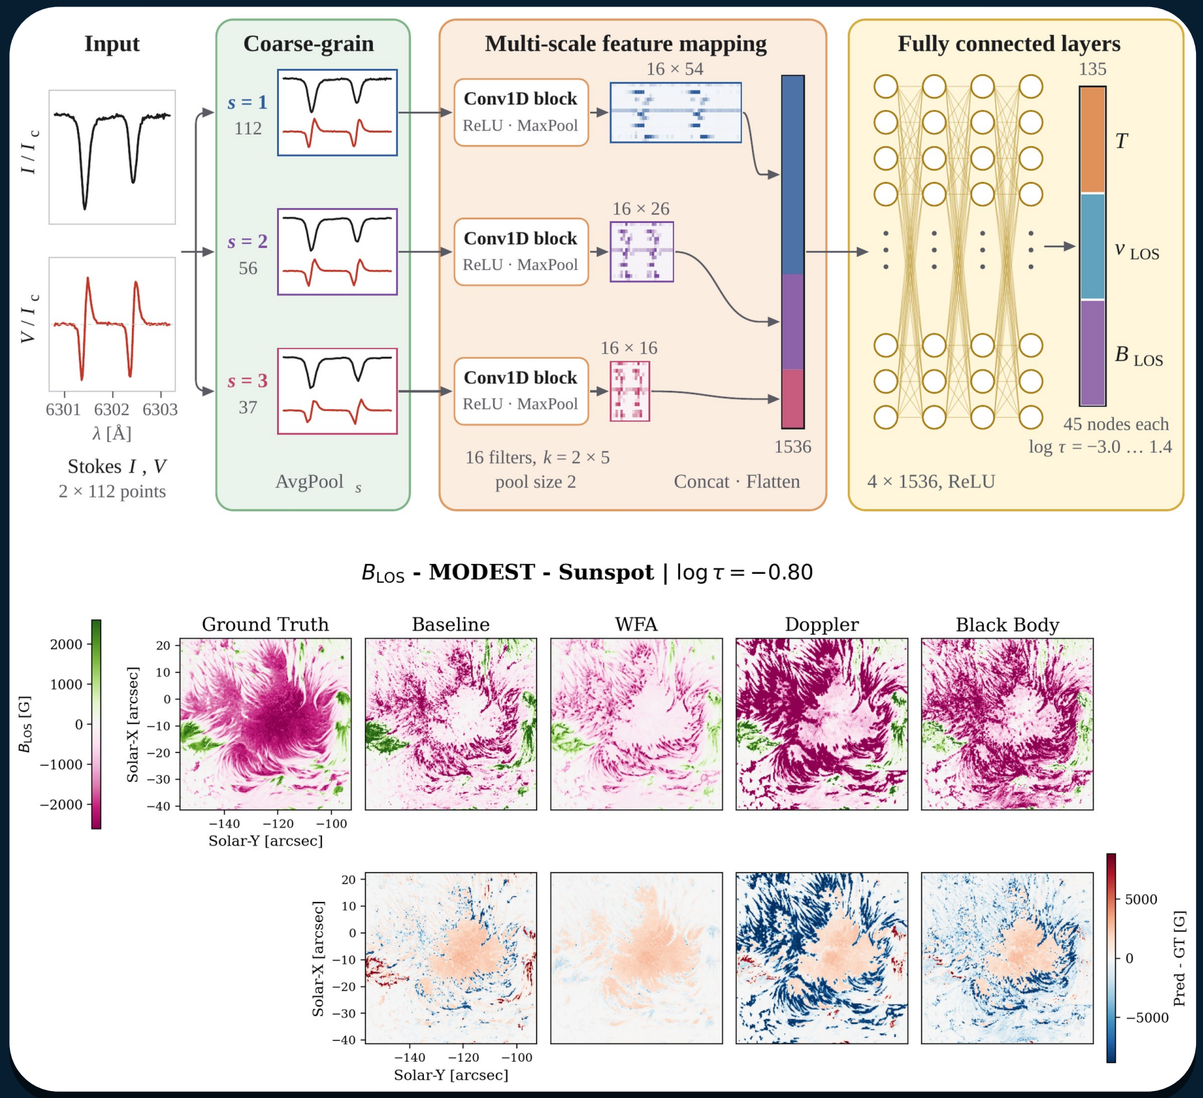
# MUISCA: inversión de Stokes con física

- Invierte **Stokes *I* y *V*** en $T$, $v_{LOS}$ y $B_{LOS}$ en **45 nodos** de profundidad óptica
- CNN multiescala entrenada con perfiles de **NICOLE** sobre simulaciones **MURaM**
- Loss con términos físicos: **WFA**, Doppler y cuerpo negro
- 480 × 480 px en una GPU, $10^3$–$10^4$ veces más rápido que sintetizar con NICOLE

**IDEA CLAVE**

En preparación: el término WFA generaliza mejor, pero aún no iguala a los códigos numéricos.

Agudelo Ortiz, Morales, Vargas Domínguez, Castellanos Durán y Shelyag, MUISCA (en preparación).




Arquitectura y $B_{LOS}$ en una mancha (Hinode/MODEST, log $\tau = -0{,}8$). Agudelo Ortiz, Morales, Vargas Domínguez, Castellanos Durán y Shelyag, en prep.

# Por tarea vs. foundation model

## Del modelo especializado al foundation model

### Un modelo por tarea

- Una red para una sola tarea
- Sus propios labels e instrumento
- U-Net, Enhance, FarNet, MUISCA

### Foundation model (Surya)

- Pretrained con 13 canales de SDO
- Se adapta con poco fine-tuning (LoRA)
- Flares, viento solar, EUV…

Referencias: Roy et al. (2025), arXiv:2508.14112 (Surya).

SECCIÓN

# 03

# Mi investigación: un copiloto



¿Puede un modelo describir con palabras lo que ve Surya?

CONCEPTO

# ¿Qué es un foundation model?

- Un modelo entrenado **una vez** con datos muy amplios, que luego se adapta a **muchas tareas**
- **Texto**: los asistentes de chat como ChatGPT, Claude o Gemini
- **Imagen y voz**: generadores como Stable Diffusion y transcripción automática como Whisper
- **Código**: asistentes de programación como GitHub Copilot
- Cada tarea final es una **downstream task**

**IDEA CLAVE**

Un mismo modelo base sirve para muchas tareas distintas, no uno por tarea.

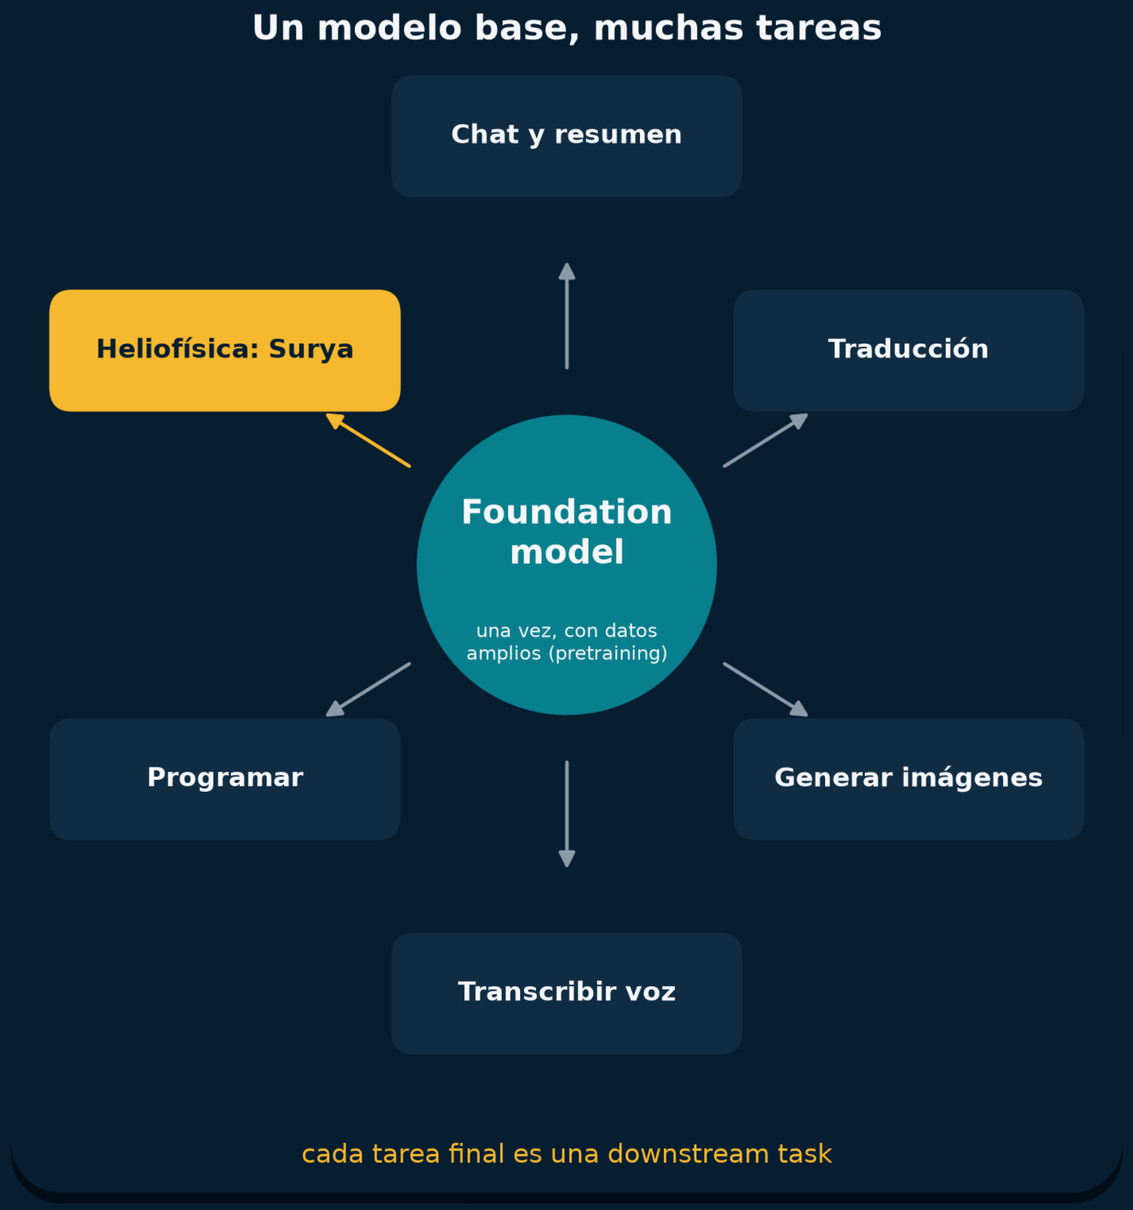



Imagen: elaboración propia (esquema)

Referencias: Bommasani et al. (2021), On the Opportunities and Risks of Foundation Models, arXiv:2108.07258 · Rombach et al. (2021), Stable Diffusion, arXiv:2112.10752 · Radford et al. (2022), Whisper, arXiv:2212.04356.

EJEMPLO DE LA SESIÓN

# Surya: un modelo para el Sol

- **Surya** es un foundation model de heliofísica: un transformer espaciotemporal con **366 M** de parámetros
- Lee **13 canales** de SDO en dos instantes y se entrenó (pretraining) para hacer forecasting del Sol **60 min** adelante
- Después se adapta a **downstream tasks**: tareas concretas para las que se ajusta el modelo ya preentrenado
- Evaluadas: dinámica solar y flares sin ajuste (zero-shot); viento solar, regiones activas, flares y espectros EUV con fine-tuning (LoRA)

**IDEA CLAVE**

Un solo modelo preentrenado sirve de base para muchas tareas finales (downstream tasks).

Referencias: Roy et al. (2025), Surya: Foundation Model for Heliophysics, arXiv:2508.14112.

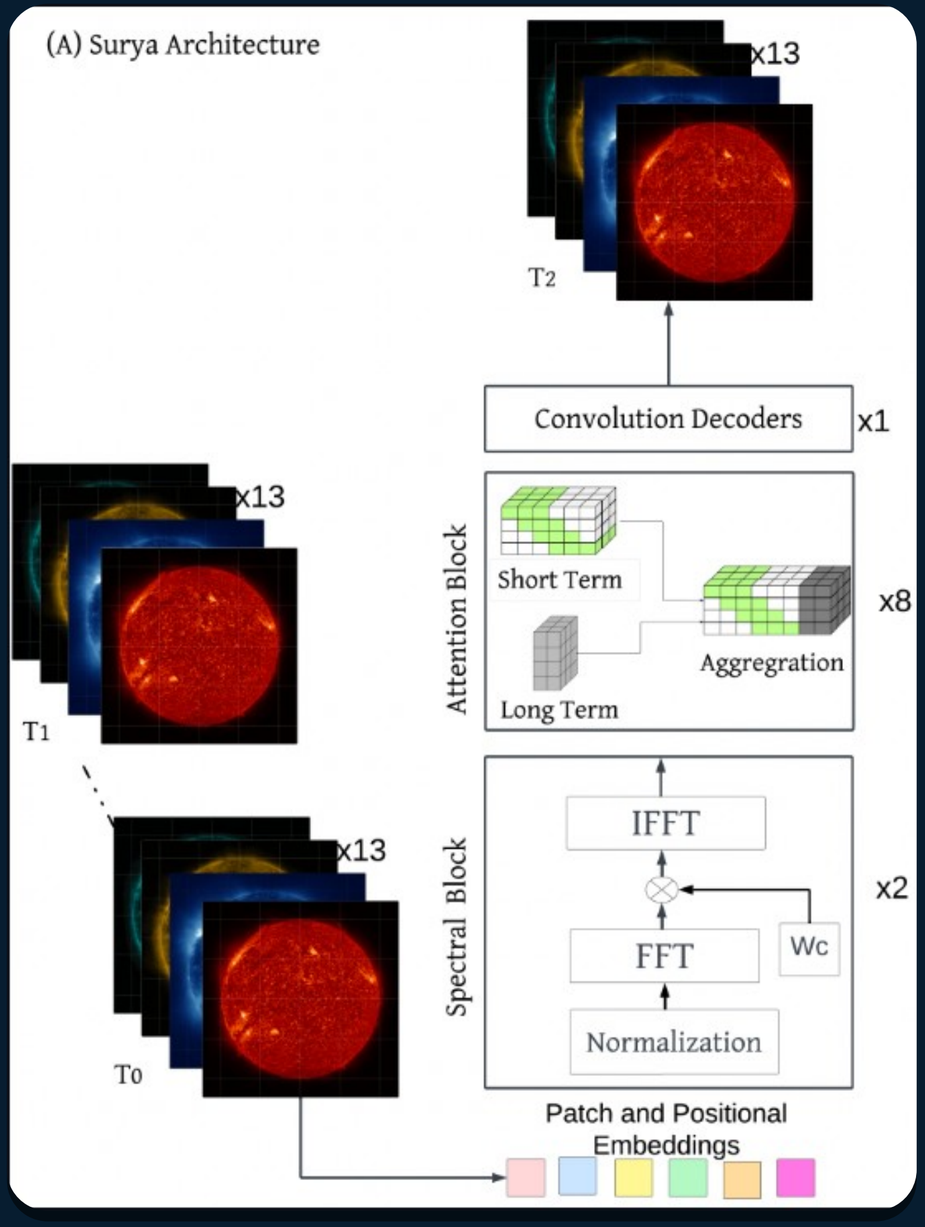



Imagen: arquitectura de Surya, Roy et al. (2025)

MOTIVACIÓN

# El copiloto de física solar

- Meta: “muéstrame esta región activa y estima la probabilidad de un flare M en 24 h”
- Un LLM orquesta los datos, ejecuta Surya y explica
- Ruta: **VLM** → preguntas → herramientas → agente
- Hoy, el primer paso: **describir** una observación de SDO

**IDEA CLAVE**

Antes de razonar sobre lo que ve Surya, sus embeddings deben traducirse al espacio del LLM.

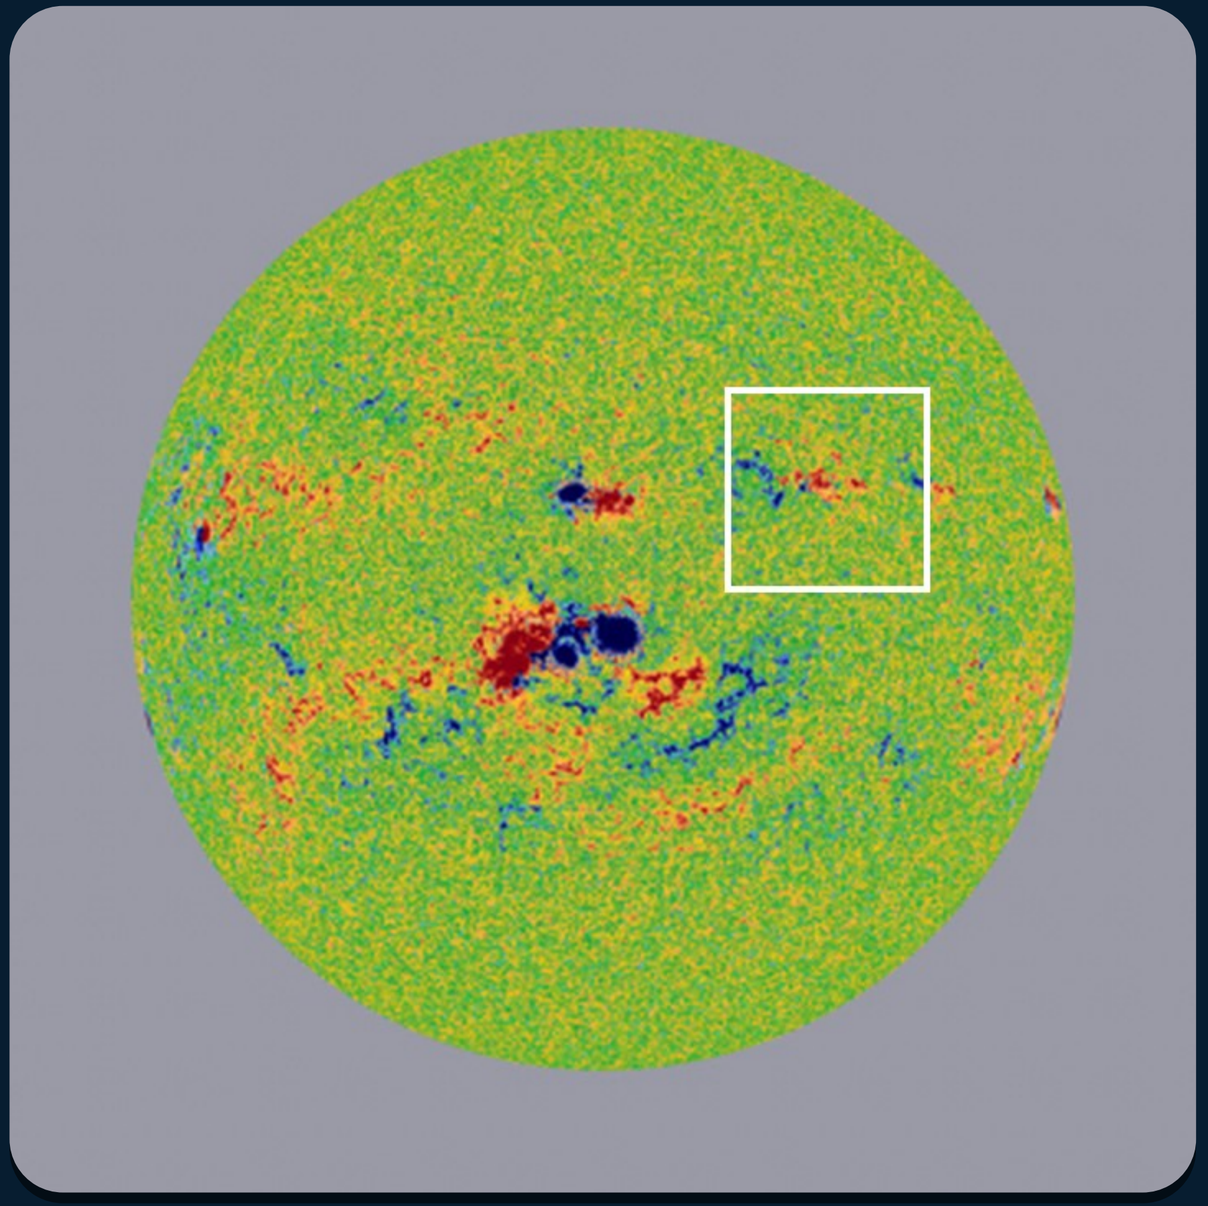


Imagen: magnetograma de HMI del 7 ene 2014 y la caja de una región activa

# Dos fuentes de texto

**Para entrenar hacen falta pares observación–caption**

## Artículos

- Figuras y textos de la literatura
- Hay que re-consultar la observación
- Pocos pares y metadatos ruidosos

## Catálogo (HEK, NOAA)

- Posición, manchas y clases
- Captions con plantilla fija, sin LLM
- Muchos pares, texto repetitivo

# Surya en cifras

UN FOUNDATION MODEL PARA HELIOFÍSICA

01

**366 M**

parámetros: transformer espaciotemporal

02

**13 canales**

8 de AIA y 5 de HMI

03

**4096²**

píxeles: la resolución nativa de SDO

04

**+60 min**

pretrained para hacer forecasting del Sol una hora adelante

Referencias: Roy et al. (2025), Surya: Foundation Model for Heliophysics, arXiv:2508.14112.

ECUACIÓN / DATO DESTACADO

$$x' = \frac{s\left(0{,}01\,x\right) - \mu}{\sigma + \varepsilon}$$

$$s(x) = \operatorname{sign}(x)\log(1 + |x|)$$

## Normalización de Surya

Scaling, signed log y standardization con $\mu$ y $\sigma$ globales de cada canal. Por eso una imagen no queda con media 0: aia94 va de −0,53 a 219,6.

Referencia: surya.datasets.helio.transform; notebook, sección 2

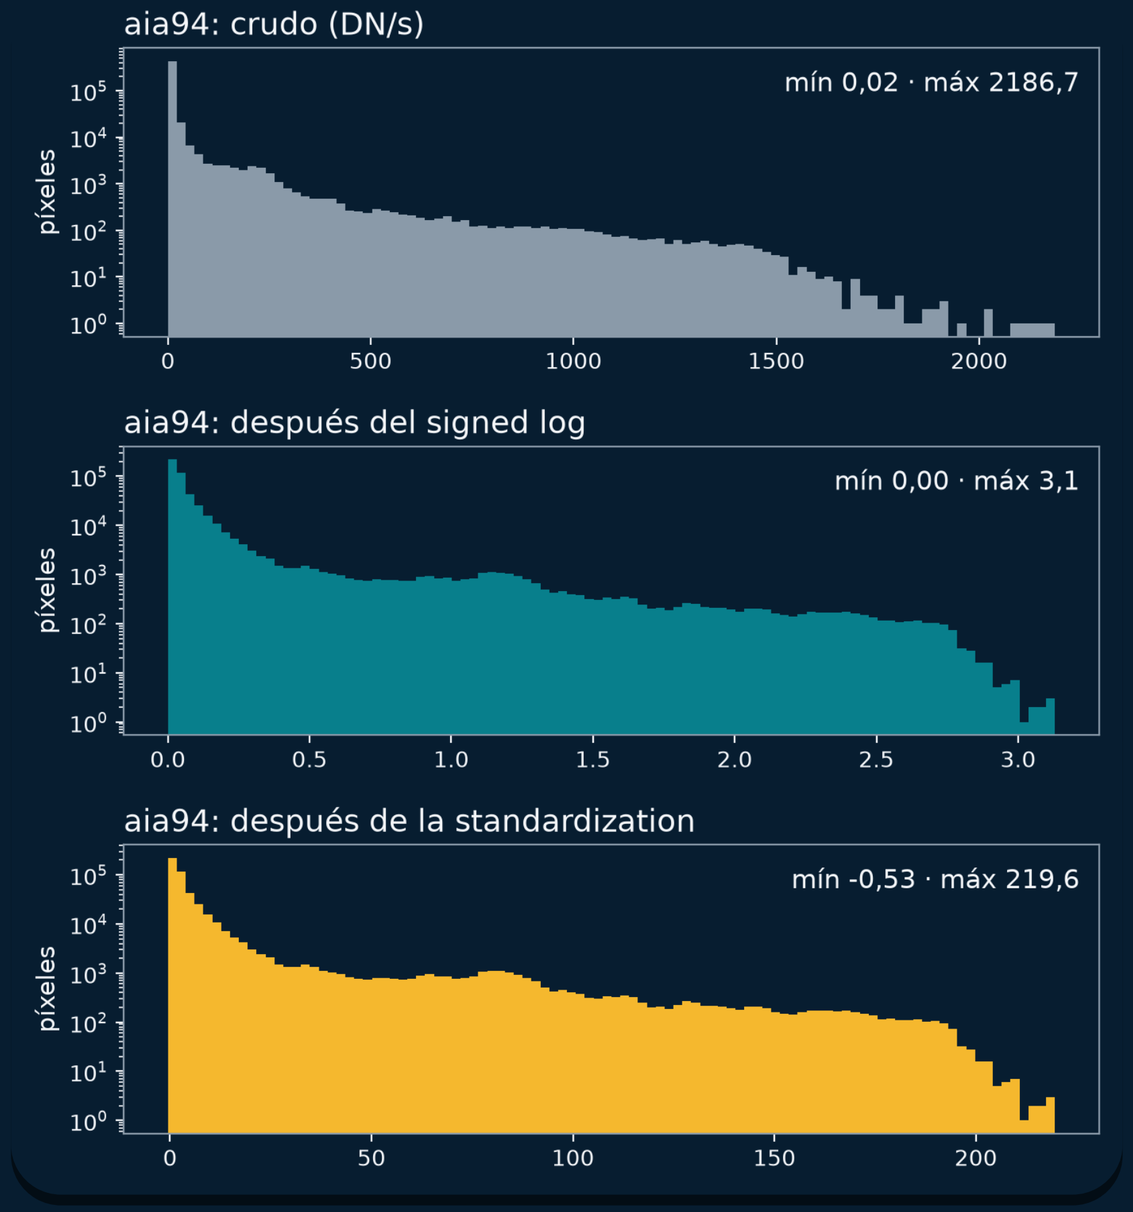



Imagen: histogramas de aia94 en cada paso, AR 11944 (notebook, sección 2)

CONCEPTO

# De la región a 256 tokens

- Recorte de **704 × 704 px** alrededor de la AR 11944
- Un token por patch de **16 × 16 px**: **45 × 45** tokens de 1280 dimensiones
- **Adaptive pooling** a 16 × 16 = **256 tokens**
- Surya corre sobre el **disco completo**: se recortan tokens, no la imagen

**IDEA CLAVE**

Recortar la imagen quitaría el contexto de posición y escala que Surya aprendió.

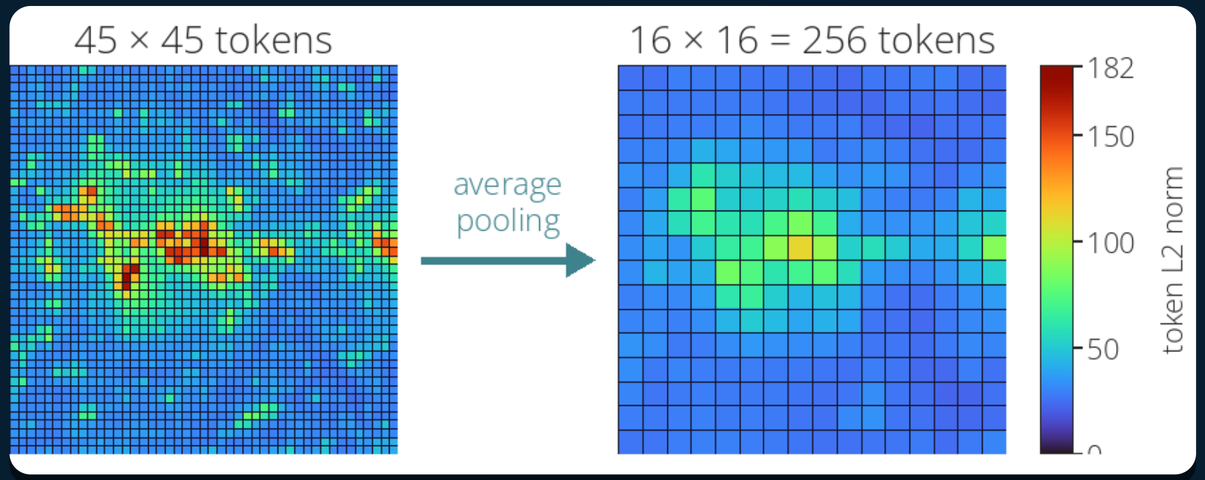



Imagen: norma L2 de los tokens antes y después del pooling

CÓDIGO · PRÁCTICA

# Práctica 1: del dato a los tokens

1. Corre las secciones 1 a 5 del notebook
2. Cambia nombre a otro canal y compara los pasos
3. Mira por qué la media no queda en 0

**OBJETIVO**

Entender la normalización de Surya y sus constantes globales.

01_Del_dato_solar_al_caption.ipynb

```
1  nombre = "aia94"
2  k = constantes[nombre]
3  x = crudo[canales.index(nombre)].astype(np.float64)
4
5  paso1 = x * k["sl_scale_factor"]
6  paso2 = np.sign(paso1) * np.log1p(np.abs(paso1))
7  paso3 = (paso2 - k["mean"]) / (k["std"] + k["epsilon"])
8
9
10
11
```

**SALIDA › paso 3: mín −0,526 · máx 219,601 · media 9,203**

ARQUITECTURA

# Surya + projector + LLM

- **Surya** frozen: 256 tokens de 1280 dimensiones
- **Projector MLP** 1280 → 4096 → GELU → 4096: **22 M** parámetros
- **Qwen3-8B** frozen lee los visual tokens y escribe el caption
- La receta de LLaVA (Liu et al., 2023)

**IDEA CLAVE**

Solo se entrena el projector: 22 M de parámetros frente a 366 M de Surya.

Referencias: Liu et al. (2023), Visual Instruction Tuning (LLaVA), arXiv:2304.08485.

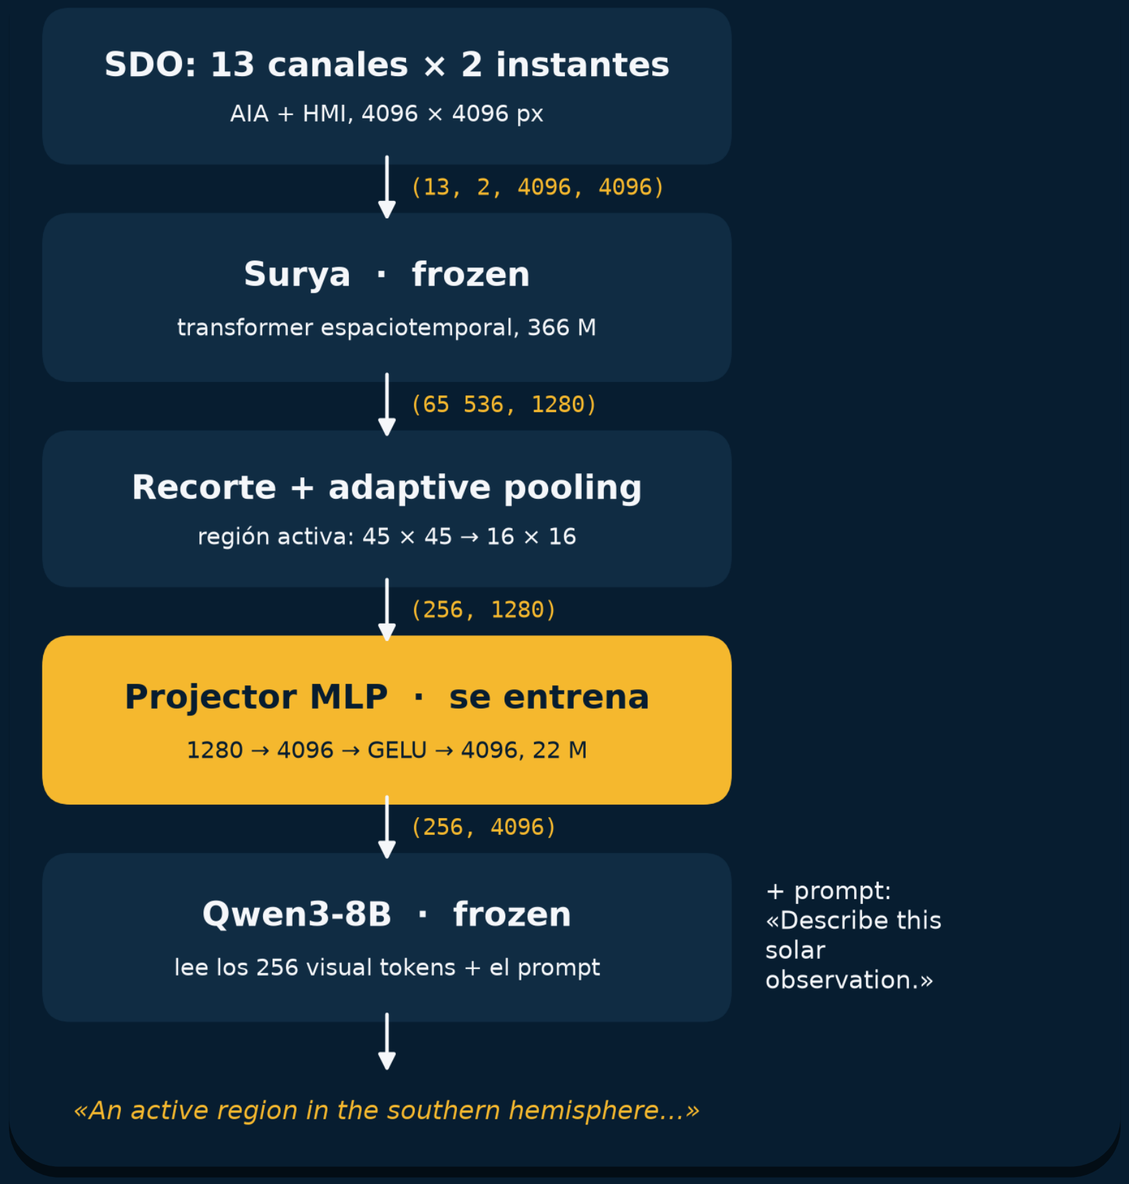



Imagen: elaboración propia, con las formas reales de cada paso

# 316 posiciones

## La secuencia que lee el LLM

Encabezado, 256 visual tokens (posiciones 4 a 259), el prompt y el caption. La loss solo cuenta el caption y su token de fin (275 a 314), no el prompt ni la imagen.

Referencia: notebook, sección 7




Imagen: elaboración propia a partir de 03_Datos/secuencia_ejemplo.json

CÓDIGO · PRÁCTICA

# Práctica 2: el projector

1. Corre las secciones 6 y 7 del notebook
2. Cuenta los parámetros del projector
3. Mira qué posiciones entran en la loss

**OBJETIVO**

Ver cómo los 256 tokens de Surya se vuelven vectores que el LLM puede leer.

01_Del_dato_solar_al_caption.ipynb

```
1  def gelu(x):
2      return 0.5 * x * (1.0 + erf(x / np.sqrt(2.0)))
3
4  class Proyector:
5      def __call__(self, x):
6          return gelu(x @ self.w1 + self.b1) @ self.w2 + self.b2
7
8  proyector = Proyector()
9  visuales = proyector(agrupados.reshape(256, 1280))
10
11
```

**SALIDA › (256, 4096) · 22.028.288 parámetros entrenables**

# Resultados del prototipo

**PRUEBA DE QUE EL FLUJO ENTRENA, NO UN RESULTADO CIENTÍFICO**

01

**0,557**

mejor loss en las regiones held-out (epoch 15)

02

**+0,18**

image gap: cuánto sube la loss si se cambia la imagen

03

**17 / 19**

hemisferio correcto en días nuevos (baseline: 7)

04

**29 / 55**

captions que dicen «sur»; solo 12 regiones lo son

RESULTADOS

# Lo que funciona y lo que no

- La loss held-out baja hasta **0,557** y se estabiliza; **la imagen importa**: con otra imagen la loss sube
- En las 2 regiones del 7 ene, **«siempre norte»** gana (36/36 frente a 21/36)
- No aprendió a **contar manchas** (6 de 19 en días nuevos)
- Datos de pocos días y captions de plantilla: aún no hay generalización

**IDEA CLAVE**

Un porcentaje global engaña: hay que comparar contra baselines y desglosar por clase.

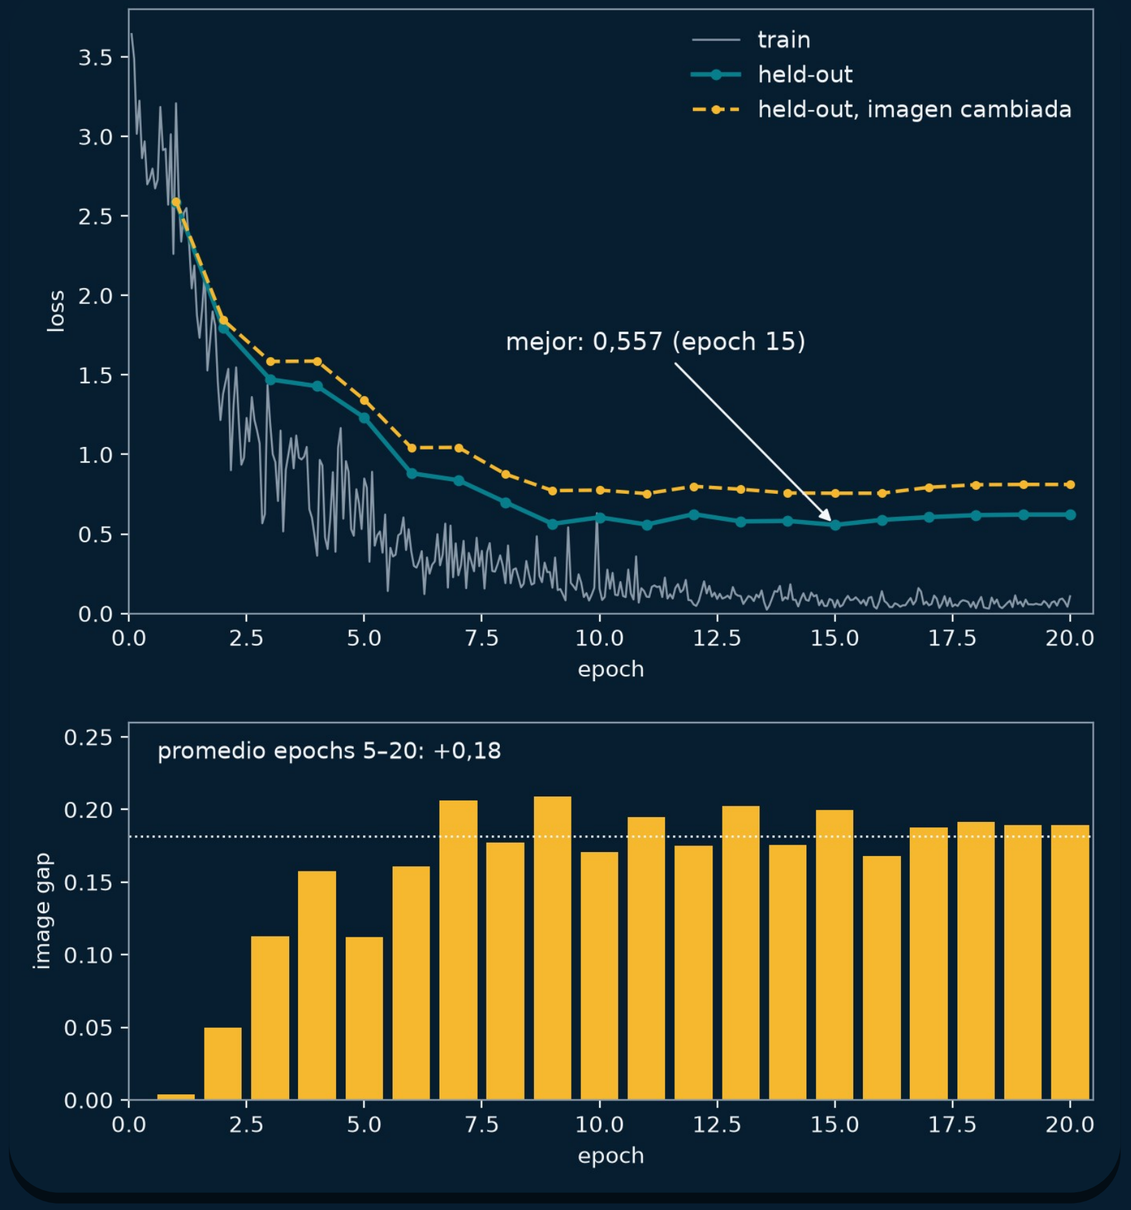



Imagen: loss curves y image gap del prototipo (run 2, 9 oct 2026)

MÁS ALLÁ DE SDO

# ¿Ve Surya a través de GOES-SUVI?

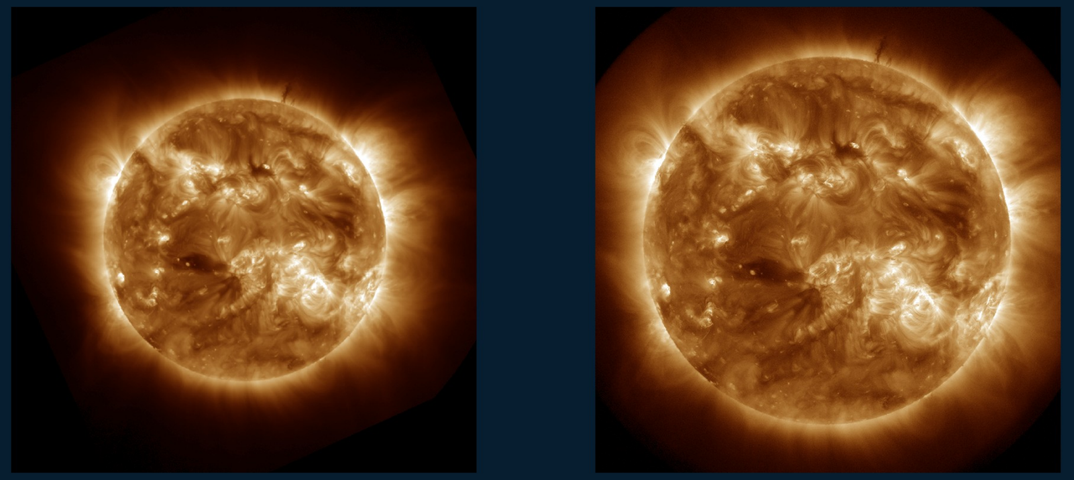
- SUVI es un instrumento **operativo** de GOES-R: daría datos en vivo
- Solo **6 de los 13** canales de Surya tienen equivalente en SUVI
- SUVI: 1280² px a 2,5″/px; AIA: 4096² a 0,6″/px
- Hay cuadros de SUVI con ruido anómalo: falta un filtro de calidad

**IDEA CLAVE**

Si Surya transfiere, el copiloto podría trabajar con datos en vivo además de SDO.

Referencias: Darnel et al. (2022), Space Weather 20, e2022SW003044.

15 mar 2023



GOES-18 SUVI 195 Å
1280² px · 2,50″/px · 09:56 UT

SDO AIA 193 Å
4096² px · 0,60″/px · 09:56 UT

Imagen: elaboración propia. SUVI 195 Å (GOES-18, NOAA) y AIA 193 Å (SDO, NASA), 15 mar 2023, 09:56 UT

# Conclusiones

**LO QUE NOS LLEVAMOS HOY**

1. El ML ya resuelve tareas solares: segmentation, super-resolution, inversión y forecasting
2. Los foundation models como Surya pasan de una tarea a muchas
3. Un projector pequeño conecta Surya con un LLM; faltan mejores datos



**TAREA › Ejercicios 1–4 del notebook (sección 9). Para seguir: HelioML**

# Referencias

## LECTURAS


Asensio Ramos, Cheung, Chifu y Gafeira (2023). Machine learning in solar physics. Living Rev. Sol. Phys. 20, 4

Bobra y Mason (2018). Machine Learning, Statistics, and Data Mining for Heliophysics (HelioML). doi:10.5281/zenodo.1412824

Roy et al. (2025). Surya: Foundation Model for Heliophysics. arXiv:2508.14112

Liu et al. (2023). Visual Instruction Tuning (LLaVA). arXiv:2304.08485

Díaz Baso y Asensio Ramos (2018). Enhancing SDO/HMI images using deep learning. A&A 614, A5

Bobra e Ilonidis (2016). Predicting Coronal Mass Ejections Using Machine Learning Methods. ApJ 821, 127

Reiss et al. (2021). The Observational Uncertainty of Coronal Hole Boundaries in Automated Detection Schemes. ApJ 913, 28




**MÁS LECTURAS › 04_Lecturas en el repositorio de la escuela**

DATOS DE CIENCIA

# Datos de Ciencia en YouTube

- Python desde cero para **Ciencia de Datos, ML e IA**
- NumPy con datos reales de **TESS**: el tránsito de WASP-18 b
- **Juan Esteban Agudelo Ortiz** (líder y guion); Thomas Gonzales, Milena Barrios y Claudia Cuellar (presentación); Santiago Pinilla y Daniel Rodríguez (edición)
- En colaboración con miembros del GoSA del OAN

**IDEA CLAVE**

Lo de hoy (arrays, normalización, imshow) está en la serie de NumPy.




**1 · Python desde cero**




**2 · NumPy vs Python básico**




**3 · Tipos de datos y precisión**

**En producción**

**4 · Shape de los arrays**

Videos de @Datos.deCiencia: 1 a 3 publicados; 4 en producción

# @Datos.deCiencia

## ¡Suscríbete!

Escanea el código o busca el canal en YouTube. Los notebooks de la serie de NumPy están en github.com/Datos-De-Ciencia.

youtube.com/@Datos.deCiencia



Logo del canal y código QR al canal



# ¡Gracias!

## ¿Preguntas?

Juan Esteban Agudelo Ortiz
juagudeloo@unal.edu.co

Registro
tiny.cc/escuelasolar

Más información
astronomiaoan.co/gosa/escuela.html

Organiza: Group of Solar Astrophysics GoSA
Observatorio Astronómico Nacional · UNAL Bogotá