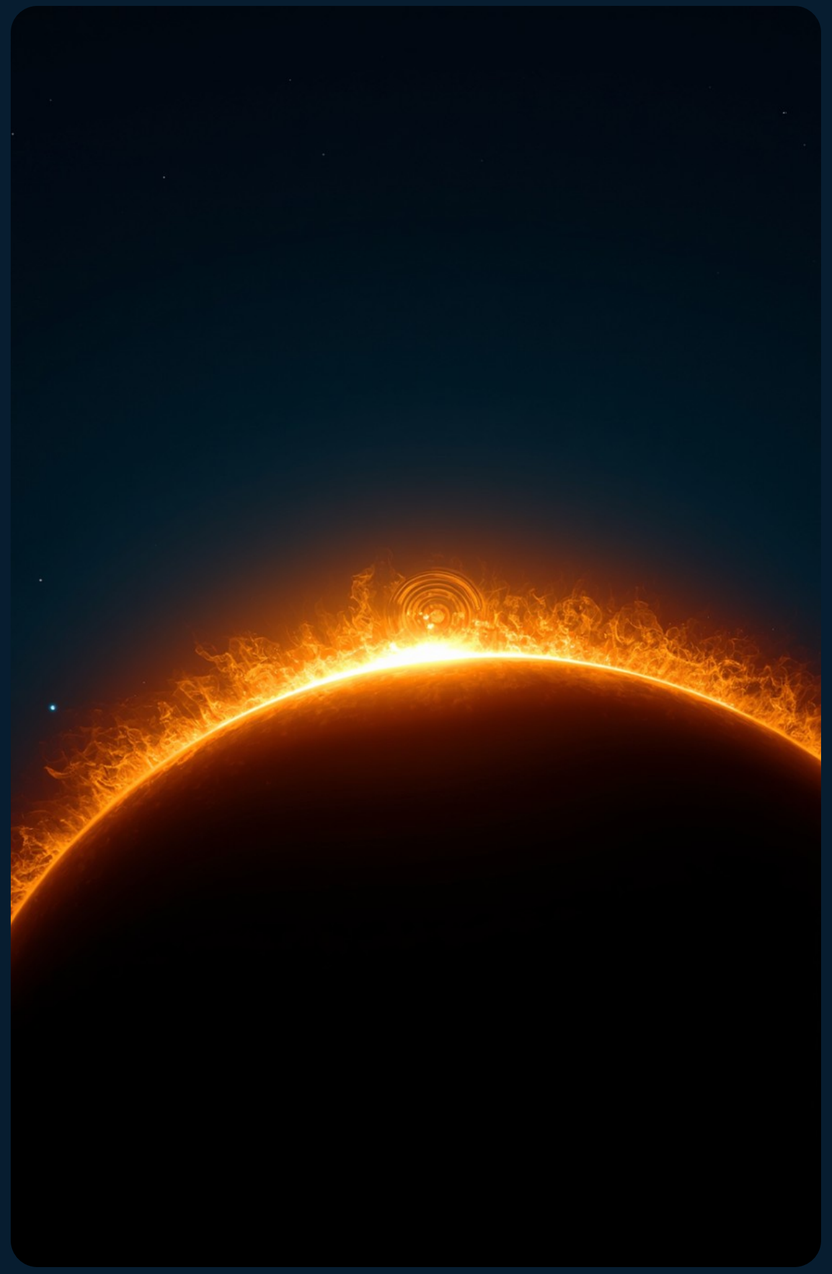
ESCUELA DE ASTROFÍSICA SOLAR · OCTUBRE 2026

HelioData Academy 2026

Machine Learning aplicado al estudio del Sol

Del dato solar al lenguaje: aplicaciones y un copiloto de física solar

Juan Esteban Agudelo Ortiz · OAN, Universidad Nacional de Colombia · 29 oct 2026



Group of Solar Astrophysics GoSA
Observatorio Astronómico Nacional · UNAL Bogotá

Agenda de la sesión

RUTA DE LA SESIÓN

01

Conceptos de ML

Supervised y unsupervised, deep learning, y cómo se entrena y se evalúa un modelo. (≈ 20 min)

02

Aplicaciones en física solar

Segmentation, super-resolution, inversión y forecasting; HelioML y MUISCA. (≈ 25 min)

03

Mi investigación: un copiloto

Surya, pares imagen–texto, projector y resultados, con dos prácticas. (≈ 60 min + 15 de discusión)

SECCIÓN

01

Machine Learning

¿Qué significa que un modelo aprenda de los datos?



Dos formas de aprender

Supervised vs. unsupervised learning (Asensio Ramos et al. 2023, §1)

Supervised

- Aprende de pares input–output
- Regresión: flujo máximo de rayos X
- Clasificación: ¿flare M o mayor?

Unsupervised

- Solo ve observaciones, sin labels
- Busca estructura: clustering
- Ej.: perfiles de Stokes parecidos

CONCLUSIÓN Con labels confiables, supervised; para explorar datos sin labels, unsupervised.

CONCEPTO

Deep learning

- **CNN**: leen imágenes con filtros locales
- **RNN y LSTM**: leen secuencias en el tiempo
- **Transformers**: atención entre todos los elementos
- Surya es un **transformer** espaciotemporal

IDEA CLAVE

La arquitectura se elige según la forma del dato: imagen, secuencia o conjunto de tokens.

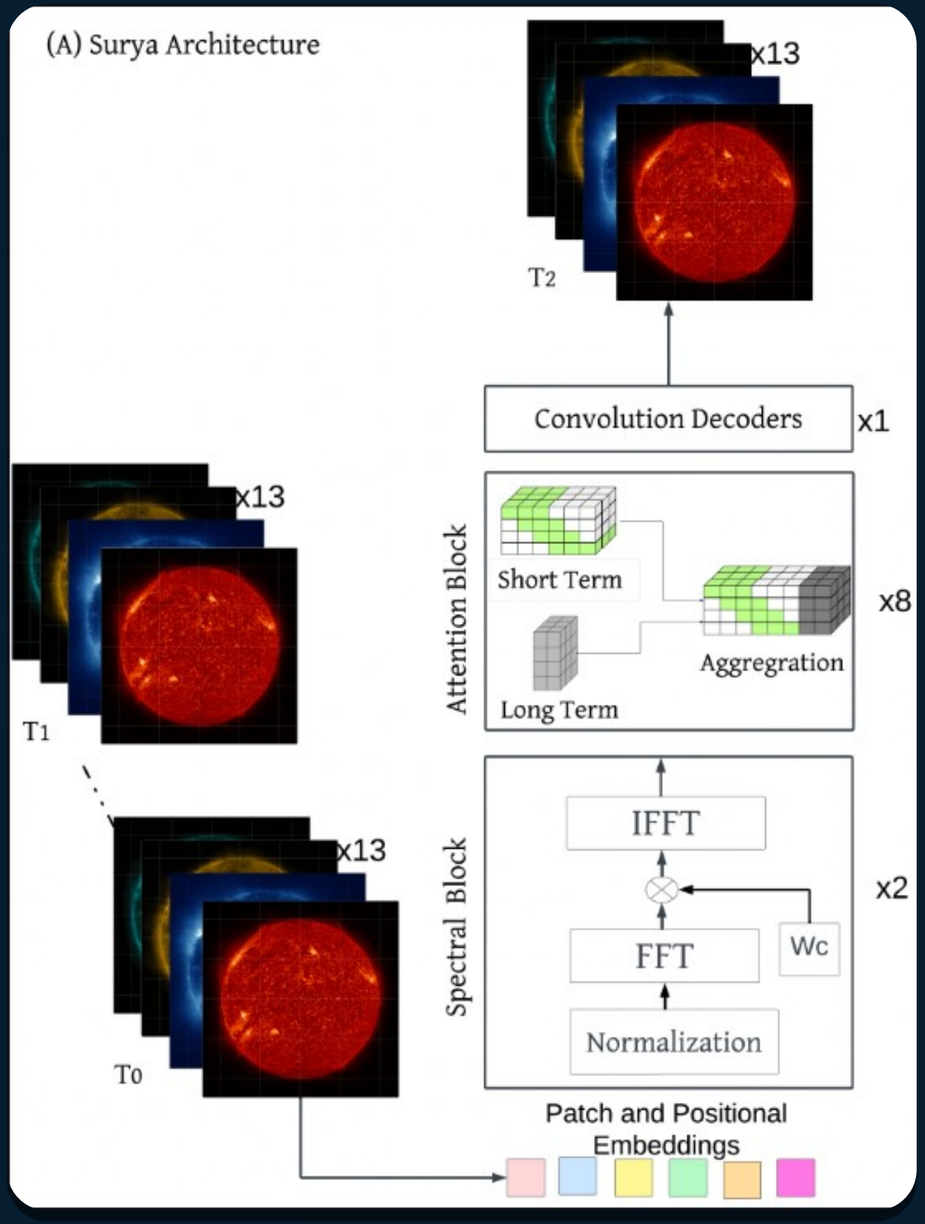


Imagen: arquitectura de Surya, Roy et al. (2025)

CONCEPTO

Entrenar y evaluar

- La **loss** mide qué tan lejos está la predicción del label
- Entrenar es bajar la loss con **gradient descent**; backpropagation dice cómo mover cada peso
- Se evalúa en datos **held-out**, que el modelo nunca vio al entrenar
- Siempre contra un **baseline** tonto, p. ej. «nunca hay flare»

IDEA CLAVE

Un modelo es bueno solo si supera a un baseline en datos que no vio.

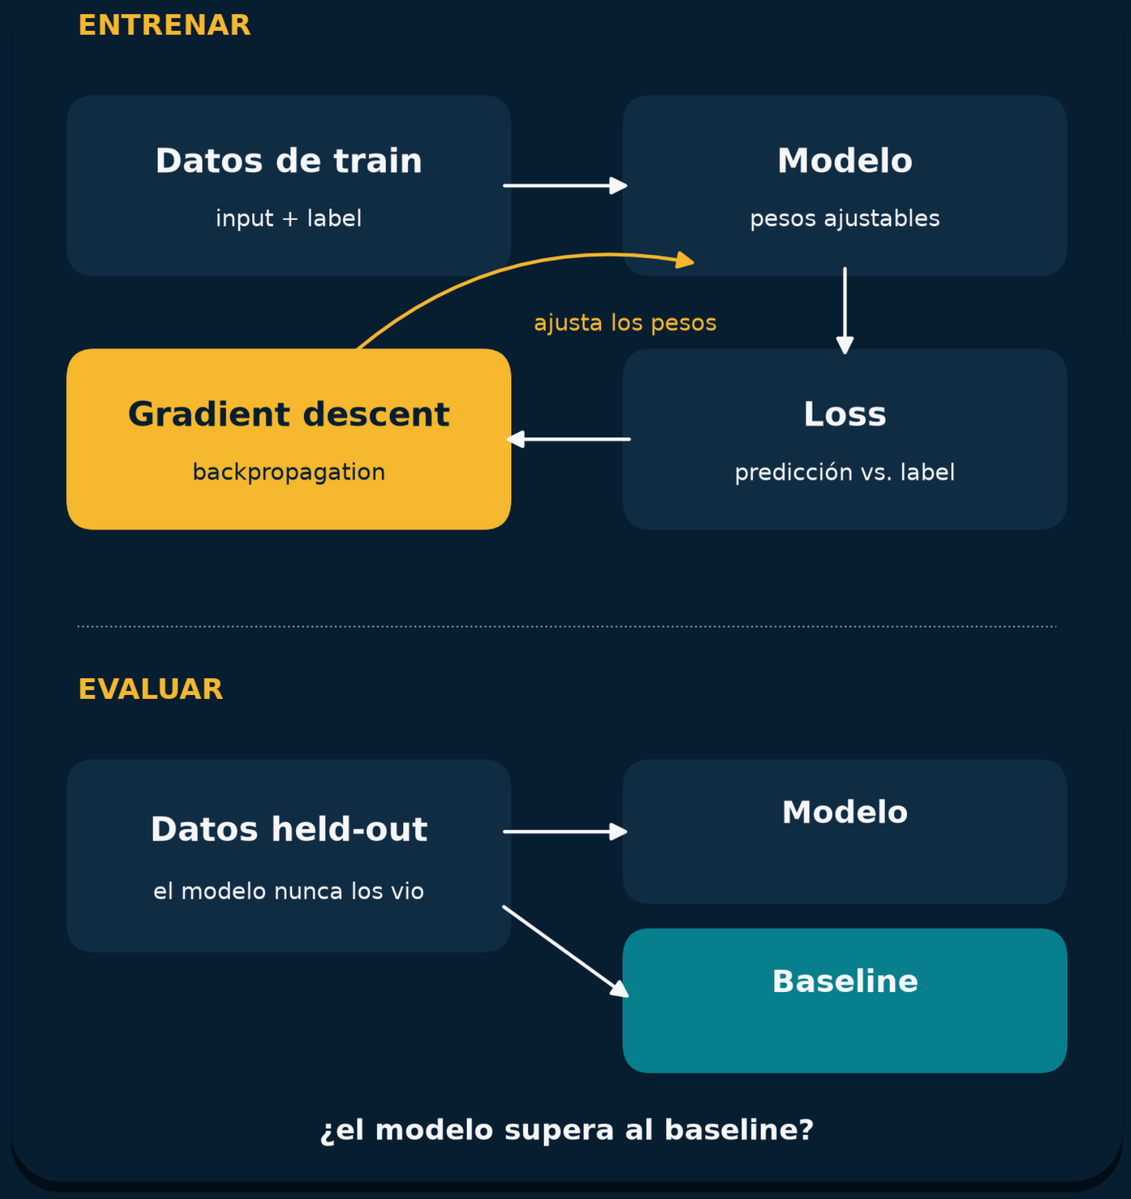


Imagen: elaboración propia (esquema)

SECCIÓN

02

Aplicaciones en física solar



¿Qué se ha hecho ya con ML en datos solares?

Aplicaciones en cifras

ASENSIO RAMOS ET AL. (2023), SECCIÓN 7

01

2385 mapas

para entrenar una U-Net que marca agujeros coronales en AIA 193 Å

02

0,5″ → 0,25″

píxel de HMI tras Enhance, una CNN de super-resolution

03

≈ 200 ms

SICON invierte un mapa de 512 × 512 de Hinode en una GPU

04

≈ 47 %

más regiones del far side con FarNet, a iguales falsos positivos

APLICACIÓN

Detectar agujeros coronales

- Zonas oscuras en EUV y fuente principal del **viento solar**
- **U-Net** sobre AIA 193 Å: dice si cada píxel es agujero o no; **2385 mapas** de entrenamiento (Illarionov y Tlatov, 2018)
- Se entrena con la **binary cross-entropy**, píxel a píxel
- **CHRONNOS**: 7 canales EUV de AIA + magnetograma de HMI (Jarolim et al., 2021)

IDEA CLAVE

Nueve métodos dibujan bordes distintos para el mismo agujero: falta estimar la incertidumbre.

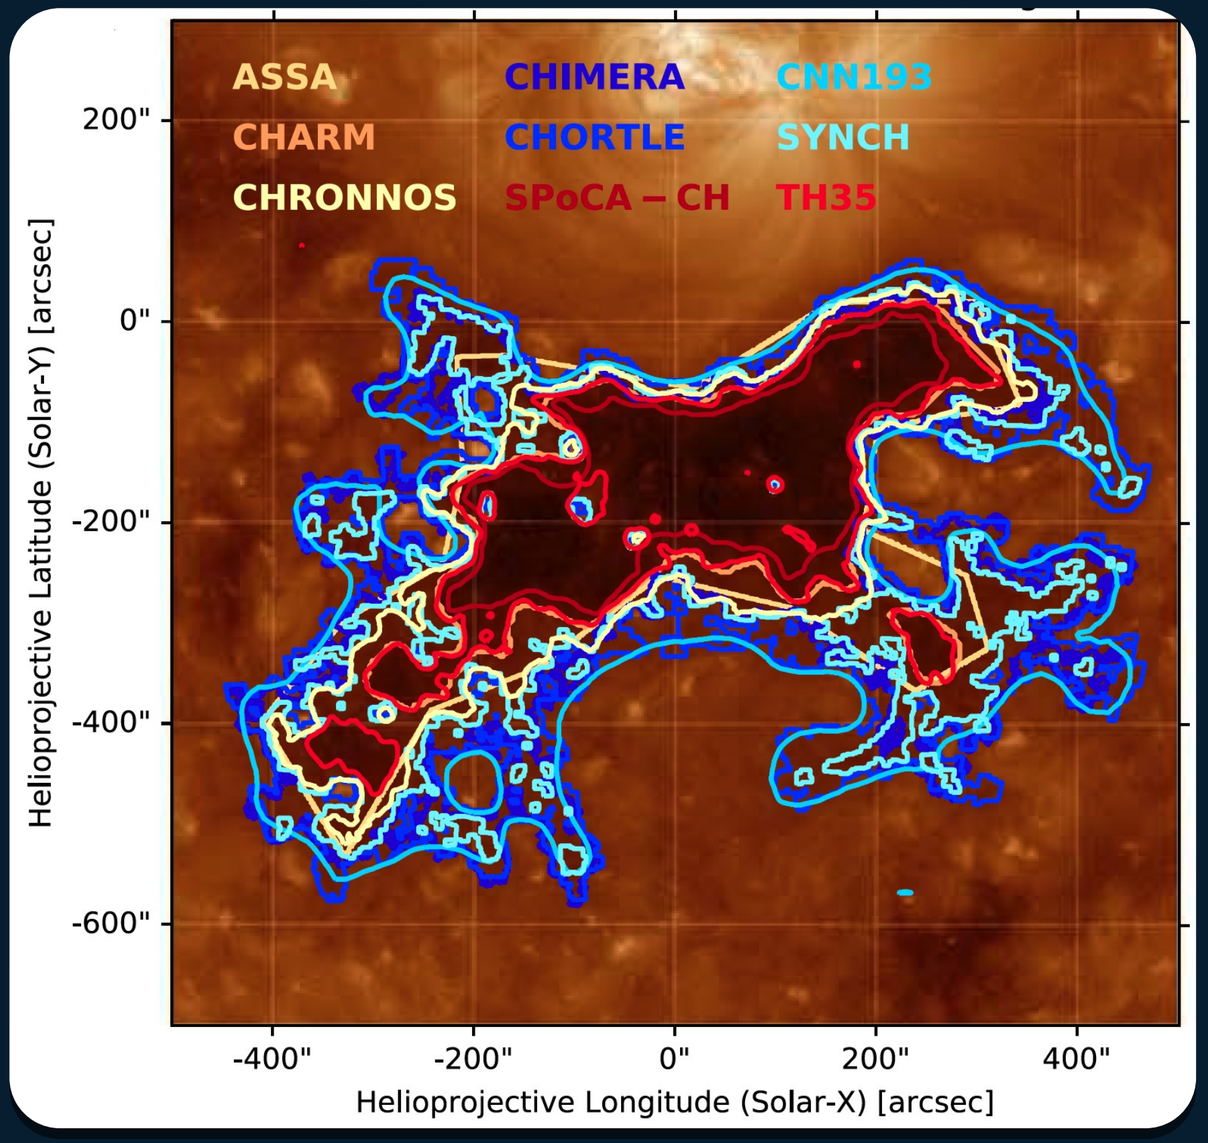


Imagen: un agujero coronal en AIA 193 Å segmentado por nueve métodos. Asensio Ramos et al. (2023), fig. 8, de Reiss et al. (2021), ApJ 913, 28

APLICACIÓN

Predecir el clima espacial

- **Flares**: clasificación (¿M o mayor en horas o días?) o regresión del flujo
- **CNN** sobre magnetogramas de MDI y HMI (Huang et al., 2018)
- **LSTM** con 25 parámetros SHARP y la historia de flares (Liu et al., 2019)
- **CME**: SVM de Bobra e Ilonidis (2016), capítulo 1 de HelioML

IDEA CLAVE

Los flares grandes son raros: hay que comparar contra baselines.

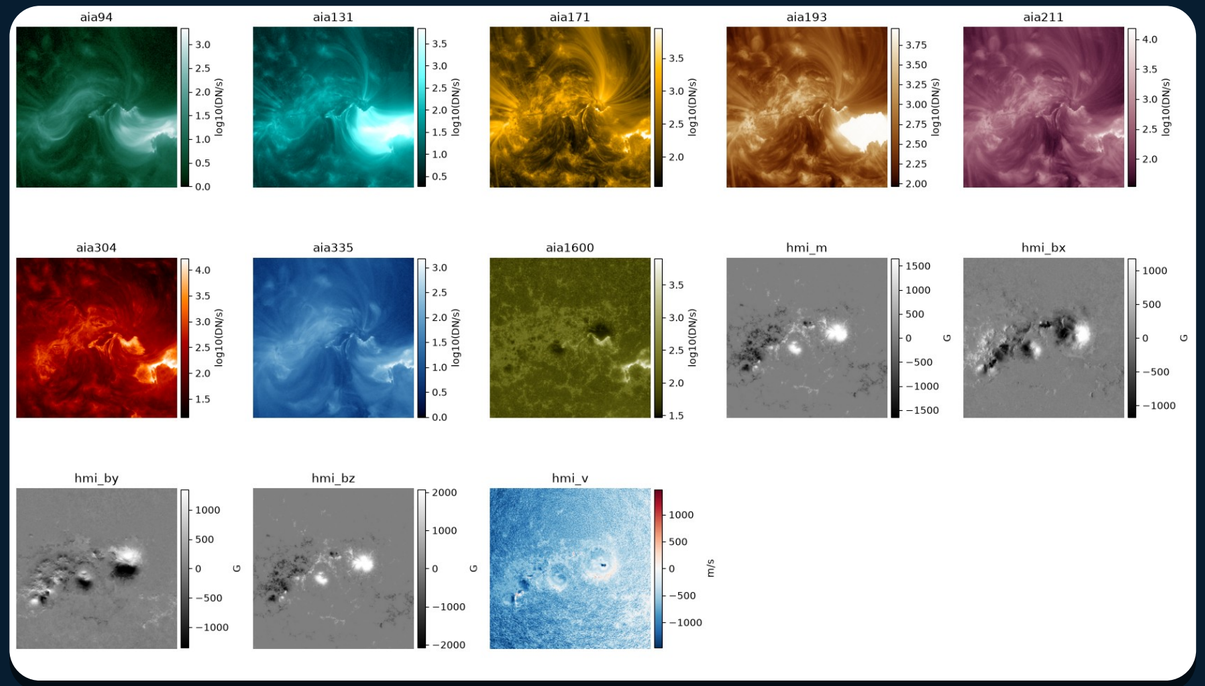


Imagen: AR 11944 durante el flare X1.2 del 7 ene 2014 (SDO, formato Surya)

RECURSO

9 notebooks

HelioML: un libro de notebooks de Jupyter

Reproducen resultados publicados: CME con SVM, Enhance, DeepEM (≈ 10^7 soluciones DEM por segundo), FarNet, viento solar sin labels (UMAP, HDBSCAN) y más.

Referencia: Bobra y Mason (2018), HelioML, helioml.org

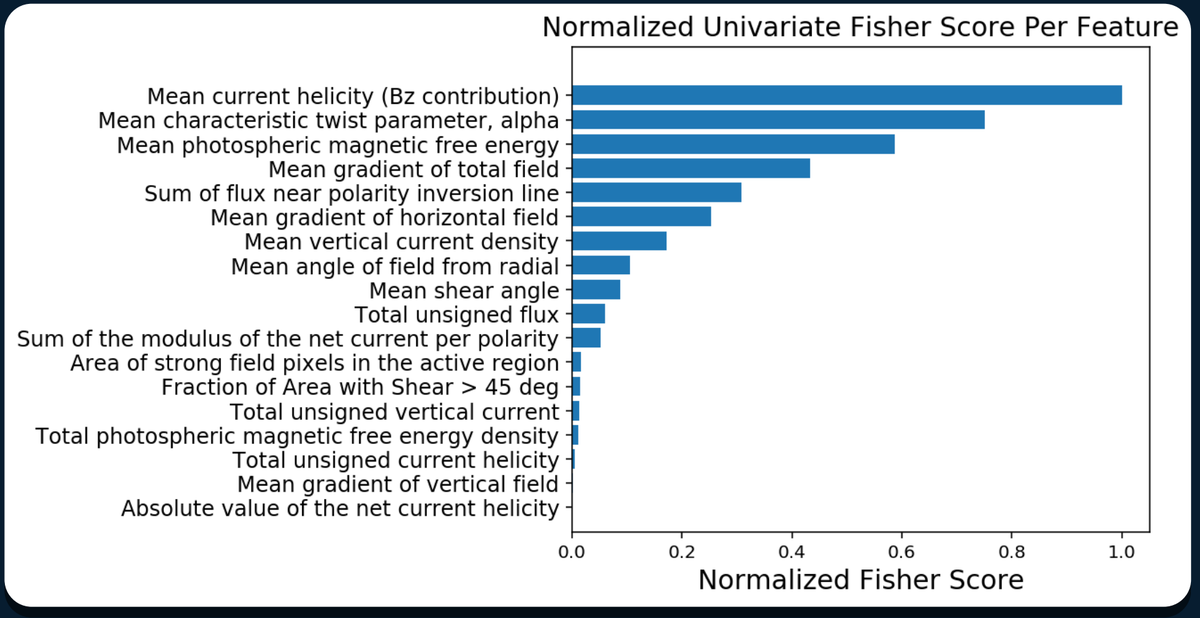


Imagen: Fisher score de cada parámetro SHARP para predecir CME. HelioML, cap. 1 (Bobra y Mason), según Bobra e Ilonidis (2016)

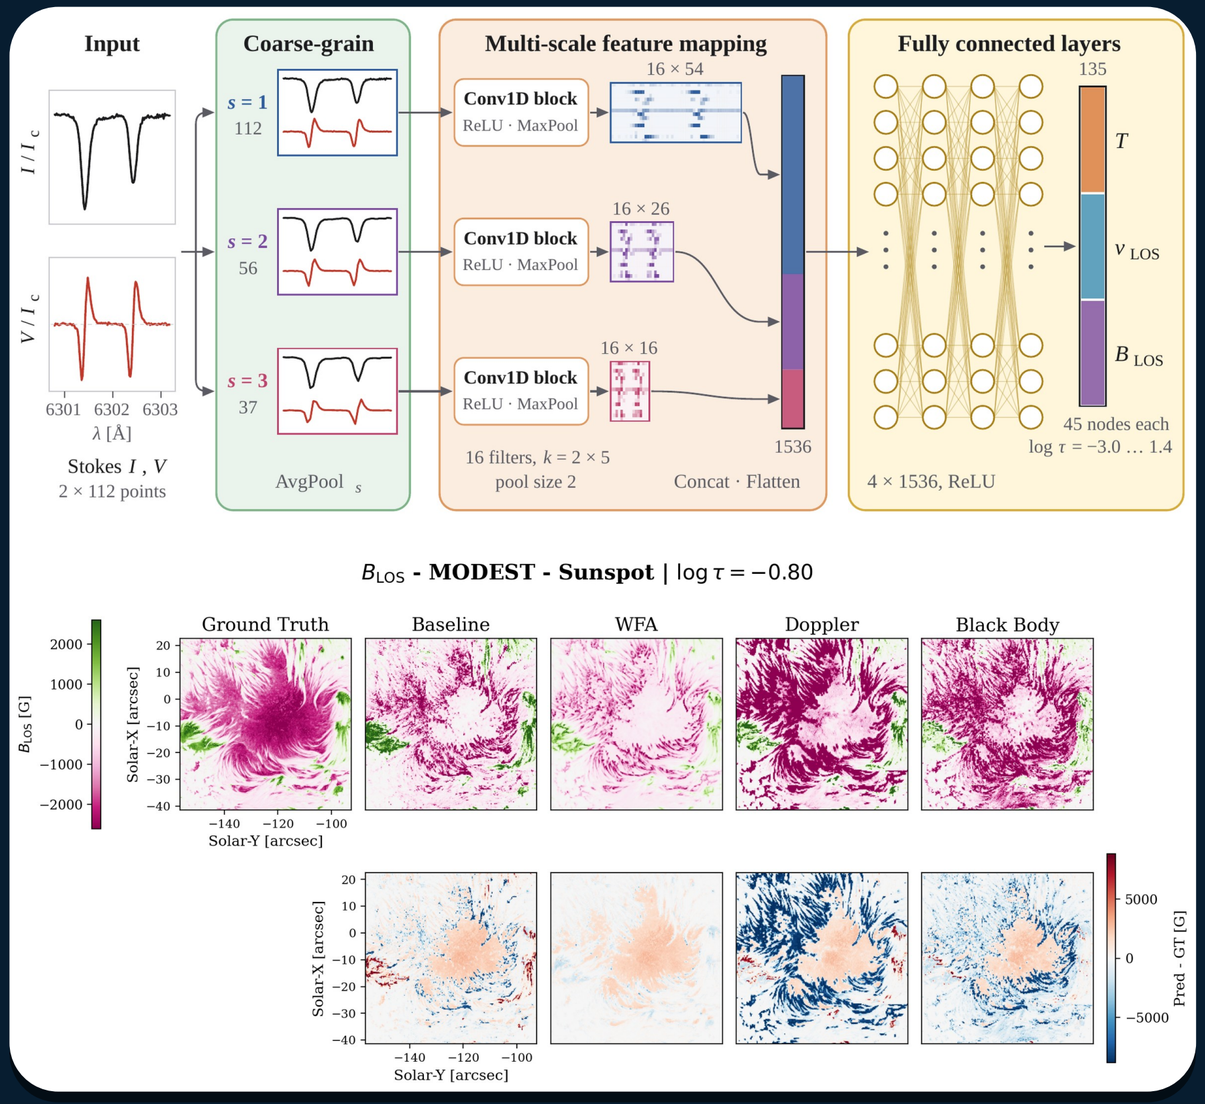
EN PREPARACIÓN

MUISCA: inversión de Stokes con física

- Invierte **Stokes I y V** en T, v_LOS y B_LOS en **45 nodos** de profundidad óptica
- CNN multiescala entrenada con perfiles de **NICOLE** sobre simulaciones **MURaM**
- Loss con términos físicos: **WFA**, Doppler y cuerpo negro
- 480 × 480 px en una GPU, 10^3–10^4 veces más rápido que sintetizar con NICOLE

IDEA CLAVE

En preparación: el término WFA generaliza mejor, pero aún no iguala a los códigos numéricos.



Arquitectura y B_LOS en una mancha (Hinode/MODEST, log τ = −0,8). Agudelo Ortiz, Morales, Vargas Domínguez, Castellanos Durán y Shelyag, en prep.

Por tarea vs. foundation model



Del modelo especializado al foundation model

Un modelo por tarea

- Una red para una sola tarea
- Sus propios labels e instrumento
- U-Net, Enhance, FarNet, MUISCA

Foundation model (Surya)

- Pretrained con 13 canales de SDO
- Se adapta con poco fine-tuning (LoRA)
- Flares, viento solar, EUV…

CONCLUSIÓN Nuestra pregunta: ¿se pueden traducir los embeddings de Surya al lenguaje?

SECCIÓN

03

Mi investigación: un copiloto



¿Puede un modelo describir con palabras lo que ve Surya?

MOTIVACIÓN

El copiloto de física solar

- Meta: “muéstrame esta región activa y estima la probabilidad de un flare M en 24 h”
- Un LLM orquesta los datos, ejecuta Surya y explica
- Ruta: **VLM** → preguntas → herramientas → agente
- Hoy, el primer paso: **describir** una observación de SDO

IDEA CLAVE

Antes de razonar sobre lo que ve Surya, sus embeddings deben traducirse al espacio del LLM.

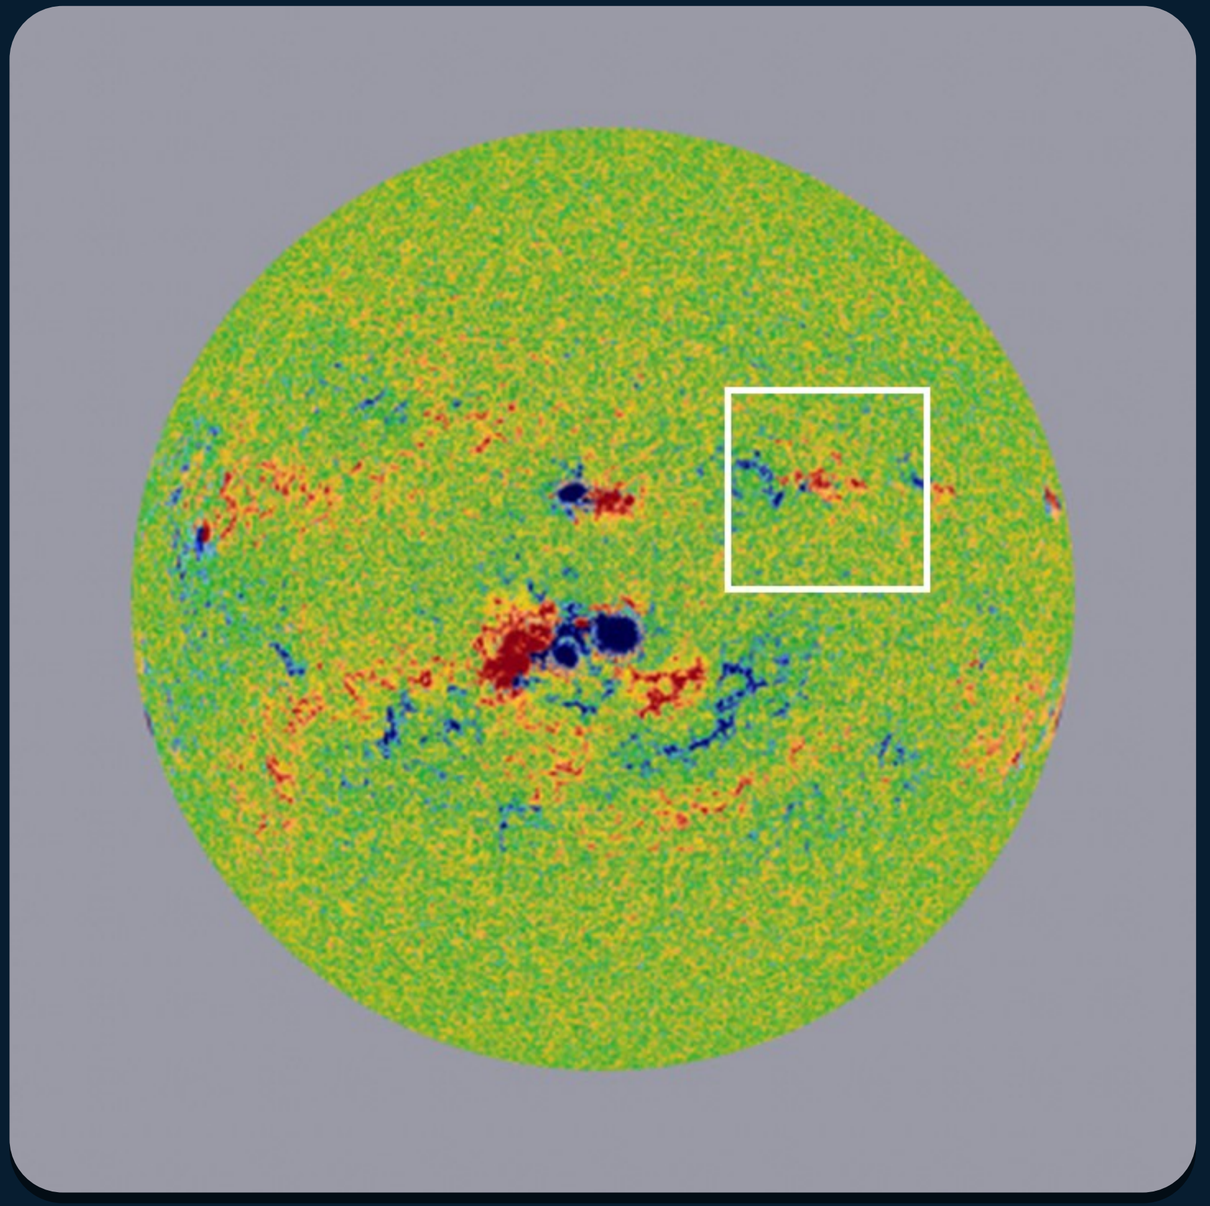


Imagen: magnetograma de HMI del 7 ene 2014 y la caja de una región activa

Dos fuentes de texto

Para entrenar hacen falta pares observación–caption

Artículos

- Figuras y textos de la literatura
- Hay que re-consultar la observación
- Pocos pares y metadatos ruidosos

Catálogo (HEK, NOAA)

- Posición, manchas y clases
- Captions con plantilla fija, sin LLM
- Muchos pares, texto repetitivo

CONCLUSIÓN El prototipo usa el catálogo; los artículos llegan cuando el pipeline madure.

Surya en cifras

ROY ET AL. (2025)

01

366 M

parámetros: transformer espaciotemporal

02

13 canales

8 de AIA y 5 de HMI

03

4096²

píxeles: la resolución nativa de SDO

04

+60 min

pretrained para hacer forecasting del Sol una hora adelante

ECUACIÓN / DATO DESTACADO

$$x' = \frac{s\left(0{,}01\,x\right) - \mu}{\sigma + \varepsilon}$$

$$s(x) = \operatorname{sign}(x)\log(1 + |x|)$$

Normalización de Surya

Scaling, signed log y standardization con μ y σ globales de cada canal. Por eso una imagen no queda con media 0: aia94 va de −0,53 a 219,6.

Referencia: surya.datasets.helio.transform; notebook, sección 2

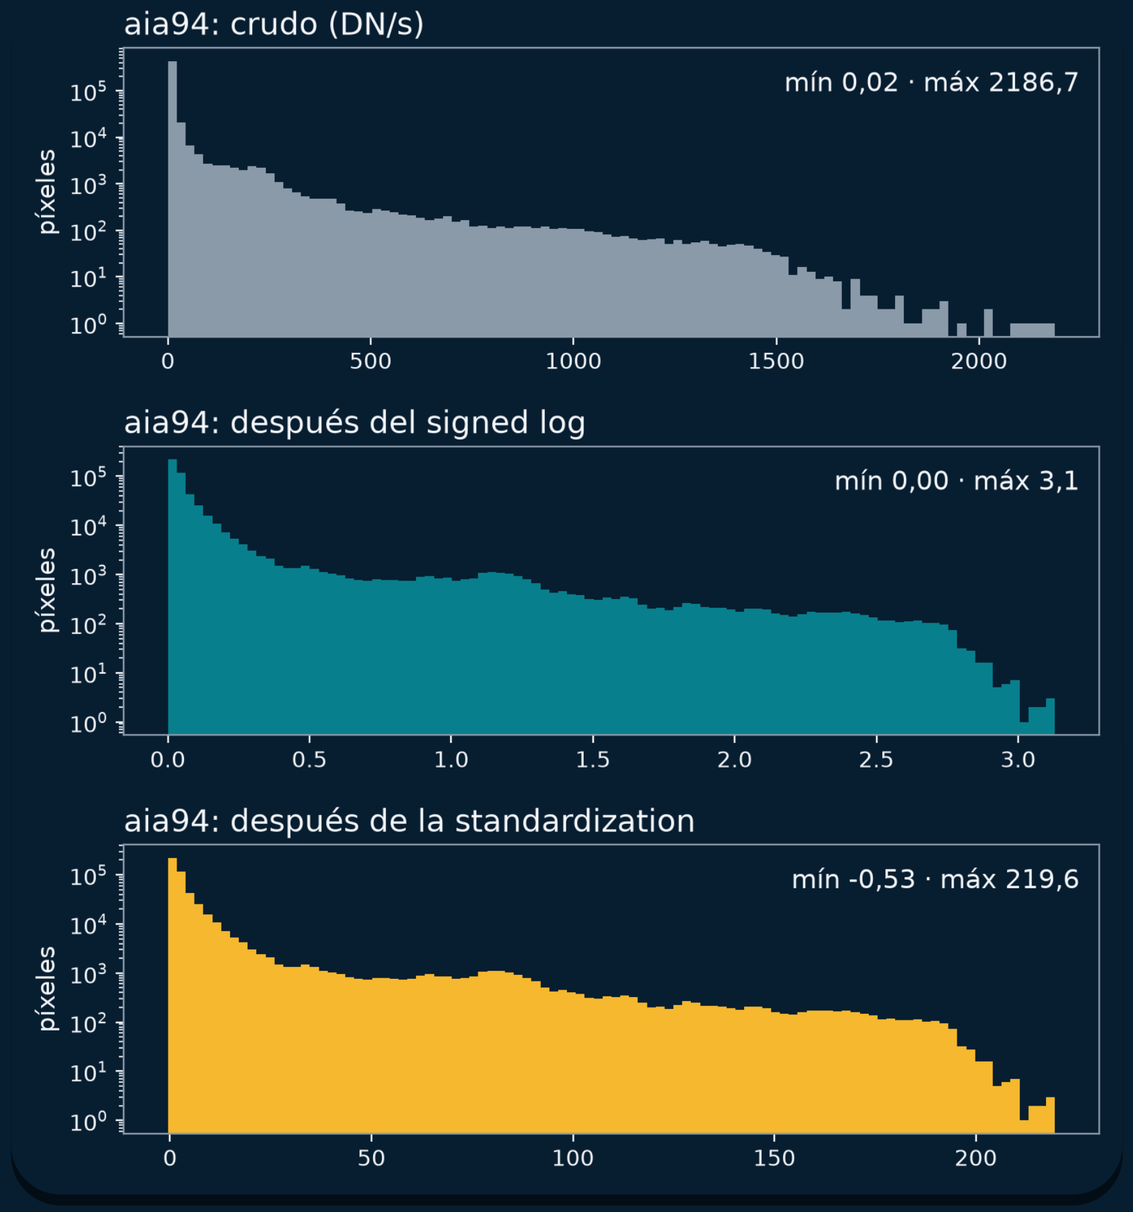


Imagen: histogramas de aia94 en cada paso, AR 11944 (notebook, sección 2)

CONCEPTO

De la región a 256 tokens

- Recorte de **704 × 704 px** alrededor de la AR 11944
- Un token por patch de **16 × 16 px**: **45 × 45** tokens de 1280 dimensiones
- **Adaptive pooling** a 16 × 16 = **256 tokens**
- Surya corre sobre el **disco completo**: se recortan tokens, no la imagen

IDEA CLAVE

Recortar la imagen quitaría el contexto de posición y escala que Surya aprendió.

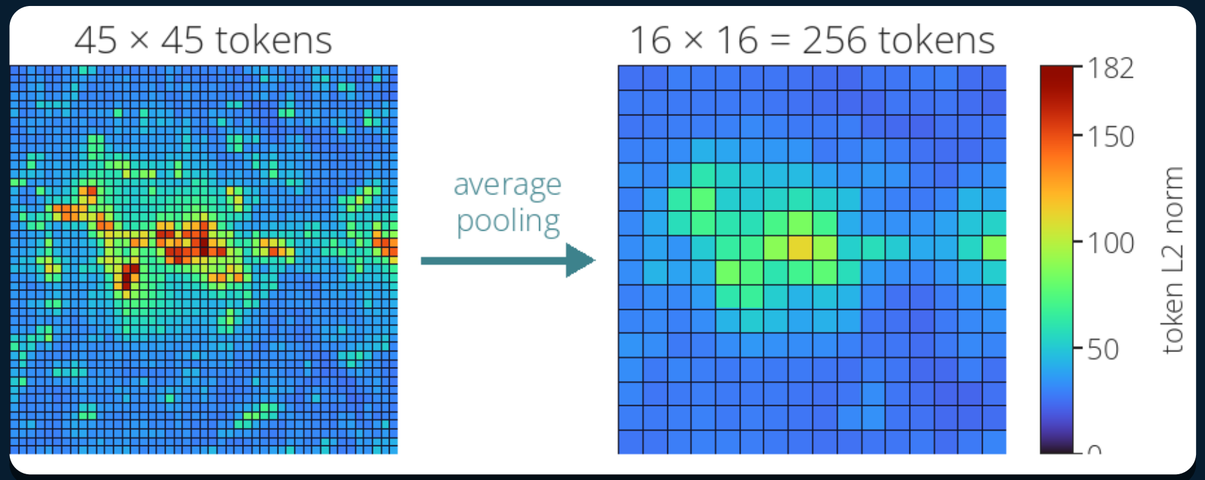


Imagen: norma L2 de los tokens antes y después del pooling

CÓDIGO · PRÁCTICA

Práctica 1: del dato a los tokens

1. Corre las secciones 1 a 5 del notebook
2. Cambia nombre a otro canal y compara los pasos
3. Mira por qué la media no queda en 0

OBJETIVO

Entender la normalización de Surya y sus constantes globales.

01_Del_dato_solar_al_caption.ipynb

```
1  nombre = "aia94"
2  k = constantes[nombre]
3  x = crudo[canales.index(nombre)].astype(np.float64)
4
5  paso1 = x * k["sl_scale_factor"]
6  paso2 = np.sign(paso1) * np.log1p(np.abs(paso1))
7  paso3 = (paso2 - k["mean"]) / (k["std"] + k["epsilon"])
8
9
10
11
```

SALIDA › paso 3: mín −0,526 · máx 219,601 · media 9,203

ARQUITECTURA

Surya + projector + LLM

- **Surya** frozen: 256 tokens de 1280 dimensiones
- **Projector MLP** 1280 → 4096 → GELU → 4096: **22 M** parámetros
- **Qwen3-8B** frozen lee los visual tokens y escribe el caption
- La receta de LLaVA (Liu et al., 2023)

IDEA CLAVE

Solo se entrena el projector: 22 M de parámetros frente a 366 M de Surya.

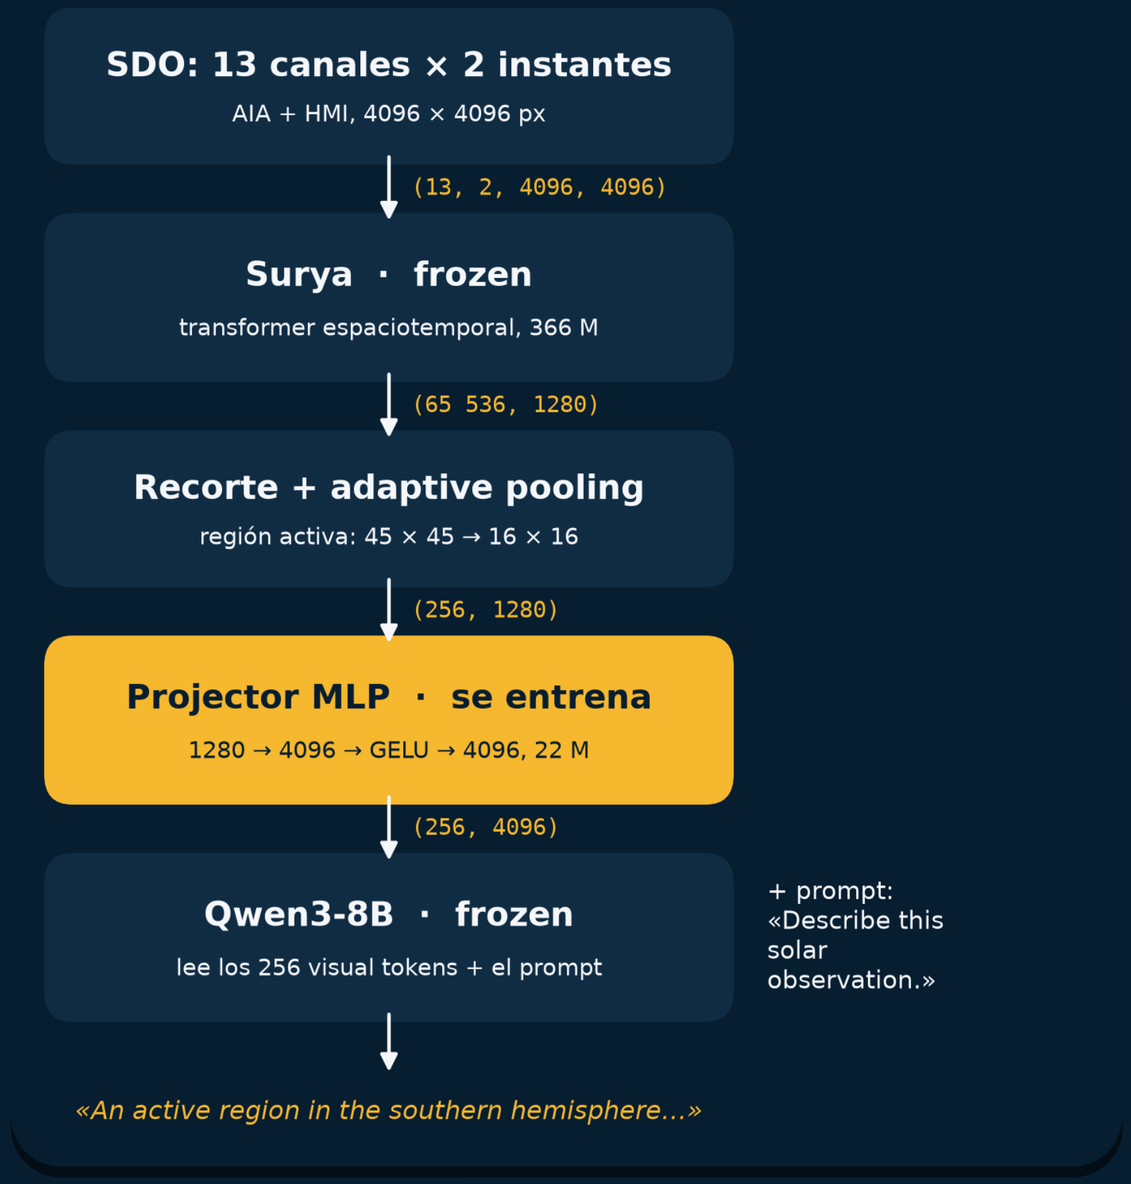


Imagen: elaboración propia, con las formas reales de cada paso

316 posiciones

La secuencia que lee el LLM

Encabezado, 256 visual tokens (posiciones 4 a 259), el prompt y el caption. La loss solo cuenta el caption y su token de fin (275 a 314), no el prompt ni la imagen.

Referencia: notebook, sección 7

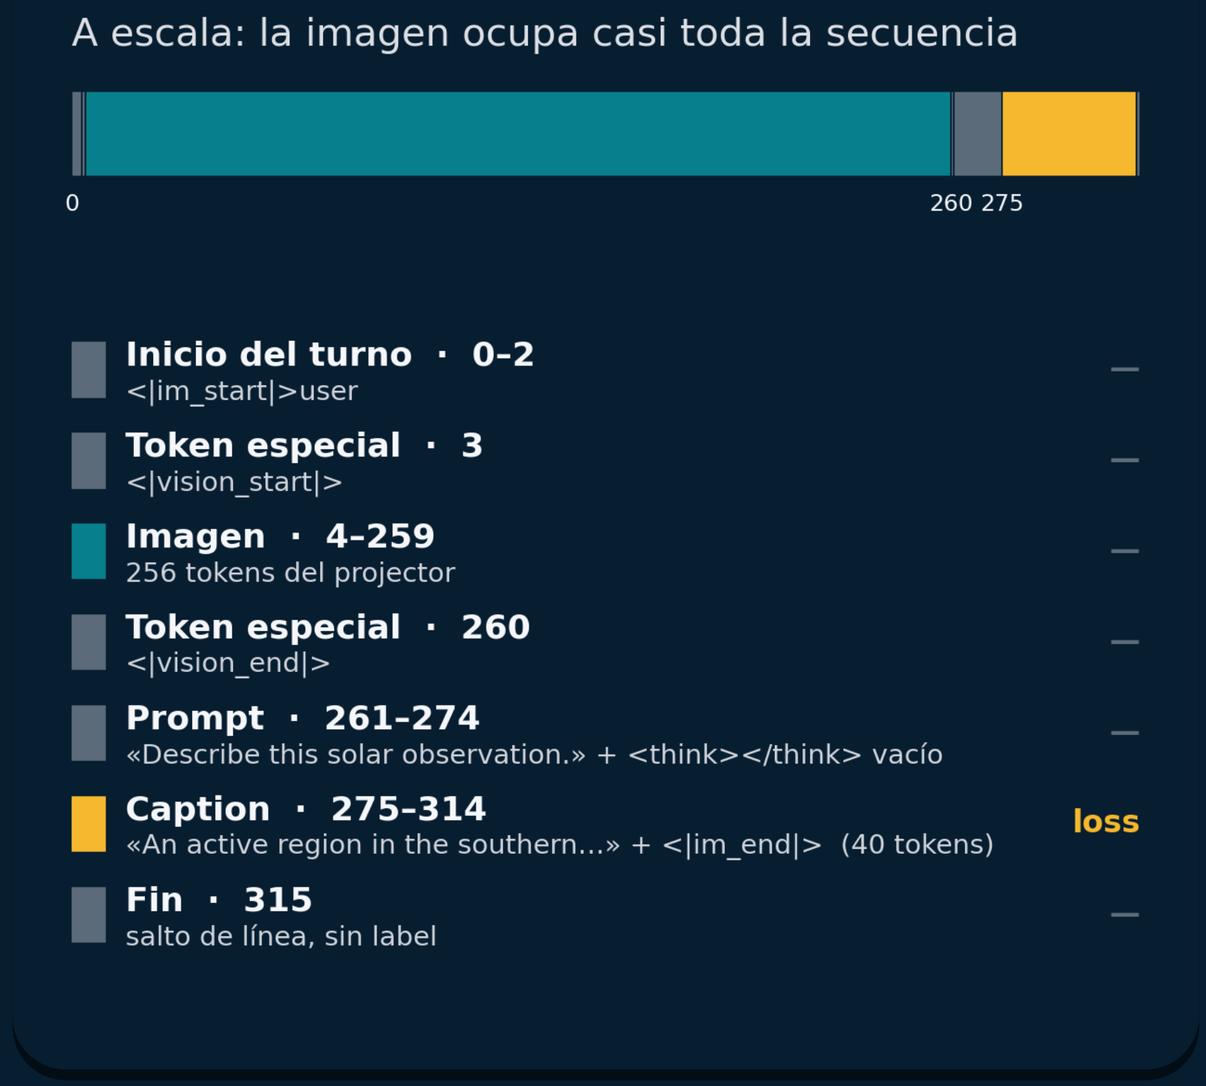


Imagen: elaboración propia a partir de 03_Datos/secuencia_ejemplo.json

CÓDIGO · PRÁCTICA

Práctica 2: el projector

1. Corre las secciones 6 y 7 del notebook
2. Cuenta los parámetros del projector
3. Mira qué posiciones entran en la loss

OBJETIVO

Ver cómo los 256 tokens de Surya se vuelven vectores que el LLM puede leer.

01_Del_dato_solar_al_caption.ipynb

```
1  def gelu(x):
2      return 0.5 * x * (1.0 + erf(x / np.sqrt(2.0)))
3
4  class Proyector:
5      def __call__(self, x):
6          return gelu(x @ self.w1 + self.b1) @ self.w2 + self.b2
7
8  proyector = Proyector()
9  visuales = proyector(agrupados.reshape(256, 1280))
10
11
```

SALIDA › (256, 4096) · 22.028.288 parámetros entrenables

Resultados del prototipo

PRUEBA DE QUE EL FLUJO ENTRENA, NO UN RESULTADO CIENTÍFICO

01

0,557

mejor loss en las regiones held-out (epoch 15)

02

+0,18

image gap: cuánto sube la loss si se cambia la imagen

03

17 / 19

hemisferio correcto en días nuevos (baseline: 7)

04

29 / 55

captions que dicen «sur»; solo 12 regiones lo son

RESULTADOS

Lo que funciona y lo que no

- La loss held-out baja hasta **0,557** y se estabiliza; **la imagen importa**: con otra imagen la loss sube
- En las 2 regiones del 7 ene, **«siempre norte»** gana (36/36 frente a 21/36)
- No aprendió a **contar manchas** (6 de 19 en días nuevos)
- Datos de pocos días y captions de plantilla: aún no hay generalización

IDEA CLAVE

Un porcentaje global engaña: hay que comparar contra baselines y desglosar por clase.

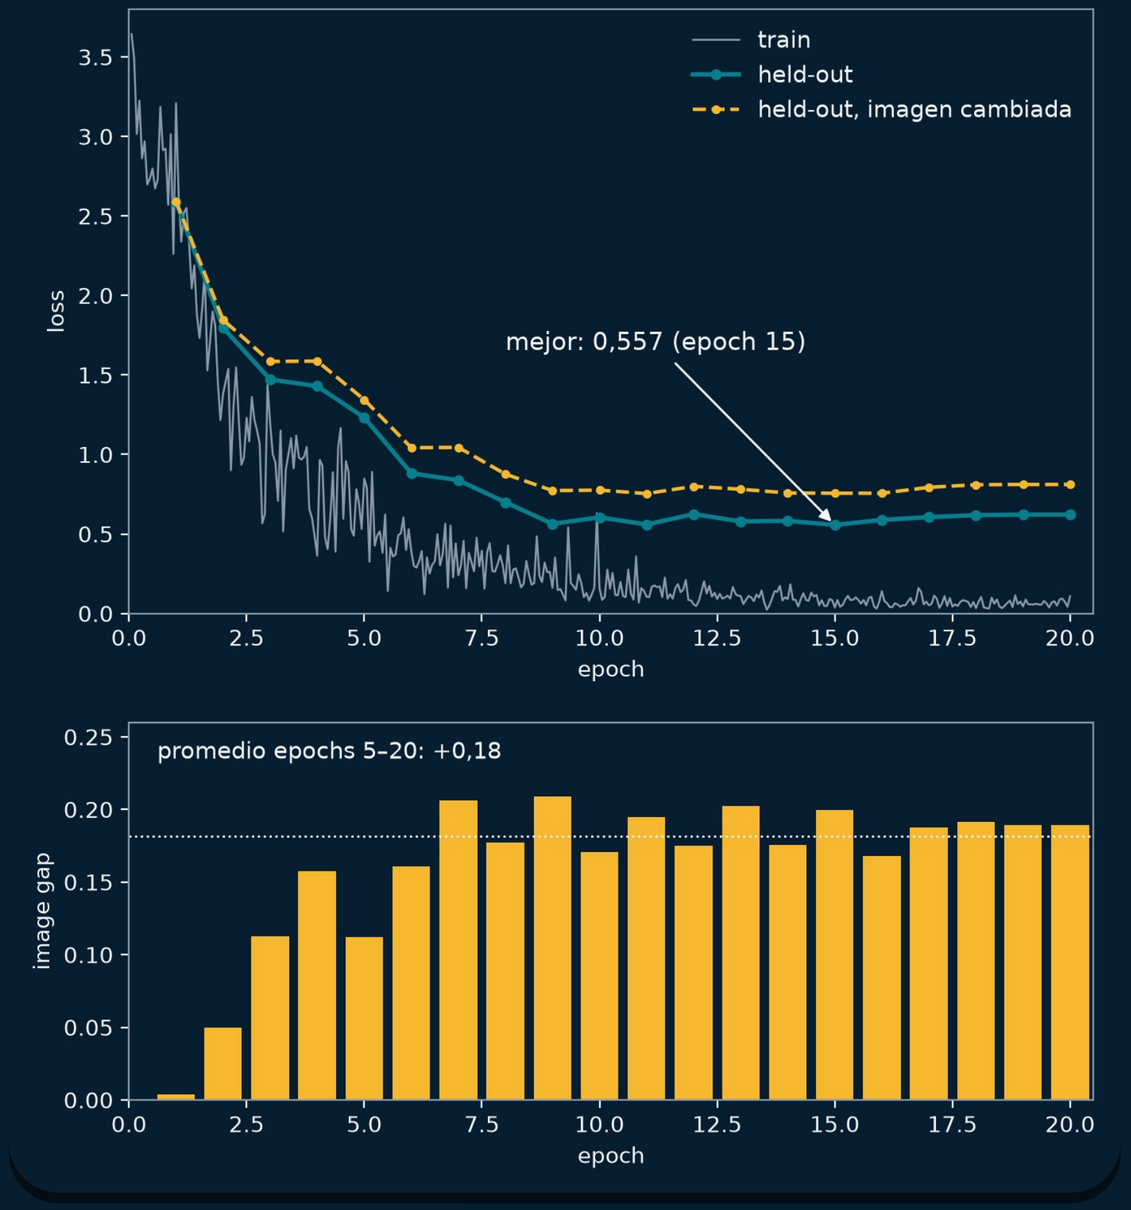


Imagen: loss curves y image gap del prototipo (run 2, 9 oct 2026)

MÁS ALLÁ DE SDO

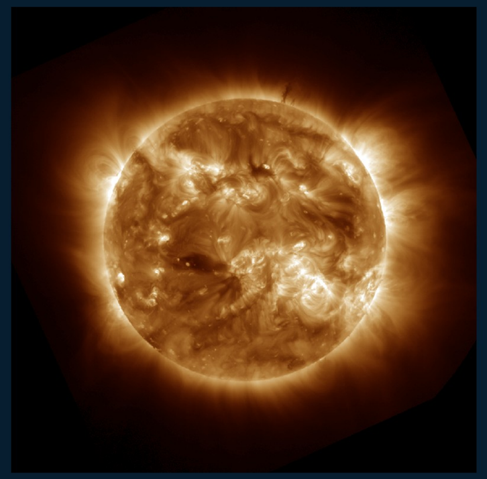
¿Ve Surya a través de GOES-SUVI?

- SUVI es un instrumento **operativo** de GOES-R: daría datos en vivo
- Solo **6 de los 13** canales de Surya tienen equivalente en SUVI
- SUVI: 1280² px a 2,5″/px; AIA: 4096² a 0,6″/px
- Hay cuadros de SUVI con ruido anómalo: falta un filtro de calidad

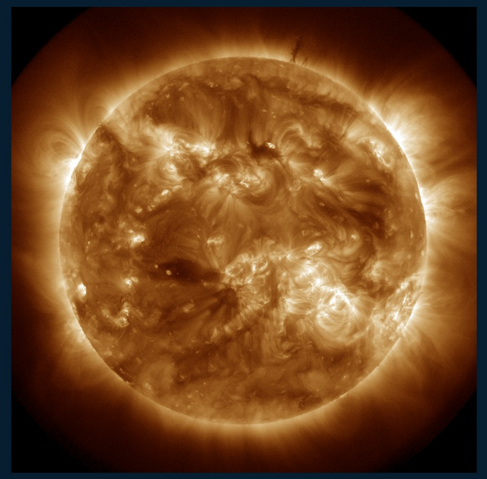
IDEA CLAVE

Si Surya transfiere, el copiloto podría trabajar con datos en vivo además de SDO.

15 mar 2023



GOES-18 SUVI 195 Å
1280² px · 2,50″/px · 09:56 UT



SDO AIA 193 Å
4096² px · 0,60″/px · 09:56 UT

Imagen: elaboración propia. SUVI 195 Å (GOES-18, NOAA) y AIA 193 Å (SDO, NASA), 15 mar 2023, 09:56 UT

Conclusiones

LO QUE NOS LLEVAMOS HOY

1. El ML ya resuelve tareas solares: segmentation, super-resolution, inversión y forecasting
2. Los foundation models como Surya pasan de una tarea a muchas
3. Un projector pequeño conecta Surya con un LLM; faltan mejores datos



TAREA › Ejercicios 1–4 del notebook (sección 9). Para seguir: HelioML

Referencias

LECTURAS

Asensio Ramos, Cheung, Chifu y Gafeira (2023). Machine learning in solar physics. Living Rev. Sol. Phys. 20, 4

Bobra y Mason (2018). Machine Learning, Statistics, and Data Mining for Heliophysics (HelioML). doi:10.5281/zenodo.1412824

Roy et al. (2025). Surya: Foundation Model for Heliophysics. arXiv:2508.14112

Liu et al. (2023). Visual Instruction Tuning (LLaVA). arXiv:2304.08485

Díaz Baso y Asensio Ramos (2018). Enhancing SDO/HMI images using deep learning. A&A 614, A5

Bobra e Ilonidis (2016). Predicting Coronal Mass Ejections Using Machine Learning Methods. ApJ 821, 127

Reiss et al. (2021). The Observational Uncertainty of Coronal Hole Boundaries in Automated Detection Schemes. ApJ 913, 28



MÁS LECTURAS › 04_Lecturas en el repositorio de la escuela

DATOS DE CIENCIA

Datos de Ciencia en YouTube

- Python desde cero para **Ciencia de Datos, ML e IA**
- NumPy con datos reales de **TESS**: el tránsito de WASP-18 b
- **Juan Esteban Agudelo Ortiz** (líder y guion); Thomas Gonzales, Milena Barrios y Claudia Cuellar (presentación); Santiago Pinilla y Daniel Rodríguez (edición)
- En colaboración con miembros del GoSA del OAN

IDEA CLAVE

Lo de hoy (arrays, normalización, imshow) está en la serie de NumPy.



1 · Python desde cero



2 · NumPy vs Python básico



3 · Tipos de datos y precisión

En producción

4 · Shape de los arrays

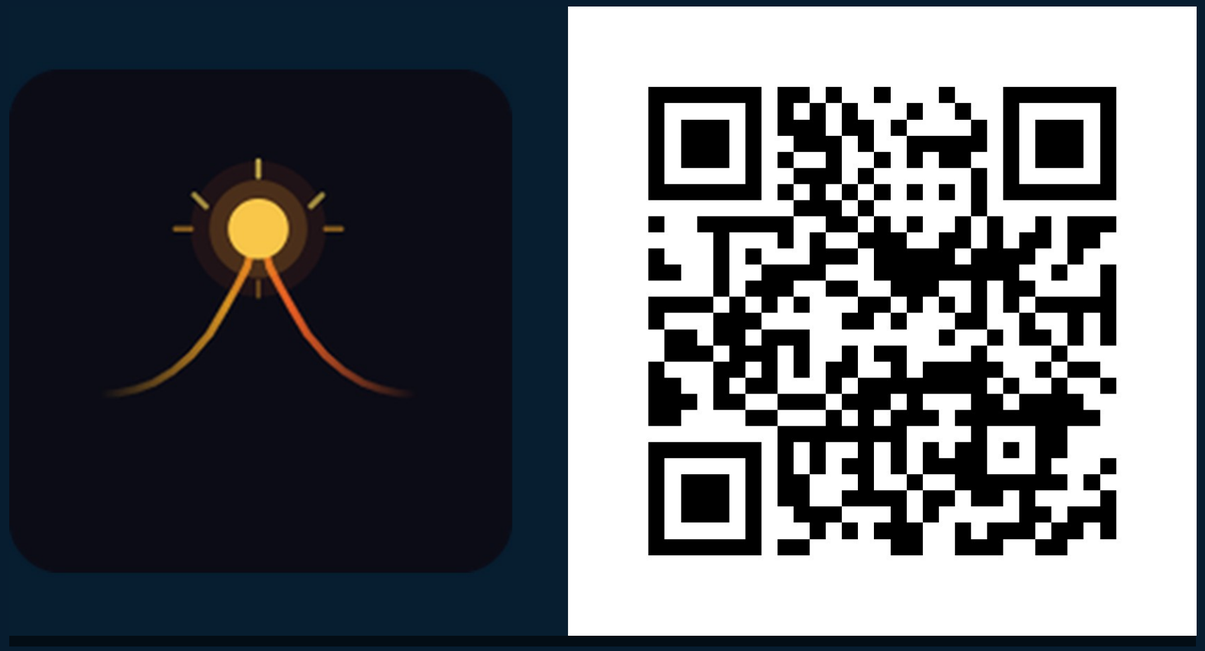
Videos de @Datos.deCiencia: 1 a 3 publicados; 4 en producción

@Datos.deCiencia

¡Suscríbete!

Escanea el código o busca el canal en YouTube. Los notebooks de la serie de NumPy están en github.com/Datos-De-Ciencia.

youtube.com/@Datos.deCiencia



Logo del canal y código QR al canal



¡Gracias!

¿Preguntas?

Juan Esteban Agudelo Ortiz
juagudeloo@unal.edu.co

Registro
tiny.cc/escuelasolar

Más información
astronomiaoan.co/gosa/escuela.html

Organiza: Group of Solar Astrophysics GoSA
Observatorio Astronómico Nacional · UNAL Bogotá